КОМП’ЮТЕРНИЙ ПРАКТИКУМ №1

Тема: Експериментальна оцінка ентропії на символ джерела відкритого тексту

Мета роботи: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Мельниченко Артемій ФБ-41

---

1. Підготовка тексту

Для дослідження обрано російськомовний текст роману Дж. К. Ролінг “Гарри Поттер и Орден Феникса” у файлі “garri_potter_i_orden_feniksa.u.txt”. Обсяг початкового файлу перевищує 1 МБ.

Попередню обробку виконано мовою Python із використанням модуля re. Текст прочитано в кодуванні UTF-8, усі літери приведено до нижнього регістру, літеру ё замінено на е. Послідовності символів, що не належать до діапазону “а-я”, замінено одним пробілом. Пробіли на початку та наприкінці тексту вилучено.

Використаний алфавіт містить 32 літери російської мови без ё, а для обчислень із пробілами - додатково пробіл, тобто 33 символи.

Нормалізований текст збережено у файлі “garri_potter_i_orden_feniksa.u_готово.txt”.

---

2. Розрахунок статистичних характеристик тексту

Для обчислень реалізовано програму task2.py, яка читає попередньо нормалізований текст. Підрахунок кількості символів і біграм виконано за допомогою Counter. Відносні частоти визначено діленням кількості поява символу або біграми на загальну кількість відповідних елементів.

Ентропію обчислено за формулами:

$$H(Z) = -\sum_{i=1}^{n} p_i \log p_i \,.$$

$$H_n = \frac{1}{n} H(x_1, x_2, ..., x_n)$$

$$H(x_1, x_2, ..., x_n) = -\sum_{z_1, z_2, ..., z_n} P(x_1 = z_1, ..., x_n = z_n) \cdot \log_2 P(x_1 = z_1, ..., x_n = z_n)$$

Ділення на 2 у формулі H_2 дозволяє отримати ентропію на один символ. Біграми з перетином вибиралися з кроком 1, без перетину - з кроком 2. Обчислення виконано для тексту з пробілами та після вилучення всіх пробілів.

Показник	З пробілами	Без пробілів
Кількість символів	1324399	1110714

Кількість біграм з перетином	1324398	1110713
Кількість біграм без перетину	662199	555357
H_1, біт/символ	4,374690	4,456150
H_2 з перетином, біт/символ	3,988228	4,156737
H_2 без перетину, біт/символ	3,987803	4,155970
Абсолютна різниця між оцінками H_2	0,000425	0,000766

П’ять найчастіших символів для кожного варіанта тексту:

З пробілами	Відносна частота	Без пробілів	Відносна частота
[пробіл]	0,161345	о	0,110848
о	0,092963	а	0,082826
а	0,069462	е	0,078233
е	0,065611	и	0,069497
и	0,058284	н	0,065308

П’ять найчастіших біграм для тексту з пробілами:

З перетином	Відносна частота	Без перетину	Відносна частота
о[пробіл]	0,020774	о[пробіл]	0,020645
и[пробіл]	0,018914	и[пробіл]	0,018960
а[пробіл]	0,017976	а[пробіл]	0,018031
[пробіл]п	0,016893	[пробіл]п	0,017169
[пробіл]с	0,016337	[пробіл]с	0,016379

П’ять найчастіших біграм для тексту без пробілів:

З перетином	Відносна частота	Без перетину	Відносна частота
то	0,014357	то	0,014362
на	0,012998	на	0,012891
он	0,012639	он	0,012763

по	0,011537	по	0,011456
не	0,011100	не	0,011115

Позначення [пробіл] використано лише для відображення пробілів у таблицях. Повні таблиці частот символів і біграм збережено у файлі frequencies.csv, який додається до роботи.
Оцінки H_2 для двох способів вибору біграм виявилися близькими. Для тексту з пробілами різниця становить приблизно 0,000425 біт/символ, без пробілів - 0,000766 біт/символ. Відмінності виникають через різні набори врахованих пар: спосіб без перетину пропускає пари між сусідніми двосимвольними блоками. Спосіб із перетином використовує більше статистичних даних: для тексту довжини N він враховує N - 1 біграму, тоді як спосіб без перетину - ⌊N/2⌋. Для дослідженого тексту це приблизно вдвічі більше пар. В обох варіантах H_2 менше за H_1, що узгоджується з наявністю залежностей між сусідніми символами. Після вилучення пробілів обидві оцінки зросли. Зокрема, вилучено найчастіший символ пробіл, а також змінено склад біграм через з'єднання сусідніх слів.

---

3. Дослідження впливу розподілу символів на ентропію

Для експерименту використано три послідовності довжиною 100 000 символів на алфавіті з 32 російських літер без "ё": А - фрагмент підготовленого тексту без пробілів; Б - повторення літери "а"; В - випадкова послідовність із рівноймовірним вибором літер. Прогноз: H_1(Б) < H_1(А) < H_1(В). Для послідовності Б очікується нульова ентропія, оскільки кожний символ однаковий. Для природного тексту А ентропія має бути більшою за нуль, але меншою за максимальну через нерівномірні частоти літер. Для послідовності В очікується значення, близьке до log_2(32) = 5 біт/символ.

```
А: довжина = 100000, H1 = 4.463642 біт/символ
Б: довжина = 100000, H1 = -0.000000 біт/символ
В: довжина = 100000, H1 = 4.999691 біт/символ
```

Для кожної послідовності довжиною 100 000 символів отримано такі значення H_1 у біт/символ: А - 4,463642, Б - 0, В - 4,999691. Прогноз підтвердився: H_1(Б) < H_1(А) < H_1(В). У послідовності Б завжди з'являється літера "а", тому її ентропія дорівнює нулю. У природному тексті А одні літери трапляються частіше за інші, тому H_1 менша за 5 біт/символ. У випадковій послідовності В частоти 32 літер майже однакові, тож H_1 наблизилася до максимального значення 5 біт/символ.

---

4. Дослідження залежностей між символами

Послідовність Д утворено повторенням пари "аб" 50000 разів. Для отримання послідовності Г ті самі символи перемішано у випадковому порядку.
Прогноз: Для обох послідовностей H_1 дорівнюватиме 1 біт/символ, оскільки кожна з двох літер становить рівно половину тексту. Значення H_2 очікую меншим для Д. З кроком 1 у Д трапляються дві біграми, "аб" і "ба", майже порівну, тому H_2 буде близькою до 0,5 біт/символ. З кроком 2 щоразу отримуємо одну й ту саму пару "аб", тому H_2 дорівнюватиме нулю. Для Г очікую близькі до 1 біт/символ значення H_2 за

обох способів підрахунку, оскільки після перемішування всі чотири можливі пари мають траплятися приблизно однаково часто.

```
Г
H1 = 1.000000
H2 з перетином = 0.999998
H2 без перетину = 0.999985

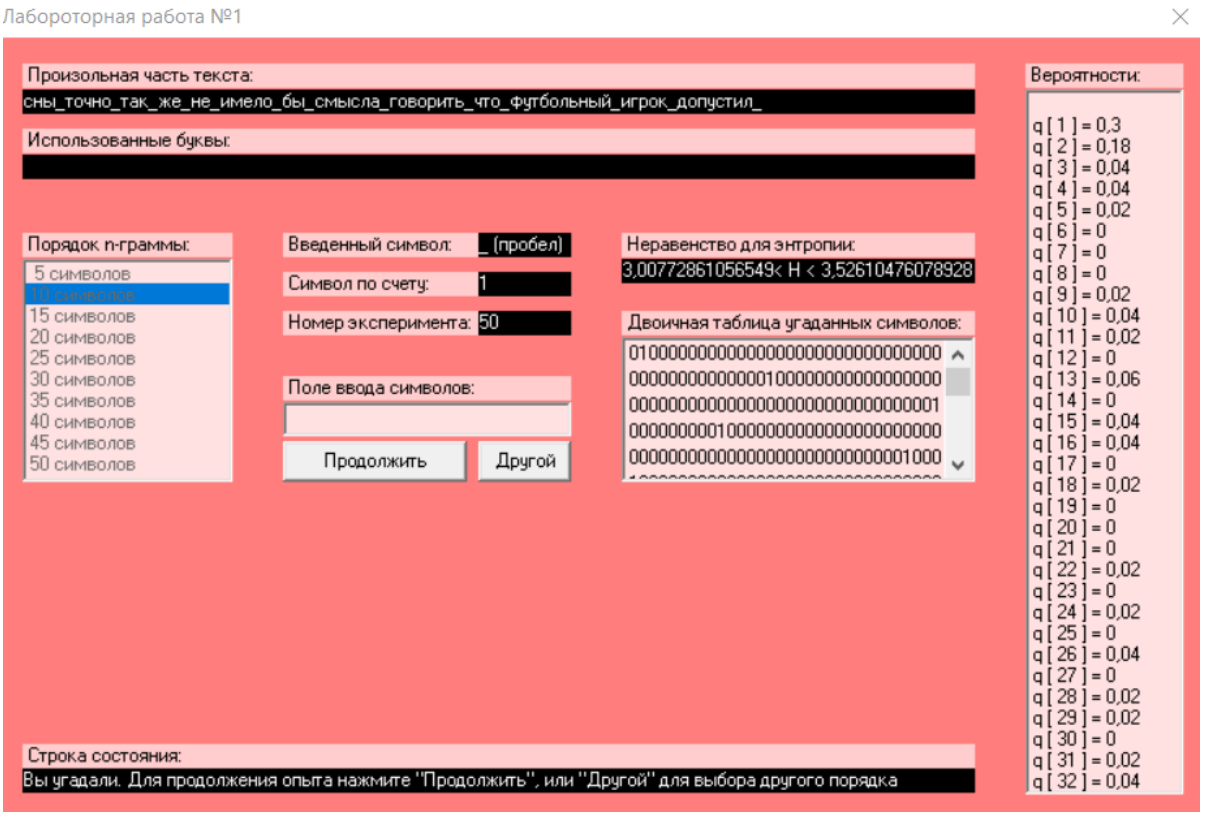
Д
H1 = 1.000000
H2 з перетином = 0.500000
H2 без перетину = 0.000000
```

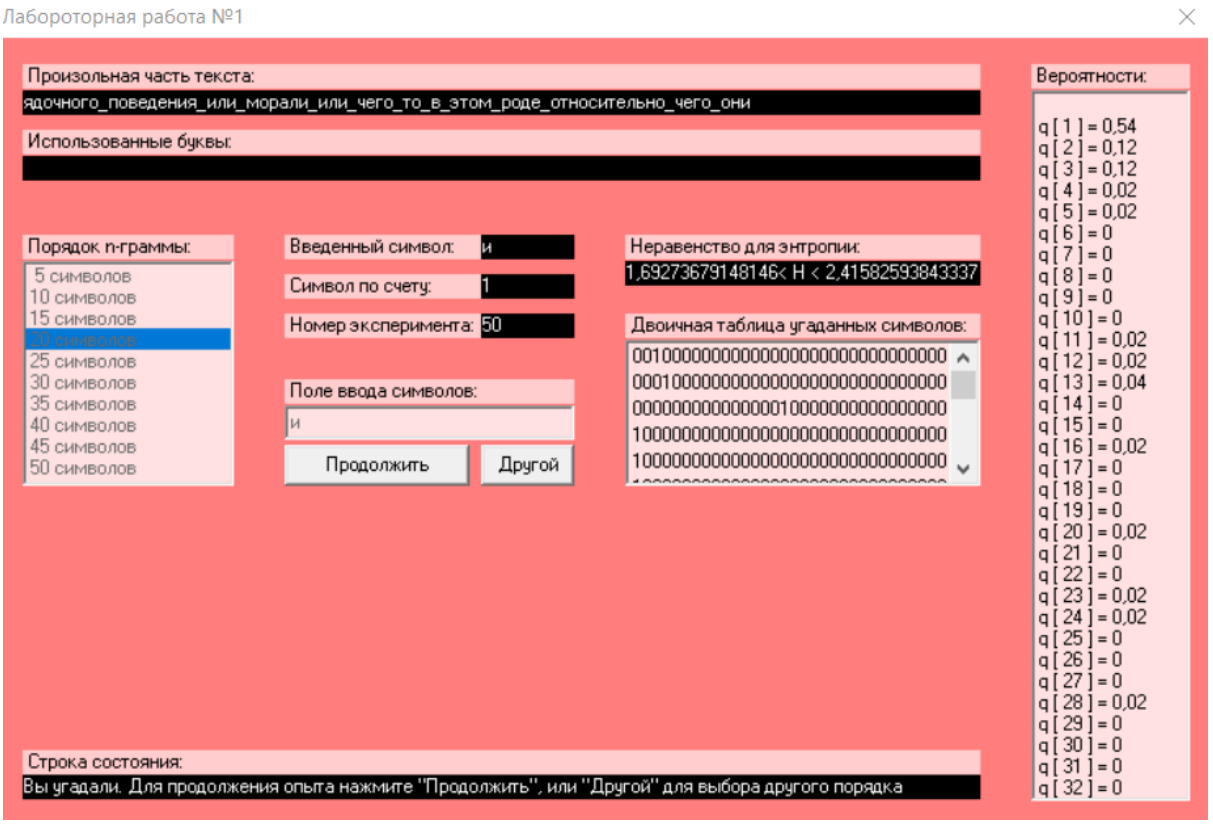
Послідовність	H_1, біт/символ	H_2 з перетином б/с	H_2 без перетину, б/с
Г (випадковий порядок)	1,000000	0,999998	0,999985
Д (чергування “аб”)	1,000000	0,500000	0,000000

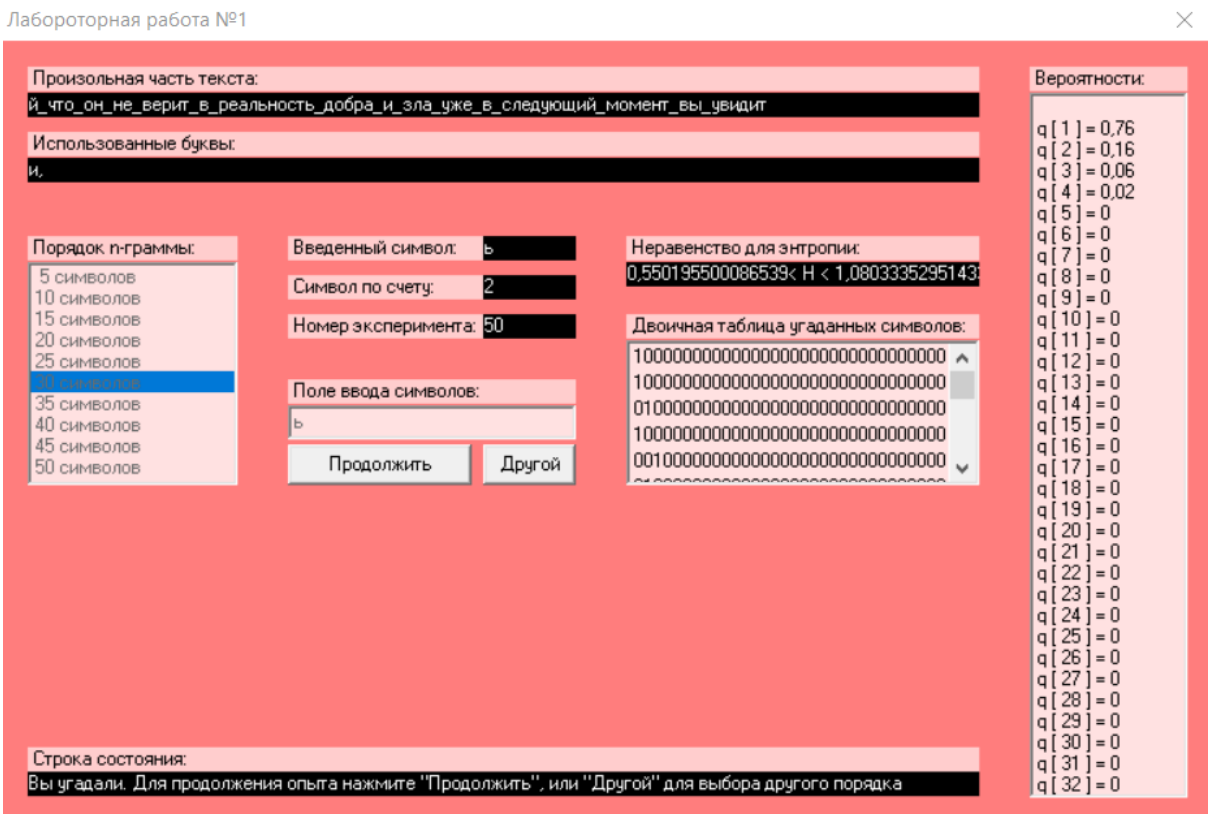
Прогноз підтвердився. В обох послідовностях літери “а” і “б” мають частоту 0,5, тому H_1 однакова й дорівнює 1 біт/символ. У послідовності Г усі чотири біграми траплялися приблизно однаково часто, тому обидві оцінки H_2 близькі до 1 біт/символ.
У послідовності Д з кроком 1 біграма “аб” трапилася 50 000 разів, а “ба” - 49 999 разів. Ентропія такої пари близька до 1 біта, тобто до 0,5 біта на символ. З кроком 2 усі 50 000 пар однакові (“аб”), тому H_2 = 0. Отже, за однакових частот окремих літер модель біграм виявляє різницю в порядку їх розташування.

---

5. Експериментальна оцінка ентропії джерела


Лабороторная работа №1
Произольная часть текста:
сны_точно_так_же_не_имело_бы_смысла_говорить_что_футбольный_игрок_допустил_
Использованные буквы:
Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов
Введенный символ: _ (пробел)
Символ по счету: 1
Номер эксперимента: 50
Поле ввода символов:
Продолжить
Другой
Неравенство для энтропии:
3,00772861056549< H < 3,52610476078928
Двоичная таблица угаданных символов:
Вероятности:
q [1] = 0,3
q [2] = 0,18
q [3] = 0,04
q [4] = 0,04
q [5] = 0,02
q [6] = 0
q [7] = 0
q [8] = 0
q [9] = 0,02
q [10] = 0,04
q [11] = 0,02
q [12] = 0
q [13] = 0,06
q [14] = 0
q [15] = 0,04
q [16] = 0,04
q [17] = 0
q [18] = 0,02
q [19] = 0
q [20] = 0
q [21] = 0
q [22] = 0,02
q [23] = 0
q [24] = 0,02
q [25] = 0
q [26] = 0,04
q [27] = 0
q [28] = 0,02
q [29] = 0,02
q [30] = 0
q [31] = 0,02
q [32] = 0,04
Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка


Лабороторная работа №1
Произольная часть текста:
ядочного_поведения_или_морали_или_чего_то_в_этом_роде_относительно_чего_они
Использованные буквы:
Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов
Введенный символ: и
Символ по счету: 1
Номер эксперимента: 50
Поле ввода символов:
и
Продолжить
Другой
Неравенство для энтропии:
1,69273679148146< H < 2,41582593843337
Двоичная таблица угаданных символов:
Вероятности:
q [1] = 0,54
q [2] = 0,12
q [3] = 0,12
q [4] = 0,02
q [5] = 0,02
q [6] = 0
q [7] = 0
q [8] = 0
q [9] = 0
q [10] = 0
q [11] = 0,02
q [12] = 0,02
q [13] = 0,04
q [14] = 0
q [15] = 0
q [16] = 0,02
q [17] = 0
q [18] = 0
q [19] = 0
q [20] = 0,02
q [21] = 0
q [22] = 0
q [23] = 0,02
q [24] = 0,02
q [25] = 0
q [26] = 0
q [27] = 0
q [28] = 0,02
q [29] = 0
q [30] = 0
q [31] = 0
q [32] = 0
Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка



У програмі CoolPinkProgram виконано по 50 експериментів для кожного порядку n-грами (10, 20 і 30). За наведеним фрагментом тексту потрібно було вгадати наступний символ. Програма фіксувала номер спроби, з якої вдалося вгадати символ, і за результатами серії визначала нижню та верхню межі ентропії.
Для порівняння використано значення H_1 та H_2, обчислені у пункті 2 для тексту з пробілами. Для H_2 взято біграми з перетином.

Оцінка	Отримане значення
H_1	4,3747
H_2	3,9882
H^10	3,0077<H^10<3,52611
H^20	1,6927<H^20<2,4158
H^30	0,5502<H^30<1,0803

Оцінка H_1 враховує лише частоти окремих символів. Оцінка H_2 додатково враховує, які символи трапляються поруч і як часто утворюють певну пару. Для дослідженого тексту врахування сусідніх символів знизило оцінку ентропії з 4,3747 до 3,9882 біт/символ.
У CoolPinkProgram довший фрагмент допомагав розпізнати слово, передбачити його закінчення або відновити зміст фрази. Для порядку 10 з першої спроби вдалося вгадати 15 символів із 50 (30%), для порядку 20-27 із 50 (54%), а для порядку 30-38 із

50 (76%). В усіх трьох серіях зі збільшенням порядку знижувалися обидві межі оцінки ентропії.
Отримані оцінки не повинні точно збігатися. H_1 і H_2 обчислено за частотами символів і пар у вибраному романі, тоді як у CoolPinkProgram використано інший текст, а результат залежав від спроб учасника. На окремі відповіді також могло вплинути звіряння з текстом книги. У цих експериментах довший контекст полегшував передбачення наступного символу.

---

6. Оцінювання надлишковості джерела
Надлишковість джерела обчислено за формулою R = 1-H /H_0, де H - отримана оцінка ентропії на символ, а H_0 = log_2(m) - максимальна ентропія для алфавіту з m символів. Для тексту з пробілами H_0 = log_2(33) = 5,0444 біт/символ, а без пробілів H_0 = log_2(32) = 5 біт/символ.

Модель	З пробілами	Без пробілів
Окремі символи H_1	13,28%	10,88%
Біграми з перетином H_2	20,94%	16,87%
Біграми без перетину H_2	20,95%	16,88%

Для оцінок CoolPinkProgram за основу порівняння взято той самий алфавіт із пробілом (H_0 = 5,0444 біт/символ). Оскільки програма визначає інтервал ентропії, надлишковість також подано інтервалом. Верхній межі H відповідає нижня межа R, оскільки зі збільшенням H значення R зменшується.

Порядок	Межі ентропії біт/символ	Межі надлишковості %
10	3,0077-3,5261	30,1-40,4
20	1,6927-2,4158	52,1-66,4
30	0,5502-1,0803	78,6-89,1

Для тексту з пробілами перехід від окремих символів до біграм з перетином підвищив оцінку надлишковості з 13,28% до 20,94%. Природна мова має ненульову надлишковість, бо літери трапляються з різною частотою, а їхній порядок у словах підпорядковується певним закономірностям. Це видно й у дослідах із вгадуванням: за довшим фрагментом легше розпізнати слово або його закінчення. Чим передбачуваніший наступний символ, тим менша його невизначеність і тим вища оцінка надлишковості.

Аналіз результатів

1. У природному тексті одні літери трапляються частіше за інші, тому ймовірність наступної літери можна оцінити навіть без контексту. У досліді 3 для фрагмента

роману отримано H_1 = 4,463642 біт/символ. Для випадкової послідовності тієї самої довжини H_1 = 4,999691 біт/символ. Це близько до максимуму для 32 рівноймовірних літер - 5 біт/символ.

2. H_1 залежить від частот окремих символів, а H_2 враховує частоти впорядкованих пар сусідніх символів. Наприклад, у тексті з пробілами найчастішою парою була літера “о” перед пробілом. За частотою самої літери “о” неможливо визначити, як часто після неї закінчується слово.
3. Так. У досліді 4 обидві послідовності містили по 50 000 літер “а” і “б”, тому H_1 в обох випадках дорівнювала 1 біт/символ. Через різний порядок літер H_2 з перетином для перемішаної послідовності Г становила 0,999998 біт/символ, а для періодичної послідовності Д - 0,500000 біт/символ.
4. Після вилучення пробілів H_1 зросла з 4,374690 до 4,456150 біт/символ. Пробіл був найчастішим символом і становив 16,13 % тексту. Його вилучення змінило відносні частоти символів і склад біграм, оскільки остання літера одного слова стала сусідньою з першою літерою наступного. H_2 з перетином зросла з 3,988228 до 4,156737 біт/символ.
5. З кроком 1 враховується кожна пара сусідніх символів. З кроком 2 пропускаються пари на межах двосимвольних блоків. Для тексту з пробілами перший спосіб охопив 1 324 398 пар, а другий - 662 199. Відносні частоти пар у цих вибірках дещо відрізнялися, тому різниця між оцінками H_2 становила приблизно 0,000425 біт/символ.
6. H_1 і H_2 обчислено за частотами символів і біграм у романі. Оцінки H^10, H^20 і H^30 отримано в CoolPinkProgram на іншому тексті за кількістю спроб, потрібних для вгадування наступного символу. Для порядків 10, 20 і 30 частка правильних відповідей із першої спроби становила відповідно 30 %, 54 % і 76 %. За довшими фрагментами було легше впізнавати слова, і в кожній наступній серії обидві межі оцінки ентропії знижувалися. На окремі відповіді також вплинуло звіряння з текстом книги.
7. Найкраще залежність між сусідніми символами показав дослід 4, оскільки змінювався лише порядок літер. У послідовності Д після “а” завжди стояла “б”. За поділу з кроком 2 усі пари мали вигляд “аб”, тому H_2 = 0. Після перемішування тих самих літер H_2 без перетину становила 0,999985 біт/символ.
8. Частим символам або парам можна призначати коротші коди, а рідкісним - довші. Це дає змогу зменшити середню кількість бітів на символ і зберегти можливість точного відновлення тексту. Для тексту з пробілами оцінка надлишковості становила 13,28 % за частотами символів і 20,94 % за біграмами з перетином. Ці значення характеризують потенціал стиснення відносно моделі рівноймовірних символів. Фактичний розмір стисненого файлу залежить від способу кодування.

Висновки

Для дослідженого тексту з пробілами отримано H_1 = 4,374690 біт/символ і H_2 = 3,988228 біт/символ для біграм з перетином. Вплив порядку символів найчіткіше проявився під час порівняння перемішаної та періодичної послідовностей. За однакових частот літер вони мали однакову H_1, але різну H_2. У дослідах із CoolPinkProgram довший контекст допомагав передбачати наступний символ.

Нерівномірні частоти літер і зв'язки між ними створюють надлишковість, яку можна використати для стиснення тексту без втрат.