

Міністерство освіти і науки України
Національний технічний університет України
"Київський політехнічний інститут імені Ігоря Сікорського"
Фізико-технічний інститут

Криптографія
Комп'ютерний практикум №1

Виконали студенти гр. ФБ-42

Бобров Павло

Ходячих Нікіта

Київ – 2026

Комп'ютерний практикум №.1

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Мета роботи:

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Хід роботи

Для аналізу обрано текст з книги «война и мир» Л. Толстого з [github репозиторію](#). Розмір файлу до обробки становить 3315 КБ.

Код для завдань 1-4 відповідно розташований у відповідних [1-4].py файлах. За алфавіт взято Російський з 32 букв + пробіл (всі ё замінені на е)

1. Підготовка тексту

Виконайте попередню обробку тексту відповідно до таких правил:

- усі літери привести до нижнього регістру;
- символи, що не належать до заданого алфавіту, вилучити або замінити пробілами;
- послідовності пробілів та інших розділових символів трактувати як один пробіл;
- для обчислень без пробілів вилучити всі пробіли з попередньо нормалізованого тексту.

Пишу відповідний код і зберігаю результат в cleaned_war.txt та cleaned_war_nospaces.txt

```
(.venv) PS D:\DZ\Crypto> d:; cd 'd:\DZ\Crypto';  
ions\ms-python.debugpy-2026.6.0-win32-x64\bundle  
yachih\1.py'  
Довжина тексту з пробілами: 1776648 символів  
Довжина тексту без пробілів: 1485071 символів
```

З початкових 1 901 009 символів текст скоротився до 1 776 648 та 1 485 071 символів з пробілами та без них відповідно

2. Розрахунок статистичних характеристик тексту

Реалізуйте програму для:

1. підрахунку частот окремих символів;
2. підрахунку частот біграм;
3. обчислення H_1 за частотами окремих символів;
4. обчислення H_2 за частотами біграм.

Частоти біграм та відповідне значення H_2 визначте двома способами:

- для біграм, що перетинаються, тобто при послідовному зміщенні на один символ;
- для біграм, що не перетинаються, тобто при зміщенні на два символи.

Виконайте обчислення для:

- нормалізованого тексту з пробілом як символом алфавіту;
- того самого тексту після вилучення всіх пробілів.

Для кожного випадку визначте п'ять символів та п'ять біграм із найбільшими частотами.

<pre>===== РЕЗУЛЬТАТИ ДЛЯ: cleaned_war.txt ===== Довжина тексту: 1776648 символів --- Монограми (H1) --- H1 = 4.377652 біт/символ Топ-5 найчастіших символів: ' ': 0.164116 (291577) 'o': 0.095635 (169910) 'e': 0.068894 (122400) 'a': 0.068801 (122235) 'i': 0.055411 (98446) --- Біграми, що перетинаються (H2) --- H2 (перетинаються) = 3.967380 біт/символ Топ-5 найчастіших біграм: 'о ': 0.022187 (39419) 'и ': 0.018774 (33355) 'е ': 0.017034 (30264) 'а ': 0.016321 (28997) ' н': 0.015668 (27837) --- Біграми, що не перетинаються (H2) --- H2 (не перетинаються) = 3.967633 біт/символ Топ-5 найчастіших біграм: 'о ': 0.022209 (19729) 'и ': 0.018847 (16742) 'е ': 0.017073 (15166) 'а ': 0.016348 (14522) ' н': 0.015568 (13829)</pre>	<pre>===== РЕЗУЛЬТАТИ ДЛЯ: cleaned_war_nospaces.txt ===== Довжина тексту: 1485071 символів --- Монограми (H1) --- H1 = 4.466633 біт/символ Топ-5 найчастіших символів: 'o': 0.114412 (169910) 'e': 0.082420 (122400) 'a': 0.082309 (122235) 'i': 0.066290 (98446) 'n': 0.065721 (97600) --- Біграми, що перетинаються (H2) --- H2 (перетинаються) = 4.147174 біт/символ Топ-5 найчастіших біграм: 'то': 0.016887 (25079) 'ст': 0.013168 (19555) 'на': 0.012231 (18164) 'ов': 0.011568 (17179) 'ал': 0.010921 (16219) --- Біграми, що не перетинаються (H2) --- H2 (не перетинаються) = 4.147440 біт/символ Топ-5 найчастіших біграм: 'то': 0.017016 (12635) 'ст': 0.013039 (9682) 'на': 0.012296 (9130) 'ов': 0.011533 (8564) 'ал': 0.010878 (8077)</pre>
--	--

Порівняйте значення H_2 , отримані для біграм, що перетинаються та не перетинаються. Поясніть можливі відмінності між результатами та визначте, який спосіб використовує більше статистичних даних.

Для тексту з пробілами маємо $H_2 = 3.967380$ та 3.967633 , різниця 0.000253

Для тексту без пробілів маємо $H_2 = 4.147174$ та 4.147440 , різниця 0.000266

В обох варіантах тексту ентропія без перетину виявилась вищою, проте різниця ну дуже мала і становить менше 0.01% відхилення. Набори та порядок топ-5 найчастіших біграм в обох випадках є абсолютно ідентичними, а їх частоти є близькими (різниці в порядку помітні лише після 10-го елемента, коли у декількох різних біграм досить близькі частоти)

Спосіб з біграмами що перетинаються використовує удвічі більше статистичних даних. Хоч і використано досить великий текст, з усіх потенційно можливих 1089 та 1024 біграм (з пробілом та без відповідно) в тексті зустрічається $797/773$ та $888/870$ (з/без перетину) унікальних. Частоти з/без пробіла між однаковими біграмами мають лише невелику похибку, яка і зумовлена різницею кількості даних. На більшій вибірці ця похибка буде меншою у відсотковому значенні, а зміна порядку топу почне відбуватися пізніше.

3. Дослідження впливу розподілу символів на ентропію

Підготуйте три послідовності достатньої для проведення експерименту довжини:

- А — фрагмент природного російськомовного тексту;
- Б — послідовність, утворену повторенням одного символу;
- В — випадкову послідовність символів того самого алфавіту, в якій усі символи генеруються з однаковою ймовірністю.

До виконання обчислень розташуйте послідовності А, Б і В у порядку очікуваного зростання H_1 та коротко обґрунтуйте свій прогноз.

За допомогою власної програми обчисліть H_1 для кожної послідовності. Порівняйте отримані результати з попереднім прогнозом. Поясніть, як характер розподілу ймовірностей символів впливає на ентропію джерела.

Послідовність Б вірогідно матиме найнижчу ентропію рівну 0, бо для цього 1 символу вірогідність буде 100%, а для інших 0%

Послідовність А буде мати щось близьке до результатів минулого коду (4.4666), але з можливо з невеликим відхиленням через меншу вибірку

Послідовність В буде мати найвищу ентропію близьку до максимальної ($\log_2(32)=5$) через однакову вірогідність кожного символу (можливе незначне відхилення)

```
H1(A) = 4.465272
H1(B) = -0.000000
H1(V) = 4.999795
```

Обрахунки програмою на вибірці з 100 000 елементів показали те, що й було спрогнозовано.

4. Дослідження залежностей між символами

Сформууйте дві послідовності однакової довжини, побудовані на однаковому алфавіті та з однаковими або максимально близькими частотами окремих символів:

- Г — символи розташовані у випадковому порядку;
- Д — символи утворюють виражену періодичну структуру, наприклад abababab....

До виконання обчислень сформулюйте прогноз:

1. чи повинні суттєво відрізнятися значення H_1 для послідовностей Г і Д;
2. чи повинні суттєво відрізнятися значення H_2 ;
3. для якої послідовності ви очікуєте менше значення H_2 .
4. чи відрізнятимуться H_2 обчислене для біграм що перетинаються і що не перетинаються Обчисліть H_1 та H_2 для обох послідовностей.

Порівняйте результати з прогнозом та поясніть:

- чому тексти з однаковими частотами окремих символів можуть мати однакові або близькі значення H_1 ;
- чому їхні значення H_2 можуть відрізнятися;
- яку інформацію про джерело дозволяє врахувати модель біграм порівняно з моделлю незалежних символів.

Так як в цьому випадку в нас алфавіт з 4 букв (абвг) то максимальна ентропія – $\log_2(4)=2$

Для H_1 вірогідно в цих обох послідовностях буде +- однакове значення – в Д буде рівно 2 (бо в нас гарантовано рівна частота кожного елемента) а в Г близька до 2 (невелике відхилення через розмір вибірки – 100 000)

Для значень H_2 вже значення повинні суттєво відрізнятися – для Д в нас буде рівно 1/0.5 з/без перетину, бо з можливих для такого алфавіту $2^4=16$ біграм наявні лише 4/2 (аб,бв,вг,га/аб,вг) що й відповідає такій ентропії, а для Г ентропія все одно буде близькою до 2 (єдине що знову можливе невелике відхилення через розмір вибірки)

```
--- ПОСЛІДОВНІСТЬ Г ---
H1                = 1.999940
H2 (перетинаються) = 1.999929
H2 (не перетинаються) = 1.999871

--- ПОСЛІДОВНІСТЬ Д ---
H1                = 2.000000
H2 (перетинаються) = 1.000000
H2 (не перетинаються) = 0.500000
```

Прогнози й результат відповідні

Тексти з однаковими частотами окремих символів можуть мати однакові або близькі значення H_1 , бо враховується лише ймовірності появи поодиноких літер, а перестановка всіх літер в послідовності не змінює загальну кількість входжень кожної літери.

Для H_2 ж різниця вже може бути, бо при конкретних послідовностях (природній текст також можна вважати послідовністю) ми можемо виключити деякі можливі пари або змінити їх частоту появи, що зменшить

ентропію. При цьому при повній відсутності послідовності, ентропія буде наближена до максимальної (при достатній вибірці). Це також видно на прикладах вище.

Модель H1 вважає джерело пам'яті позбавленим (марковський процес 0-го порядку), де кожен наступний символ обирається випадково та незалежно від попередніх. Модель біграм H2 враховує взаємні зв'язки між сусідніми символами (марковський ланцюг 1-го порядку). Вона дозволяє оцінити передбачуваність наступного символу, якщо відомий один попередній, що суттєво знижує оцінку ентропії для структурованих і природних мов.

5. Експериментальна оцінка ентропії джерела

За допомогою програми CoolPinkProgram оцініть значення H10 H20 H50

Лабораторная работа №1

Произвольная часть текста:
ность_добра_и_зла_уже_в_следующий_момент_вы_увидите_как_этот_же_человек_сам

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: р
Символ по счету: 1
Номер эксперимента: 52
Поле ввода символов:
р
Продолжить Другой

Неравенство для энтропии:
 $1.25667189019385 < H < 1.976993840462$
Двоичная таблица угаданных символов:
10000000000000000000000000000000
10000000000000000000000000000000
00100000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000

Вероятности:
q[1] = 0.596153646153646
q[2] = 0.173076923076923
q[3] = 0.0576923076923077
q[4] = 0.0192307692307692
q[5] = 0.0576923076923077
q[6] = 0.0192307692307692
q[7] = 0
q[8] = 0
q[9] = 0.0364615364615365
q[10] = 0
q[11] = 0
q[12] = 0
q[13] = 0
q[14] = 0
q[15] = 0
q[16] = 0
q[17] = 0
q[18] = 0
q[19] = 0
q[20] = 0
q[21] = 0
q[22] = 0
q[23] = 0.0192307692307692
q[24] = 0
q[25] = 0
q[26] = 0.0192307692307692
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0

Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

Лабораторная работа №1

Произвольная часть текста:
 еческой_природы_их_

Использованные буквы:

Порядок n-граммы:

- 5 символов
- 10 символов
- 15 символов
- 20 символов
- 25 символов
- 30 символов
- 35 символов
- 40 символов
- 45 символов
- 50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 53

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:
 $1,30983731947668 < H < 1,983435631311$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
00001000000000000000000000000000
01000000000000000000000000000000
01000000000000000000000000000000
0000000000000000000000000100000000

Вероятности:

q[1] = 0,615394615394615
 q[2] = 0,173076923076923
 q[3] = 0,0576923076923077
 q[4] = 0
 q[5] = 0,0192307692307692
 q[6] = 0
 q[7] = 0,0192307692307692
 q[8] = 0
 q[9] = 0
 q[10] = 0
 q[11] = 0
 q[12] = 0
 q[13] = 0,0192307692307692
 q[14] = 0
 q[15] = 0,0192307692307692
 q[16] = 0
 q[17] = 0
 q[18] = 0
 q[19] = 0
 q[20] = 0,0192307692307692
 q[21] = 0
 q[22] = 0,0192307692307692
 q[23] = 0
 q[24] = 0,0192307692307692
 q[25] = 0
 q[26] = 0,0192307692307692
 q[27] = 0
 q[28] = 0
 q[29] = 0
 q[30] = 0
 q[31] = 0
 q[32] = 0

Строка состояния:

Лабораторная работа №1

Произвольная часть текста:
 нескольких_различных_законов_и_среди_них_имеется_

Использованные буквы:

Порядок n-граммы:

- 5 символов
- 10 символов
- 15 символов
- 20 символов
- 25 символов
- 30 символов
- 35 символов
- 40 символов
- 45 символов
- 50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 52

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:
 $0,946905844296846 < H < 1,46175501761$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
00000100000000000000000000000000
00000000100000000000000000000000
01000000000000000000000000000000
10000000000000000000000000000000

Вероятности:

q[1] = 0,686274509803922
 q[2] = 0,196076431372549
 q[3] = 0,0196076431372549
 q[4] = 0
 q[5] = 0
 q[6] = 0,0196076431372549
 q[7] = 0
 q[8] = 0
 q[9] = 0,0196076431372549
 q[10] = 0
 q[11] = 0
 q[12] = 0
 q[13] = 0
 q[14] = 0
 q[15] = 0
 q[16] = 0
 q[17] = 0
 q[18] = 0
 q[19] = 0,0196076431372549
 q[20] = 0,039215686274509
 q[21] = 0
 q[22] = 0
 q[23] = 0
 q[24] = 0
 q[25] = 0
 q[26] = 0
 q[27] = 0
 q[28] = 0
 q[29] = 0
 q[30] = 0
 q[31] = 0
 q[32] = 0

Строка состояния:

Порівняйте отримані значення з H_1 та H_2 , обчисленими власною програмою.

Результати подайте в одній порівняльній таблиці:

Оцінка	Отримане значення
H1	4.466633
H2	4.147174
H10	$1.256671 < H < 1.976993$
H20	$1.309837 < H < 1.983435$
H50	$0.946905 < H < 1.461755$

Проаналізуйте отримані результати та поясніть:

1. чому наведені оцінки ентропії не повинні обов'язково збігатися;
2. які статистичні залежності враховуються при визначенні H_1 та H_2 ;
3. чому врахування довгих залежностей між символами може змінювати оцінку ентропії природної мови;
4. яку тенденцію можна спостерігати при переході від H_1 до оцінок, що враховують дедалі довший контекст.

1. Оцінки ентропії не збігаються, бо в кожному експерименті взято різну кількість символів і в випадках з H_{10-50} врадувала останній символ людина (метод шеннона), яка фактично може бути ефективніша в деяких випадках як тут. Також вплинув обсяг досліджених даних.

2. H_1 враховує тільки абсолютні та відносні частоти появи окремих символів і порядок розташування в тексті ніяк не впливає, а H_2 враховує парні залежності між двома сусідніми символами й фіксує ймовірності переходу від одного конкретного символу до наступного, відображаючи базові фонетичні й орфографічні правила мови (наприклад, високу

ймовірність сполучень ст, но або о_ і нульову ймовірність сполучень ьь чи ьь).

3. Природна мова має високу надлишковість та складну ієрархічну структуру (морфологічну, синтаксичну та семантичну). Знаючи перші 4-5 літер слова людина або алгоритм може з високою ймовірністю вгадати закінчення, що зводить невизначеність цих символів практично до нуля. Також по контексту довжиною у декілька слів можна передбачити можливі наступні слова (напр. «ни я ни отец мой ни...» логічно що тут може бути далі «дед мой»).

4. При збільшенні довжини контексту спостерігається поступове падіння ентропії

*H20 на фоні H10 є виключенням як похибка через малу кількість статистичних даних

6. Оцінювання надлишковості джерела

Використовуючи отримані значення ентропії, оцініть надлишковість російського письмового тексту для досліджених моделей джерела.

Оцінка	Отримане значення	Надлишковість
H1	4.466633	10.67%
H2	4.147174	17.06%
H10	$1.256671 < H < 1.976993$	60.46-74.87%
H20	$1.309837 < H < 1.983435$	60.33-73.80%
H50	$0.946905 < H < 1.461755$	70.76-81.06%

Порівняйте отримані оцінки та поясніть:

- як змінюється оцінка надлишковості при врахуванні залежностей між символами;
- чому природна мова має ненульову надлишковість;
- який зв'язок існує між передбачуваністю наступних символів тексту, ентропією та надлишковістю джерела.

Надлишковість збільшувалась зі збільшенням контексту

Ненульова (і висока) надлишковість природної мови є необхідною, завдяки цьому розмову/текст можна частково відновлювати при невеликих шумах чи спотворенні (наприклад якщо дати людині текст, в якому всі літери слів окрім першої та останньої будуть перемішані в словах, то людина зможе без проблем його читати). Також Надлишковість формується за рахунок жорстких правил граматики, синтаксису, морфологічної будови слів та обмеженого набору фразеологізмів.

Між цими трьома характеристиками існує пряма математична та логічна залежність – зі збільшенням передбачуваності збільшується надлишковість і падає ентропія. Тож вони є прямо пропорційними величинами.

Аналіз результатів

1. Порівняння ентропії природного тексту та випадкової послідовності.

Природний текст має нижчу ентропію порівняно з випадковою послідовністю через нерівномірний розподіл частот літер. В експерименті для тексту без пробілів зафіксовано $H_1 = 4.466633$ біт/символ, тоді як для випадкової послідовності В на 32 символи отримано $H_1 = 4.999795$ біт/символ, що практично дорівнює теоретичному максимуму $H = \log_2(32) = 5.0$ біт/символ. У послідовності В усі літери рівноймовірні, а в природному тексті є виражені часті символи (напр. «о» = 11.44, «е» = 8.24%) та рідкісні букви («ф» = 0.16% або «ё» яку я виключив через наявність лише 9 у всьому тексті, або 0.00064%). Будь-яке відхилення від рівномірного розподілу зменшує невизначеність джерела.

2. Інформація, яку враховує H_2 на відміну від H_1 . Модель H_1 оцінює джерело без пам'яті (символи генеруються незалежно), а модель H_2 враховує парні статистичні залежності 1-го порядку між сусідніми символами. У дослідженому тексті без пробілів це знизило ентропію з 4.466633 (H_1) до 4.147174 біт/символ (H_2). H_2 фіксує фонетико-орфографічні правила мови — високу частоту типових пар (напр. то — 1.69%, ст — 1.32%) та відсутність неможливих сполучень (ьь, ъь), що зводить умовну невизначеність.

3. Збіг H_1 при суттєвій відмінності H_2 . Тексти з однаковими частотами окремих символів мають однакові H_1 , але їхні значення H_2 відрізняються через різну внутрішню структуру. Це підтверджує експеримент із 4-символьним алфавітом ($H_0 = 2$ біт/символ): випадкова послідовність Г має $H_1 = 1.999940$ та $H_2 = 1.999929$ біт/символ, а періодична послідовність Д (абвгабвг...) при ідентичному $H_1 = 2.000000$ дає $H_2 = 1.000000$ біт/символ (з перетином) та 0.500000 біт/символ (без перетину).

4. Вплив вилучення пробілів на значення ентропії. Видалення пробілу підвищило значення ентропії: для тексту з пробілами ($m=33$) отримано $H_1 = 4.377652$ та $H_2 = 3.967380$ біт/символ, а без пробілів ($m=32$) — $H_1 = 4.466633$ та $H_2 = 4.147174$ біт/символ. Пробіл був абсолютним лідером за частотою (16.41%). Наявність одного дуже частого символу знижувала

загальну невизначеність, а його вилучення зробило розподіл ймовірностей решти 32 літер більш рівномірним.

5. Відмінність між H_2 з перетином та без перетину. Для тексту без пробілів H_2 з перетином дорівнює 4.147174, а без перетину — 4.147440 біт/символ (різниця 0.000266 або $<0.01\%$). Спосіб з перетином аналізує $N-1$ біграм і використовує вдвічі більше даних. Спосіб без перетину формує лише $N/2$ біграм і пропускає непарні переходи, через що виникає незначна статистична похибка, яка на вибірці $N > 1.48$ млн символів є досить мізерною.

6. Динаміка змін H_1 , H_2 , H_{10} , H_{20} , H_{50} . Оцінки ентропії монотонно меншають із розширенням контексту: $H_1 (4.467) > H_2 (4.147) > H_{10} (1.26 - 1.98) > H_{20} (1.31 - 1.98) > H_{50} (0.95 - 1.46)$ біт/символ. H_1 та H_2 враховують лише локальні зв'язки, тоді як ручне вгадування у CoolPinkProgram залучає людські знання граматики, синтаксису та семантики, що дозволяє угадувати символи з перших спроб (окрім випадків коли останнім йде пробіл☺) і різко знижує невизначеність.

7. Експеримент, що найкраще демонструє залежності між символами. Залежності найкраще ілюструють порівняння послідовностей Г і Д, а також угадування в CoolPinkProgram. Наявність періодичної структури в Д знизилася H_2 у 2–4 рази при однакових $H_1 = 2.0$ біт/символ. Вгадування за Шенноном продемонструвало падіння ентропії з 4.47 біт/символ до $[0.95, 1.46]$ біт/символ при $N=50$, доводячи суворе обмеження кожного наступного символу контекстом.

8. Зв'язок із можливістю стиснення тексту без втрат. Згідно з теоремою Шеннона, реальна ентропія джерела визначає межу стиснення без втрат. Зазвичай символ кодується 8 бітами (або 5 бітами при $H_0 = \log_2(32)$), однак реальна ентропія тексту з урахуванням довгих контекстів становить лише $H^{(50)} 0.95 - 1.46$ біт/символ. Це формує високу відносну надлишковість $R 70\% - 81\%$, що дозволяє алгоритмам безповоротно ущільнювати текстові файли у 3–4 рази без втрати інформації.

