

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ»
ФІЗИКО-ТЕХНІЧНИЙ ІНСТИТУТ

КРИПТОГРАФІЯ

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

Експериментальна оцінка ентропії на символ джерела


відкритого текст

Виконали
Студенти групи ФБ-42:
Малишко Дарія
Сизова Марія

Мета роботи: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Хід роботи:

Для аналізу тексту обираємо твір Булгакова “Майстер і Маргарита”



Для початку використаємо скрипт для нормалізації тексту

```
text_prep.py X text_nospaces.txt X entropy_calc.py X
FB-42_Syzova_Malyshko > text_prep.py > ...
1 import re
2 import os
3
4 def preprocess_text(input_file, output_spaces, output_nospaces):
5     print(f"Починаємо обробку файлу: {input_file}")
6
7     try:
8         with open(input_file, 'r', encoding='utf-8') as f:
9             text = f.read().lower()
10    except UnicodeDecodeError:
11        with open(input_file, 'r', encoding='cp1251') as f:
12            text = f.read().lower()
13
14    text = re.sub(r'^[а-яё\s]', ' ', text)
15    text_with_spaces = re.sub(r'\s+', ' ', text).strip()
16    text_no_spaces = text_with_spaces.replace(' ', '')
17
18    with open(output_spaces, 'w', encoding='utf-8') as f1:
19        f1.write(text_with_spaces)
20
21    with open(output_nospaces, 'w', encoding='utf-8') as f2:
22        f2.write(text_no_spaces)
23
24    print("Обробку завершено успішно!")
25    print(f"Довжина тексту з пробілами: {len(text_with_spaces)} символів")
26    print(f"Довжина тексту без пробілів: {len(text_no_spaces)} символів")
27
28 if __name__ == "__main__":
29     preprocess_text('raw_text.txt', 'text_spaces.txt', 'text_nospaces.txt')
```

Результат

```
PS C:\Users\Admin\Desktop\crypto26-27\Lab1> cd FB-42_Syzova_Malyshko
PS C:\Users\Admin\Desktop\crypto26-27\Lab1\FB-42_Syzova_Malyshko> python text_prep.py
Починаємо обробку файлу: raw_text.txt
Обробку завершено успішно!
Довжина тексту з пробілами: 712040 символів
Довжина тексту без пробілів: 598083 символів
```

Отже, увесь текст переведено до нижнього регістру, всі символи, що не належать до російського алфавіту (а-я, ё), вилучено та замінено на пробіли для уникнення злиття сусідніх слів (регулярний вираз `^[а-яё\s]`), будь-які послідовності пробілів, табуляцій або переносів рядків зведено до одного пробілу (`\s+`), зайві пробіли на початку та в кінці файлу видалено (`.strip()`)

Завдання 2: Розрахунок статистичних характеристик тексту.

```

text_prep.py X text_nospaces.txt X entropy_calc.py X
FB-42_Syzova_Malyshko > entropy_calc.py > analyze_text
1 import math
2 from collections import Counter
3 import os
4
5 def calculate_entropy(frequencies, total_count, n_gram_length=1):
6     """Обчислює ентропію на символ за заданими частотами."""
7     entropy = 0
8     for count in frequencies.values():
9         probability = count / total_count
10        entropy -= probability * math.log2(probability)
11
12    return entropy / n_gram_length
13
14 def analyze_text(filename, n_gram_type='unigram', step=1):
15     """Аналізує текст і повертає частоти та ентропію."""
16     with open(filename, 'r', encoding='utf-8') as f:
17         text = f.read()
18
19     text_length = len(text)
20
21     if n_gram_type == 'unigram':
22         frequencies = Counter(text)
23         total_count = text_length
24         entropy = calculate_entropy(frequencies, total_count, 1)
25
26     elif n_gram_type == 'bigram':
27
28         bigrams = [text[i:i+2] for i in range(0, text_length - 1, step)]
29
30         if step == 2 and len(bigrams[-1]) == 1:
31             bigrams = bigrams[:-1]
32
33         frequencies = Counter(bigrams)
34         total_count = len(bigrams)
35         entropy = calculate_entropy(frequencies, total_count, 2)
36
37     top_5 = dict(frequencies.most_common(5))
38     return top_5, entropy
39
40 if __name__ == "__main__":
41     script_dir = os.path.dirname(os.path.abspath(__file__))
42     file_spaces = os.path.join(script_dir, 'text_spaces.txt')
43     file_nospaces = os.path.join(script_dir, 'text_nospaces.txt')
44
45     print("ТЕКСТ В ПРОБІЛАХ ")
46     top_sym_sp, h1_sp = analyze_text(file_spaces, 'unigram')
47     print(f"H1: {h1_sp:.5f}")
48     print(f"Топ-5 символів: {top_sym_sp}")
49
50     top_bi_sp_cross, h2_sp_cross = analyze_text(file_spaces, 'bigram', step=1)
51     print(f"H2 (перетинаються): {h2_sp_cross:.5f}")
52     print(f"Топ-5 біграм: {top_bi_sp_cross}")
53
54     top_bi_sp_nocross, h2_sp_nocross = analyze_text(file_spaces, 'bigram', step=2)
55     print(f"H2 (не перетинаються): {h2_sp_nocross:.5f}")

```

```

53
54 top_bi_sp_nocross, h2_sp_nocross = analyze_text(file_spaces, 'bigram', step=2)
55 print(f"H2 (не перетинаються): {h2_sp_nocross:.5f}")
56 print(f"Топ-5 біграм: {top_bi_sp_nocross}\n")
57
58 print("ТЕКСТ БЕЗ ПРОБІЛІВ")
59 top_sym_nosp, h1_nosp = analyze_text(file_nospaces, 'unigram')
60 print(f"H1: {h1_nosp:.5f}")
61 print(f"Топ-5 символів: {top_sym_nosp}")
62
63 top_bi_nosp_cross, h2_nosp_cross = analyze_text(file_nospaces, 'bigram', step=1)
64 print(f"H2 (перетинаються): {h2_nosp_cross:.5f}")
65 print(f"Топ-5 біграм: {top_bi_nosp_cross}")
66
67 top_bi_nosp_nocross, h2_nosp_nocross = analyze_text(file_nospaces, 'bigram', step=2)
68 print(f"H2 (не перетинаються): {h2_nosp_nocross:.5f}")
69 print(f"Топ-5 біграм: {top_bi_nosp_nocross}")

```

Результат

```

PS C:\Users\Admin\Desktop\crypto26-2\Lab1\FB-42-Syzova_Malyshko> python text_prep.py
ТЕКСТ З ПРОБІЛАМИ
H1: 4.37481
Топ-5 символів: {' ': 113957, 'о': 66176, 'а': 51664, 'е': 48624, 'и': 40933}
H2 (перетинаються): 3.98333
Топ-5 біграм: {'о ': 15225, 'а ': 12820, ' п': 12089, ' в': 11618, 'и ': 11555}
H2 (не перетинаються): 3.98314
Топ-5 біграм: {'о ': 7600, 'а ': 6357, ' п': 6094, ' в': 5800, 'и ': 5730}

ТЕКСТ БЕЗ ПРОБІЛІВ
H1: 4.45308
Топ-5 символів: {'о': 66176, 'а': 51664, 'е': 48624, 'и': 40933, 'н': 38352}
H2 (перетинаються): 4.14780
Топ-5 біграм: {'то': 9704, 'но': 7071, 'ст': 6688, 'на': 6560, 'по': 6522}
H2 (не перетинаються): 4.14687
Топ-5 біграм: {'то': 4910, 'но': 3478, 'ст': 3338, 'по': 3316, 'на': 3306}

```

Таблиця 1. Значення ентропії H1 та H2

1	Стан тексту	H1 (окремі сим	H2 (перетинні б	H2 (неперетинні біграми, крок 2)		
2	З пробілами	4.37481	3.98333	3.98314		
3	Без пробілів	4.45308	4.14780	4.14687		
4						

Таблиця 2. Топ-5 найчастіших символів

	A	B	C	D	E
1	Ранг	Символ (з проб	Частота	Символ (без пр	Частота
2	1	[пробіл]	113 957	о	66 176
3	2	о	66 176	а	51 664
4	3	а	51 664	е	48 624
5	4	е	48 624	и	40 933
6	5	и	40 933	н	38 352
7					
8					

Таблиця 3. Топ-5 біграм для тексту з пробілами

A	B	C	D	E
Ранг	Перетинаються	Частота	Не перетинаються	Частота
1	о_	15 225	о_	7 600
2	а_	12 820	а_	6 357
3	_п	12 089	_п	6 094
4	_в	11 618	_в	5 800
5	и_	11 555	и_	5 730

Таблиця 4. Топ-5 біграм для тексту без пробілів

A	B	C	D	E
Ранг	Перетинаються	Частота	Не перетинаються	Частота
1	то	9 704	то	4 910
2	но	7 071	но	3 478
3	ст	6 688	ст	3 338
4	на	6 560	по	3 316
5	по	6 522	на	3 306

Завдання 3: Дослідження впливу розподілу символів на ентропію

Прогноз перед експериментом:

Очікуваний порядок зростання ентропії H_1 : **Б** < **А** < **В**.

Обґрунтування:

1. Послідовність **Б** (один символ) матиме ентропію 0, оскільки ймовірність появи цього символу дорівнює 1 (повна відсутність невизначеності).
2. Послідовність **А** (природний текст) матиме проміжне значення, оскільки символи розподілені нерівномірно (одні зустрічаються часто, інші рідко).
3. Послідовність **В** (випадкова) матиме максимальну ентропію (близько $\log_2(34) \approx 5.08$), оскільки всі символи алфавіту мають однакову ймовірність появи, що створює максимальну невизначеність.

Тепер перевіримо на практиці:

```
text_prep.py X entropy_calc.py X task3.py X text_spaces.txt X
FB-42_Syzova_Malyshko > task3.py > ...
6 def calc_h1(text):
7     frequencies = Counter(text)
8     entropy = 0
9     total = len(text)
10    for count in frequencies.values():
11        p = count / total
12        entropy -= p * math.log2(p)
13    return entropy
14
15 if __name__ == "__main__":
16     script_dir = os.path.dirname(os.path.abspath(__file__))
17     file_spaces = os.path.join(script_dir, 'text_spaces.txt')
18
19     with open(file_spaces, 'r', encoding='utf-8') as f:
20         seq_A = f.read()[:10000]
21
22     seq_B = 'A' * 10000
23
24     alphabet = 'абвгдеёжзийклмнопрстуфхцчшщъыьэя '
25     seq_C = ''.join(random.choices(alphabet, k=10000))
26
27     print(f"H1 (Б - один символ): {calc_h1(seq_B):.5f}")
28     print(f"H1 (А - природний текст): {calc_h1(seq_A):.5f}")
29     print(f"H1 (В - випадкова): {calc_h1(seq_C):.5f}")

```

Problems Output Debug Console Terminal Ports

```
PS C:\Users\Admin\Desktop\crypto26-27\Lab1\FB-42_Syzova_Malyshko> python -u "
42_Syzova_Malyshko\task3.py"
H1 (Б - один символ): 0.00000
H1 (А - природний текст): 4.37159
H1 (В - випадкова): 5.08547
PS C:\Users\Admin\Desktop\crypto26-27\Lab1\FB-42_Syzova_Malyshko>

```

Послідовність Б (один символ): 0.00000

Послідовність А (природний текст): 4.37159

Послідовність В (випадкова рівномірна): 5.08547

Прогноз $H_1(B) < H_1(A) < H_1(V)$ повністю підтвердився. Послідовність із повторенням одного символу дає ентропію 0, оскільки ми маємо вироджений розподіл імовірностей появи символу дорівнює 1, а невизначеність повністю відсутня. Випадкова послідовність дає максимальну ентропію (5.08, що майже дорівнює $\log_2(34) \approx 5.087$), оскільки всі символи з'являються з однаковою ймовірністю, що унеможливорює передбачення наступного символу. Природна мова має проміжне значення, оскільки літери в ній розподілені нерівномірно (одні зустрічаються часто, інші рідко). Отже, чим ближчий розподіл ймовірностей до рівномірного, тим вищою є ентропія джерела.

Завдання 4: Дослідження залежностей між символами

Прогноз:

1. Чи повинні суттєво відрізнятися значення H_1 для Г і Д?
Ні, вони будуть ідентичними або максимально близькими. Модель H_1 ігнорує порядок символів і залежить виключно від їхніх частот, які за умовою є однаковими.
2. Чи повинні суттєво відрізнятися значення H_2 ?
Так, значення суттєво відрізнятимуться. У випадковій послідовності (Г) можливі різні варіанти біграм, тоді як у жорстко періодичній (Д, наприклад абабаб) набір біграм буде мінімальним і строго детермінованим.
3. Для якої послідовності очікується менше значення H_2 ?
Для періодичної послідовності (Д). Завдяки жорсткій закономірності наступний символ легко передбачити, що мінімізує невизначеність.
4. Чи відрізнятиметься H_2 для біграм, що перетинаються та не перетинаються?
Для періодичної послідовності типу абабаб неперетинні біграми (з кроком 2) розіб'ють текст на однакові блоки (аб, аб), що дасть $H_2 = 0$. Перетинні біграми зафіксують переходи аб та ба, даючи $H_2 = 1$. Для випадкової послідовності різниця буде менш радикальною, але перетинний метод завжди враховує більше статистики.

Тепер перейдемо до експерименту:

```
text_prep.py X entropy_calc.py X task3.py X task4.py X text_spaces.txt X
FB-42_Syzova_Malyshko > task4.py > ...
1  import math
2  import random
3  from collections import Counter
4
5  def calc_entropy(frequencies, total_count, n_gram_length):
6      entropy = 0
7      for count in frequencies.values():
8          p = count / total_count
9          entropy -= p * math.log2(p)
10     return entropy / n_gram_length
11
12 def analyze_seq(text):
13     h1 = calc_entropy(Counter(text), len(text), 1)
14     bigrams_cross = [text[i:i+2] for i in range(0, len(text)-1, 1)]
15     h2_cross = calc_entropy(Counter(bigrams_cross), len(bigrams_cross), 2)
16     bigrams_nocross = [text[i:i+2] for i in range(0, len(text)-1, 2)]
17
18     if len(bigrams_nocross[-1]) == 1:
19         bigrams_nocross = bigrams_nocross[:-1]
20     h2_nocross = calc_entropy(Counter(bigrams_nocross), len(bigrams_nocross), 2)
21
22     return h1, h2_cross, h2_nocross
23
24 if __name__ == "__main__":
25     length = 10000
26     seq_D = ('aD' * (length // 2))
27     seq_G_list = list(seq_D)
28     random.shuffle(seq_G_list)
29     seq_G = ''.join(seq_G_list)
30
31     h1_D, h2_c_D, h2_n_D = analyze_seq(seq_D)
32     h1_G, h2_c_G, h2_n_G = analyze_seq(seq_G)
33
34     print("Послідовність Д (періодична)")
35     print(f"H1: {h1_D:.5f}")
36     print(f"H2 (перетинаються): {h2_c_D:.5f}")
37     print(f"H2 (не перетинаються): {h2_n_D:.5f}\n")
38
39     print("Послідовність Г (випадкова)")
40     print(f"H1: {h1_G:.5f}")
41     print(f"H2 (перетинаються): {h2_c_G:.5f}")
42     print(f"H2 (не перетинаються): {h2_n_G:.5f}")

PS C:\Users\Admin\Desktop\crypto26-27\Lab1\FB-42_Syzova_Malyshko> python -u "c:\Users\Admin\Desktop\crypto26-27\Lab1\FB-42_Syzova_Malyshko\task4.py"
Послідовність Д (періодична)
H1: 1.00000
H2 (перетинаються): 0.50000
H2 (не перетинаються): 0.00000

Послідовність Г (випадкова)
H1: 1.00000
H2 (перетинаються): 0.99993
H2 (не перетинаються): 0.99975
PS C:\Users\Admin\Desktop\crypto26-27\Lab1\FB-42_Syzova_Malyshko> 
```

Послідовність Д (періодична): $H_1 = 1.00000$, H_2 (перетинаються) = 0.50000, H_2 (не перетинаються) = 0.00000.

Послідовність Г (випадкова): $H_1 = 1.00000$, H_2 (перетинаються) = 0.99993, H_2 (не перетинаються) = 0.99975

Завдання 5: Експериментальна оцінка ентропії методом передбачення (експеримент Шеннона)

Метод Шеннона базується на здатності людини (як носія мови та її внутрішніх статистичних закономірностей) вгадувати невідомий наступний символ відкритого тексту за відомою передісторією довжиною n символів (n -грамою). Програма підраховує кількість спроб, необхідних для вгадування, будує емпіричний розподіл ймовірностей q_i (ймовірність вгадати символ з i -ї спроби) та обчислює межі ентропії джерела H_n за формулами Шеннона:

$$F_n^L = \sum_{i=1}^m i \cdot (q_i - q_{i+1}) \cdot \log_2 i \leq H_n \leq - \sum_{i=1}^m q_i \log_2 q_i = F_n^U$$

Для розрахунку надлишковості мови R використовується співвідношення:

$$R = 1 - \frac{H_n}{H_0}, \text{ де } H_0 = \log_2(34) \approx 5.087 \text{ біт/символ}$$

1. Порядок $n = 10$ символів

Підсумкова зафіксована нерівність на 50-му кроці експерименту:

$$1,9369210422391 < H_{10} < 2,7879199399452$$

Середнє значення ентропії:

$$H_{10} = \frac{1,9369+2,7879}{2} \approx 2,3624 \text{ біт/символ}$$

Надлишковість:

$$R_{10} = 1 - 2,3624/5,0875 \approx 0,5356 \text{ (53,56\%)}$$

[illegible]

3. Порядок $n = 30$ символів

Підсумкова зафіксована нерівність на 50-му кроці експерименту:

$$3,98494434831114 < H_{30} < 3,73605761275515$$

Середнє значення ентропії:

$$H_{30} = \frac{3,9849 + 3,7361}{2} \approx 3,8605 \text{ біт/символ}$$

Надлишковість:

$$R_{30} = 1 - (3,8605/5,0875) \approx 0,2412 \text{ (24,12\%)}$$

$n = 30$ СИМВОЛІВ	3,9849	3,7361	3,8605	24,12%
-----------------------------	--------	--------	--------	--------

В інтерфейсі програми для порядків $n = 20$ та $n = 30$ спостерігається формальна інверсія меж (значення зліва виявилось більшим за значення справа). Це обумовлено тим, що обчислення базуються на емпіричній оцінці Шеннона для скінченної вибірки (50 експериментів). При високій дисперсії номерів спроб вгадування дискретний розрахунок теоретичної нижньої суми може перевищувати верхню сукупну ентропію розподілу q_i , тому найбільш репрезентативним орієнтиром виступає середнє арифметичне значення H_{avg} . Отримані результати підтверджують значну надлишковість природного мовного тексту ($R > 10\text{--}50\%$), зумовлену сталими граматичними, синтаксичними і лексичними зв'язками між послідовностями літер.

Порівняння результатів з прогнозом

- Чому значення H_1 збігаються?** Як і прогнозувалося, H_1 для обох послідовностей дорівнює рівно 1.0. Це відбувається тому, що модель H_1 (модель незалежних символів) враховує виключно частоту появи кожного символу (в обох випадках рівно 50% «а» та 50% «б») і повністю ігнорує їхній порядок.
- Чому значення H_2 суттєво відрізняються?** Модель біграм (H_2) враховує залежності між сусідніми символами (ймовірності переходів). У випадковій послідовності біграми («аа», «аб», «ба», «бб») розподілені майже рівномірно, що зберігає високу невизначеність ($H_2 \approx 1.0$). У періодичній послідовності («абабаб...») жорстка структура радикально обмежує кількість можливих комбінацій.
- Різниця між перетинними та неперетинними біграмами у періодичній структурі:** Для послідовності Д неперетинні біграми (крок 2) розбивають текст на ідентичні блоки («аб», «аб», «аб»). Оскільки ймовірність появи блоку «аб» становить 100%, невизначеність повністю зникає, і $H_2 = 0$. Перетинні біграми

фіксують переходи («аб» та «ба» з частотою по 50%), що дає $H_2 = 0.5$.

4. **Висновок щодо моделей джерела:** Модель H_2 дозволяє виявити внутрішню структуру, шаблони та періодичність джерела, тоді як H_1 сліпа до будь-яких закономірностей порядку. Це доводить, що врахування ширшого контексту (ланцюгів Маркова) дає набагато точнішу оцінку реальної ентропії тексту.

Висновки

1. **Нормалізація та попередня обробка тексту (Завдання 1):**
Здійснено стандартизацію літературного корпусу (роману М. Булгакова «Майстер і Маргарита»): зведення до єдиного регістру, вилучення неалфавітних знаків із коректною заміною на одинарні пробіли (регулярний вираз `[^a-яё\s]`) та видалення крайових інтервалів. Це дало змогу сформувати замкнений алфавіт потужністю $m = 34$ символи (33 літери російської абетки + пробіл) без штучного злиття сусідніх слів для коректного обчислення частот.
2. **Статистичні характеристики та первинні моделі (Завдання 2):**
Отримані значення ентропії H_1 та H_2 для відкритого тексту підтвердили нерівномірність природного мовного розподілу. Наявність найчастіших літер та типових біграм (особливо за участю пробілу) суттєво знижує ентропію порівняно з теоретичним максимумом $H_0 = \log_2(34) \approx 5,0875$ біт/символ, створюючи передумови для частотного аналізу моноалфавітних шифрів.
3. **Вплив закону розподілу на невизначеність (Завдання 3):**
Повністю підтверджено теоретичний прогноз щодо монотонного зростання ентропії $H_1(B) < H_1(A) < H_1(V)$:
 - **Послідовність Б** (один символ): $H_1 = 0,00000$ (вироджений розподіл, подія абсолютно достовірна, невизначеність відсутня).
 - **Послідовність А** (природний текст): $H_1 = 4,37159$ біт/символ (проміжний стан через суттєву дисперсію частот літер).

- **Послідовність В** (рівноймовірна випадкова): $H_1 = 5,08547$ біт/символ (максимальна невизначеність, майже ідеально наближена до теоретичної границі $\log_2(34)$).

Висновок: Ентропія джерела є прямою мірою хаотичності: що ближчий розподіл імовірностей до рівномірного, то вищою є ентропія на символ.

4. Залежності між символами та обмеженість моделі H_1 (Завдання 4):

- Модель незалежних символів H_1 виявилася ідентичною для періодичної (Д) та випадкової (Г) послідовностей ($H_1 = 1,00000$), оскільки вона враховує лише глобальні частоти літер ($p = 0,5$) і цілком ігнорує структуру та порядок їх слідування.
- Модель біграм H_2 враховує умовні зв'язки та дозволяє виявити детермінованість структури: для періодичної послідовності неперетинні біграми знижують ентропію до $H_2 = 0,00000$ (оскільки крок 2 розбиває текст на єдиний блок **аб**), а перетинні — до $H_2 = 0,50000$. Для випадкового тексту ентропія залишається близькою до одиниці ($H_2 \approx 0,999$).

Висновок: Моделювання вищих порядків (ланцюги Маркова) є критично необхідним для адекватної оцінки ентропії структурованих джерел.

5. Оцінка ентропії методом передбачення Шеннона (Завдання 5):

- Експериментально підтверджено гіпотезу Шеннона: людина, спіраючись на контекст довжиною n символів, звужує простір можливих варіантів наступного символу завдяки семантичним та граматичним правилам мови.
- Для перевірених порядків ($n = 10, n = 20, n = 30$) середня оцінка ентропії H_{avg} становить від 2,36 до 4,53 біт/символ, демонструючи стійку мовну надлишковість від 10,99% до 53,56%.

- Виявлена формальна інверсія числових меж для порядків $n = 20$ та $n = 30$ у лабораторній програмі зумовлена статистичною похибкою дискретного емпіричного оцінювання на скінченній вибірці (50 спроб).
- Висока природна надлишковість ($R > 50\%$) є фундаментальною властивістю природних мов, що забезпечує відновлюваність повідомлень при спотвореннях у каналах зв'язку, але водночас є базовою вразливістю, яка уможливорює розкриття класичних криптосистем.