Лабораторна робота 1

З Криптографії

Виконав студент: ФБ-43 Литвиненко Артем

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

1. **Підготовка тексту**

Оберіть довільний текст російською мовою обсягом не менше 1 МБ.

Виконайте попередню обробку тексту відповідно до таких правил:

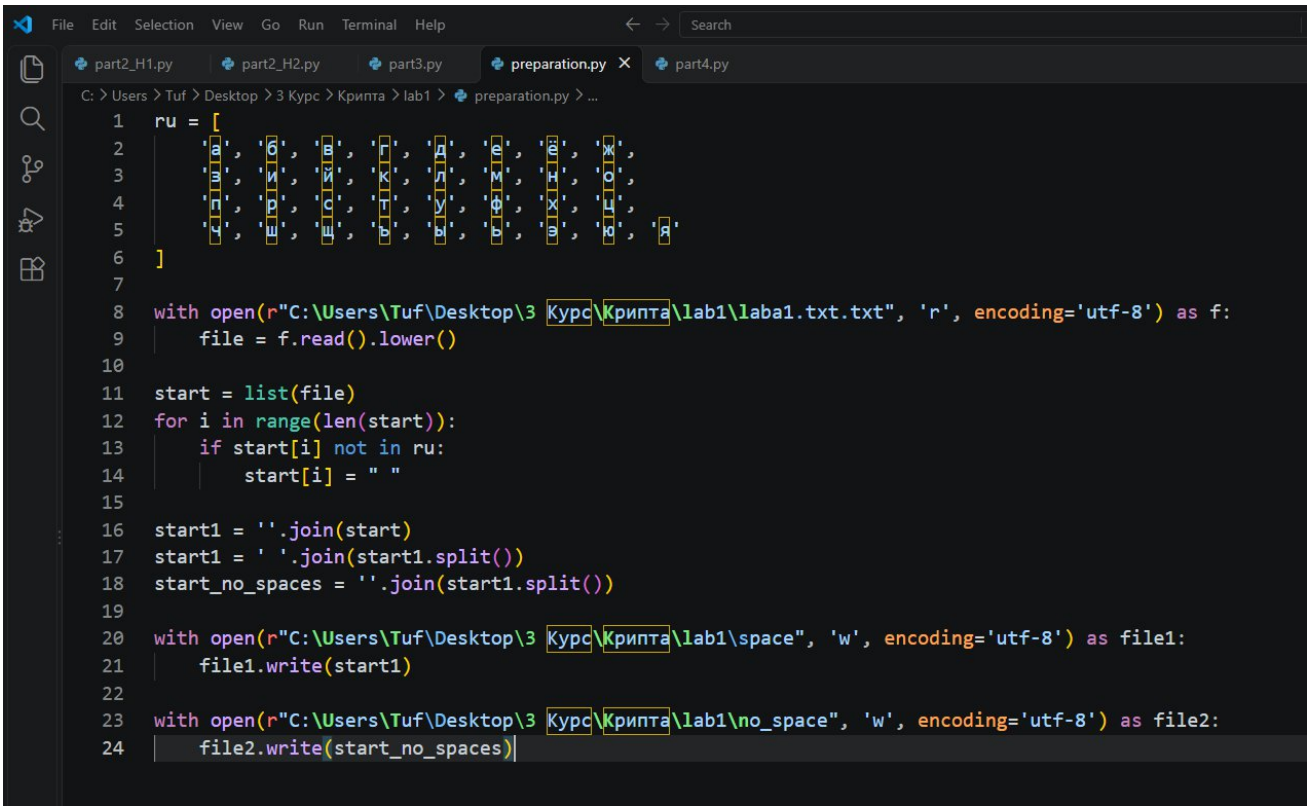
● усі літери привести до нижнього регістру;

● символи, що не належать до заданого алфавіту, вилучити або замінити пробілами;

● послідовності пробілів та інших розділових символів трактувати як один пробіл;

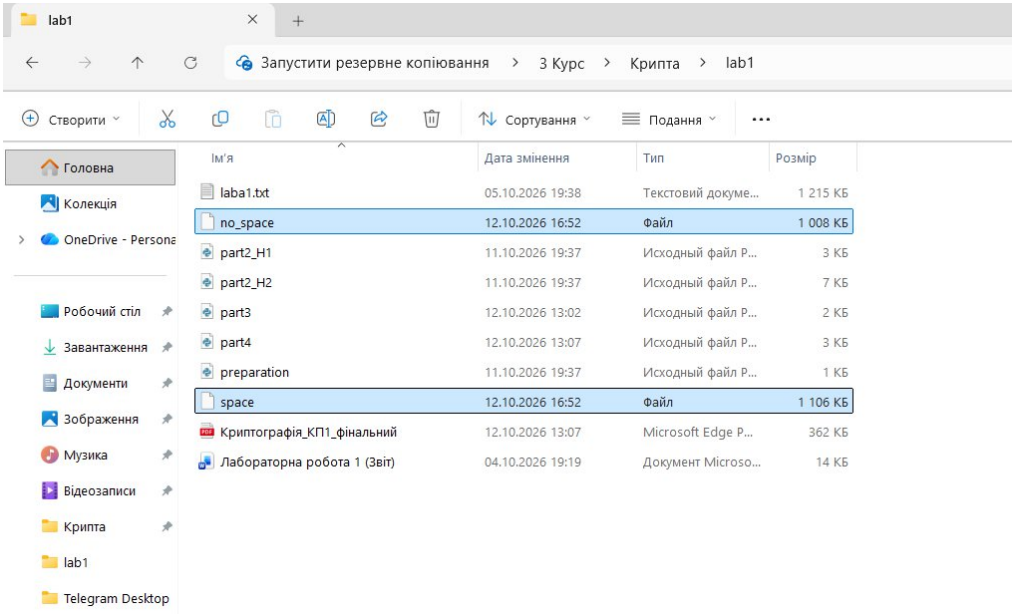
● для обчислень без пробілів вилучити всі пробіли з попередньо нормалізованого тексту. Зафіксуйте правила попередньої обробки, використані у вашій програмі.

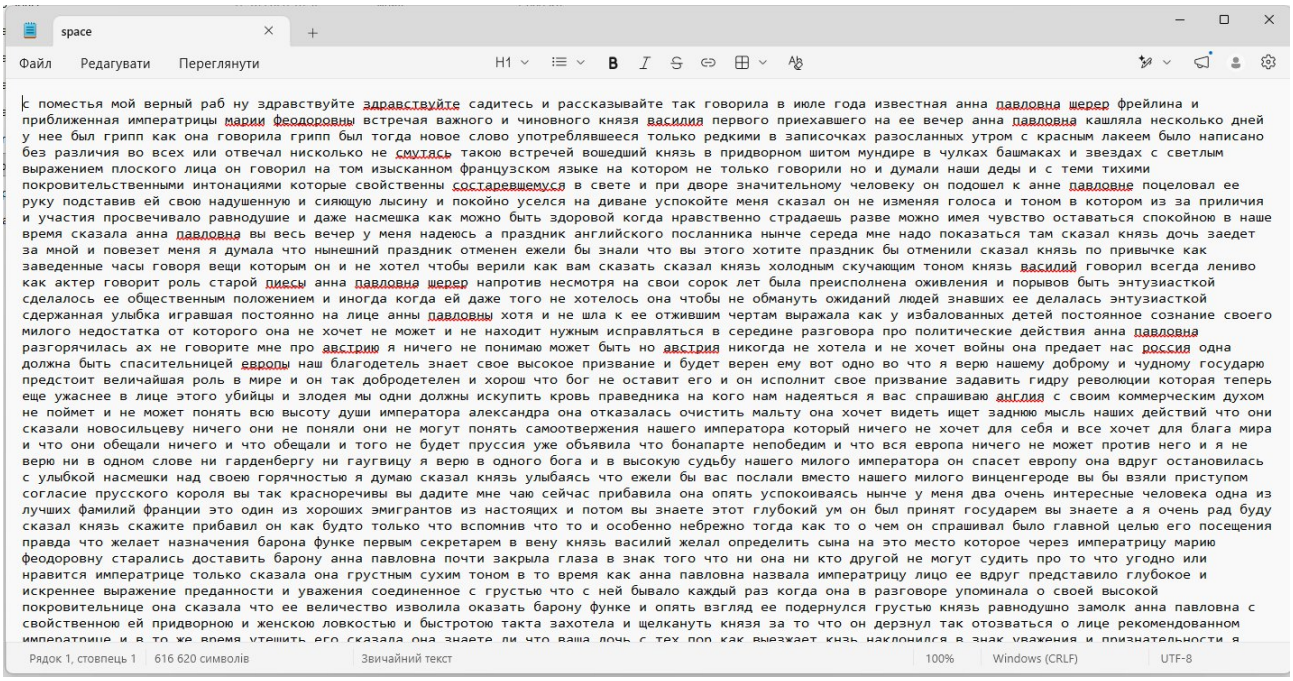
код

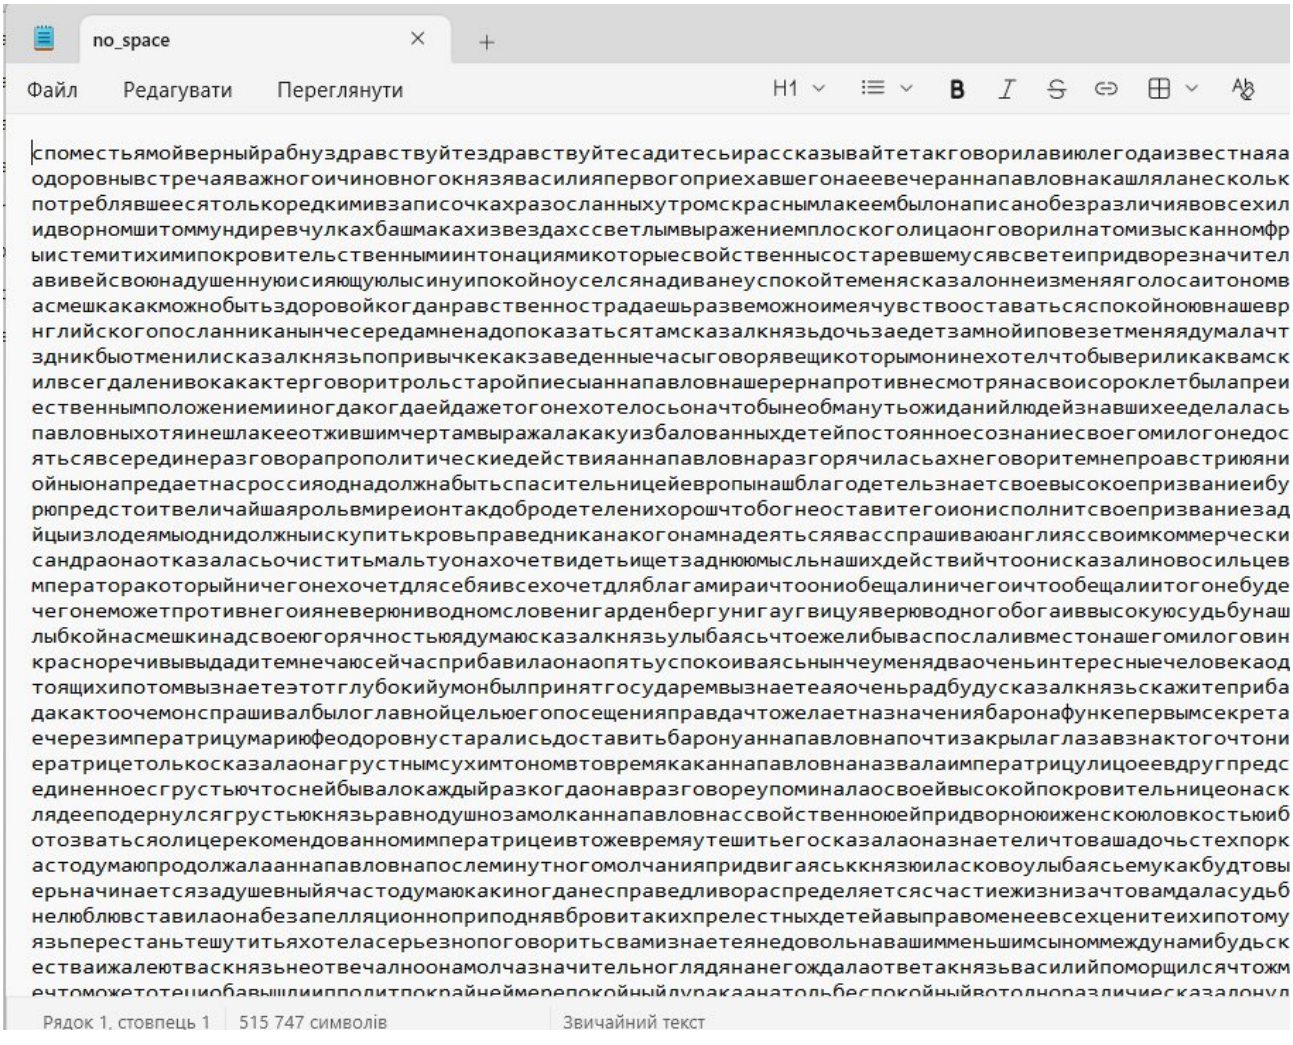


Даний код містить в собі масив з російських літер. Спочатку при запуску код відкриває в заданій по шляху папці файл з необробленим текстом, читає його і переписує у нові змінні уже готовий текст з файлу і записує у 2 файли результат.

При запуску створюється 2 файли де міститься текст з пробілами не більше 1, та текст без пробілів.




space
Файл
Редагувати
Переглянути
H1
с поместья мой верный раб ну здравствуйте здравствуйте садитесь и рассказывайте так говорила в июле года известная анна павловна шерер фрейлина и приближенная императрицы марии феодоровны встречая важного и чиновного князя василия первого приехавшего на ее вечер анна павловна кашляла несколько дней у нее был грипп как она говорила грипп был тогда новое слово употреблявшееся только редкими в записочках разосланных утром с красным лакеем было написано без различия во всех или отвечал нисколько не смутясь такою встречей вошедший князь в придворном шитом мундире в чулках башмаках и звездах с светлым выражением плоского лица он говорил на том изысканном французском языке на котором не только говорили но и думали наши деды и с теми тихими покровительственными интонациями которые свойственны состаревшемуся в свете и при дворе значительному человеку он подошел к анне павловне поцеловал ее руку подставив ей свою надушенную и сияющую лысину и покойно уселся на диване успокойте меня сказал он не изменяя голоса и тоном в котором из за приличия и участия просвечивало равнодушие и даже насмешка как можно быть здоровой когда нравственно страдаешь разве можно имея чувство оставаться спокойною в наше время сказала анна павловна вы весь вечер у меня надеюсь а праздник английского посланника нынче середа мне надо показаться там сказал князь дочь заедет за мной и повезет меня я думала что нынешний праздник отменен ежели бы знали что вы этого хотите праздник бы отменили сказал князь по привычке как заведенные часы говоря вещи которым он и не хотел чтобы верили как вам сказать сказал князь холодным скучающим тоном князь василий говорил всегда лениво как актер говорит роль старой пиесы анна павловна шерер напротив несмотря на свои сорок лет была преисполнена оживления и порывов быть энтузиасткой сделалось ее общественным положением и иногда когда ей даже того не хотелось она чтобы не обмануть ожиданий людей знавших ее делалась энтузиасткой сдержанная улыбка игравшая постоянно на лице анны павловны хотя и не шла к ее отжившим чертам выражала как у избалованных детей постоянное сознание своего милого недостатка от которого она не хочет не может и не находит нужным исправляться в середине разговора про политические действия анна павловна разгорячилась ах не говорите мне про австрию я ничего не понимаю может быть но австрия никогда не хотела и не хочет войны она предает нас россия одна должна быть спасительницей европы наш благодетель знает свое высокое призвание и будет верен ему вот одно во что я верю нашему доброму и чудному государю предстоит величайшая роль в мире и он так добродетелен и хорош что бог не оставит его и он исполнит свое призвание задавить гидру революции которая теперь еще ужаснее в лице этого убийцы и злодея мы одни должны искупить кровь праведника на кого нам надеяться я вас спрашиваю англия с своим коммерческим духом не поймет и не может понять всю высоту души императора александра она отказалась очистить мальту она хочет видеть ищет заднюю мысль наших действий что они сказали новосильцеву ничего они не поняли они не могут понять самоотвержения нашего императора который ничего не хочет для себя и все хочет для блага мира и что они обещали ничего и что обещали и того не будет пруссия уже объявила что бонапарте непобедим и что вся европа ничего не может против него и я не верю ни в одном слове ни гарденбергу ни гаугвицу я верю в одного бога и в высокую судьбу нашего милого императора он спасет европу она вдруг остановилась с улыбкой насмешки над своею горячностью я думаю сказал князь улыбаясь что ежели бы вас послали вместо нашего милого винценгероде вы бы взяли приступом согласие прусского короля вы так красноречивы вы дадите мне чаю сейчас прибавила она опять успокоиваясь нынче у меня два очень интересные человека одна из лучших фамилий франции это один из хороших эмигрантов из настоящих и потом вы знаете этот глубокий ум он был принят государем вы знаете а я очень рад буду сказал князь скажите прибавил он как будто только что вспомнив что то и особенно небрежно тогда как то о чем он спрашивал было главной целью его посещения правда что желает назначения барона функе первым секретарем в вену князь василий желал определить сына на это место которое через императрицу марию феодоровну старались доставить барону анна павловна почти закрыла глаза в знак того что ни она ни кто другой не могут судить про то что угодно или нравится императрице только сказала она грустным сухим тоном в то время как анна павловна назвала императрицу лицо ее вдруг представило глубокое и искреннее выражение преданности и уважения соединенное с грустью что с ней бывало каждый раз когда она в разговоре упоминала о своей высокой покровительнице она сказала что ее величество изволила оказать барону функе и опять взгляд ее подернулся грустью князь равнодушно замолк анна павловна с свойственною ей придворною и женскою ловкостью и быстротою такта захотела и щелкануть князя за то что он дерзнул так отозваться о лице рекомендованном императрице и в то же время утешить его сказала она знаете ли что ваша дочь с тех пор как выезжает князь наклонился в знак уважения и признательности я
Рядок 1, стовпець 1
616 620 символів
Звичайний текст
100%
Windows (CRLF)
UTF-8

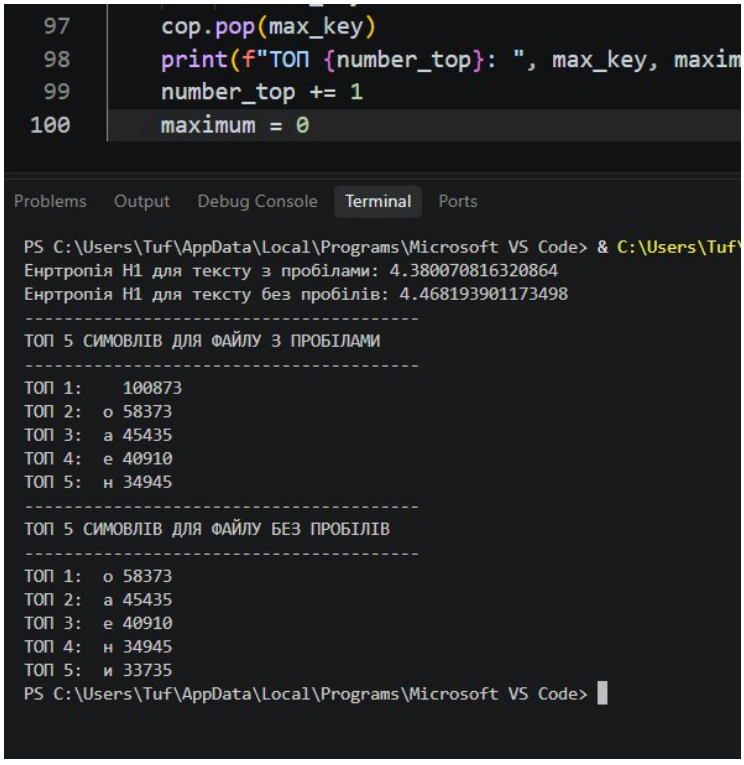

no_space
Файл
Редагувати
Переглянути
H1
споместьямойверныйрабнуздравствуйтездравствуйтесадитесьирассказывайтетакговорилавиюлегодаизвестнаяа
одоровнывстречаяважногоичиновногокнязявасилияпервогоприехавшегонаеевечераннапавловнакашляланесколь
потреблявшеесятолькоредкимивзаписочкахразосланныхутромскраснымлакеембылонаписанобезразличияввовсехил
идворномшитоммундиревчулкахбашмакахизвездахссветлымвыражениемплоскоголицаонговорилнатомизысканномфр
ыистемитихимипокровительственнымиинтонациямикоторыесвойственнысостаревшемусявсветеипридворезначител
авивейсвоюнадушеннуюисияющуюлысинуипокойноуселсянадиванеуспокойтеменясказалоннеизменяяголосаитономв
асмешкакакможнобытьздоровойкогданравственнострадаешьразвеможноимеячувствооставатьсяспокойноювнашевр
нглийскогопосланникаанынчесередамненадопоказатьсятамсказалкнязьдочьзаедетзамнойиповезетменяядумалачт
здникбыотменилисказалкнязьпопривычкекакзаведенныечасыговорявещикоторымонинехотелчтобывериликаквамск
илвсегдаленивокакактерговоритрольстаройпиесыаннапавловнашерернапротивнесмотрянасвоисороклетбылапреи
ественнымположениемииногдакогдаейдажетогонехотелосьоначтобынеобманутьожиданийлюдейзнавшихееделалась
павловныхотяинешлакееотжившимчертамвыражалакакуизбалованныхдетейпостояннеосознаниесвоегомилогонедос
ятьсявсерединеразговорапрополитическиедействияаннапавловнаразгорячиласьахнеговоритемнепроавстриюяни
ойныонапредаетнасроссияоднадолжнабытьспасительницейевропынашблагодетельзнаетсвоевысокоепризваниеибу
рюпредстоитвеличайшаярольвмиреионтакдобродетеленихорошчтобогнеоставитегоионисполнитсвоепризваниезад
йцыизлодеямыоднидолжныискупитькровьправедниканакогонамнадеятьсяявасспрашиваюанглияссвоимкоммерчески
сандраонаотказалась ьочиститьмальтуонахочетвидетьищетзаднююмыслынашихдействийчтоонисказалиновосильцев
мператоракоторыйничегонехочетдлясебяивсехочетдляблагамираичтоониобещалиничегоичтообещалиитогонебуде
чегонеможетпротивнегоияневерюниводномсловенигарденбергунигаугвицуяверюводногобогаиввысокуюсудьбунаш
лыбкойнасмешкинадсвоеюгорячностьюядумаюсказалкнязьулыбаясьчтоежелибывапослаливместонашегомилоговин
красноречивывыдадитемнечаюсейчасприбавилаонаопятьуспокоиваясьнынчеуменядваоченьинтересныечеловекаод
тоящихипотомвызнаетеэтотглубокийумонбылпринятгосударемвызнаетеаяоченьрадбудусказалкнязьскажитеприба
дакактоочемонспрашивалбылоглавнойцельюегопосещенияправдачтожелаетназначениябаронафункепервымсекрета
ечерезимператрицумариюфеодоровнустарались доставитьбаронуаннапавловнапочтизакрылаглазавзнактогочтони
ератрицетолькосказалаонагрустнымсухимтономвтовремякаканнапавловнаназвалаимператрицулицоеевдругпредс
единенноесгрустьючтоснейбывалокаждыйразкогдаонавразговореупоминалаосвоейвысокойпокровительницеонаск
лядееподернулсягрустьюкнязьравнодушнозамолканнапавловнассвойственноюейпридворноюиженскоюловкостьюиб
отозватьсяолицерекомендованномимператрицеивтожевремяутешитьегосказалаоназнаетеличтовашадочьстехпорк
астодумаюпродолжалааннапавловнапослеминутногомолчанияпридвигаяськкнязюиласковоулыбаясьемукакбудтовы
ерьначинаетсязадушевныйячастодумаюкакиногданесправедливораспределяетсясчастиежизнизачтовамдаласудьб
нелюблювставилаонабезапелляционноприподнявбровитакихпрелестныхдетейавыправоменеевсехценитеихипотому
язьперестаньтешутитьяхотеласерьезнопоговоритьсвамизнаетеянедовольнавашимменьшимсыноммеждунамибудьск
ествваижалеютваскнязьнеотвечалноонамолчазначительноглядянанегождалаответакнязьвасилийпоморщилсячтожм
ечтоможетотециобавышлиипродитпокрайнеймерепокойныйдуракаанатольбеспокойныйвотдноразличиесказалонул
Рядок 1, стовпець 1
515 747 символів
Звичайний текст

Бачимо, що результат ми отримали той що треба, отже пунк 1 виконано.

2 Розрахунок статистичних характеристик тексту

Спочатку для окремих символів:

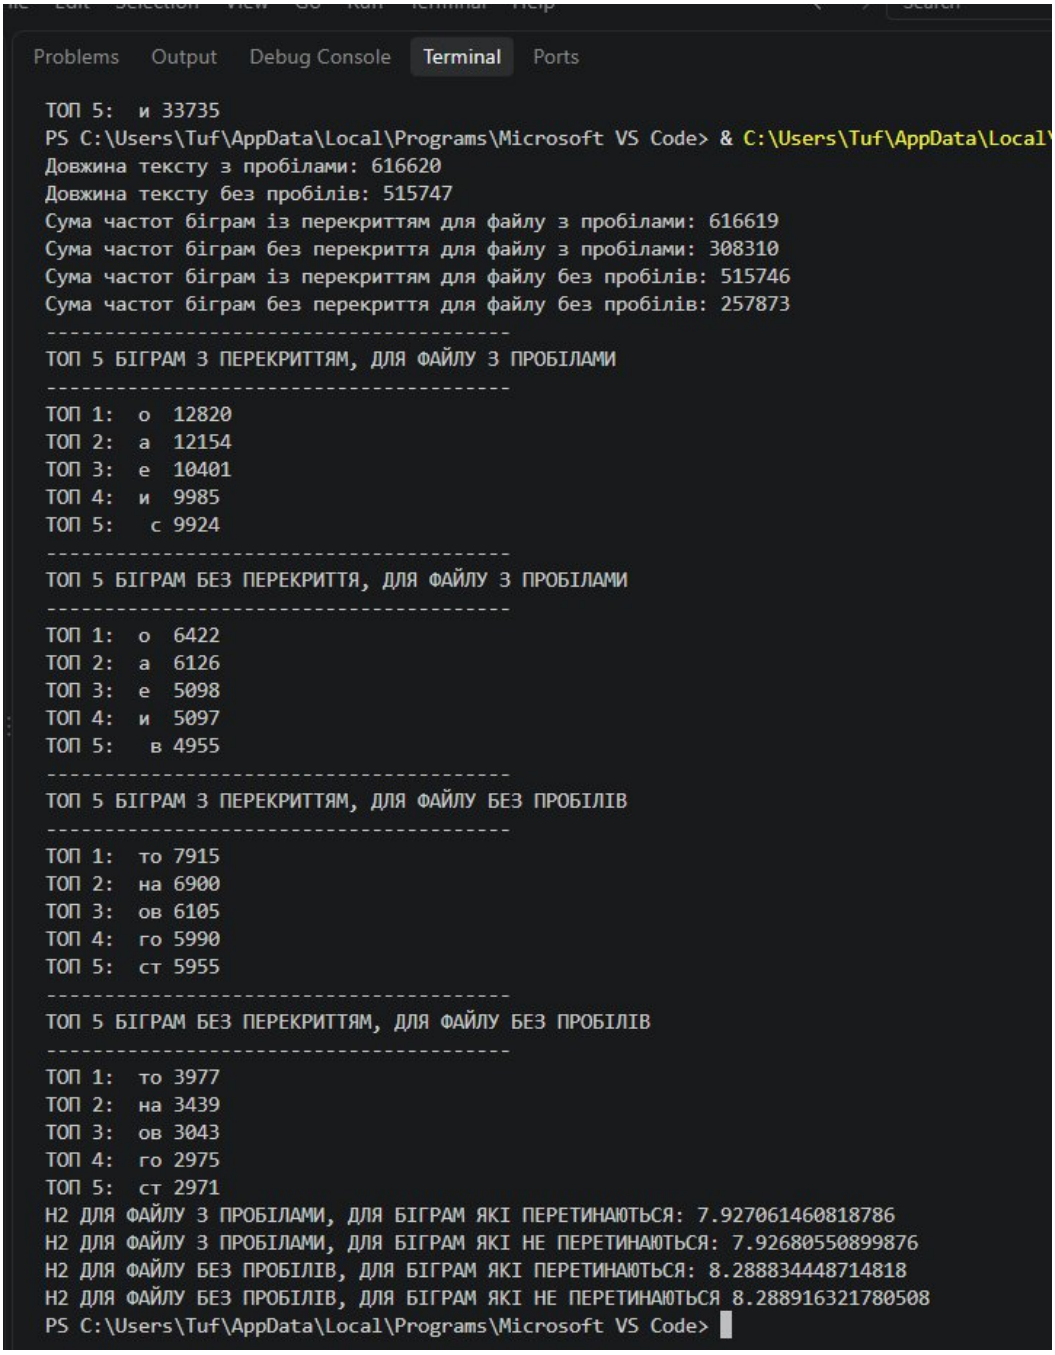
Результат після запуску другої програми для окремих символів



Для файлу з пробілами у нас H1 = 4.380070816320864 біт/символ і найчастіший елемент який зустрічається у ньому це пробіл.

А для файлу без пробілів H1 = 4.468193901173498 біт/символ і його найчастіший символ це (О)

H2 для біграм:



У програмі було підраховано частоти біграм двома способами: з перекриттям і без перекриття. Для біграм із перекриттям кожна наступна пара починається з наступного символу, а без перекриття через два символи. Також було визначено п’ять найчастіших біграм для тексту з пробілами та без них.

Для тексту з пробілами найчастішою біграмою в обох випадках виявилася пара, що містить пробіл і літеру «о». Для тексту без пробілів найчастішою біграмою стала. Ентропія H2 для тексту з пробілами становить приблизно 7,927, а для тексту без пробілів — 8,289. Значення ентропії для біграм із перекриттям і без перекриття дуже близькі між собою.

Значення H2 для біграм, що перетинаються та не перетинаються, майже однакові. Для тексту з пробілами вони становлять 7,9271 і 7,9268 відповідно, а для тексту без пробілів — 8,2888 і 8,2889.

Невеликі відмінності виникають через те, що під час використання біграм із перекриттям враховуються всі сусідні пари символів, а без перекриття — лише пари, які не мають спільних символів. Більше статистичних даних використовує спосіб із перекриттям, оскільки він враховує майже кожну можливу пару сусідніх символів у тексті.

Короткий опис коду:

```python
with open(r"C:\Users\Tuf\Desktop\3 Курс\Крипта\lab1\space", "r", encoding="utf-8") as file:
    space = file.read()
with open(r"C:\Users\Tuf\Desktop\3 Курс\Крипта\lab1\no_space", "r", encoding="utf-8") as file:
    no_space = file.read()
```

Спочатку ми відкриваємо наші 2 файли, записуємо їх значення у змінні та закриваємо ці файли.

Після цього я реалізував програму яка підраховує частити біграм, їх у мене вийшло 4.

```python
#1) Для текста з пробілами
#1.1 ті що перетинаються (зсув на 1 символ)
bigrams_with_space_p = {}
for i in range(len(space) - 1):
    if space[i:i+2] not in bigrams_with_space_p.keys():
        bigrams_with_space_p[space[i:i+2]] = 1
    else:
        bigrams_with_space_p[space[i:i+2]] += 1


#1.2 ті що не перетинаються (зсув на 2 символи)
bigrams_with_space_np = {}
for i in range(0, len(space) - 1, 2):
    if space[i:i+2] not in bigrams_with_space_np.keys():
        bigrams_with_space_np[space[i:i+2]] = 1
    else:
        bigrams_with_space_np[space[i:i+2]] += 1

print("Сума частот біграм із перекриттям для файлу з пробілами:", sum(bigrams_with_space_p.values()))
print("Сума частот біграм без перекриття для файлу з пробілами:", sum(bigrams_with_space_np.values()))
```

Усі отримані дані я зберігаю в словнику, бо так зручніше, і далі вивожу загальну суму частот біграм та суми частот окремих біграм у мене так і залишаються у зберіганні в словнику. Цей код однакого виглядить із

аналізом файлу без пробілу, просто відрізняються назвами змін, але суть та сама.

```
"ТОР 5"
#для файлу з пробілами, біграми що перекриваються (зсув на 1 символ)

print('--' * 20)
print('ТОП 5 БІГРАМ З ПЕРЕКРИТТЯМ, ДЛЯ ФАЙЛУ З ПРОБІЛАМИ')
print('--' * 20)

cop = bigrams_with_space_p.copy()
maximum = 0
max_key = ''
number_top = 1

while number_top <= 5:
    for i in cop:
        if cop[i] > maximum:
            maximum = cop[i]
            max_key = i
    cop.pop(max_key)
    print(f"ТОП {number_top}: ", max_key, maximum )
    number_top += 1
    maximum = 0
```

Тут я реалізував свій цикл який вичисляє та виводить тап 5 біграм з перетином для файлу з пробілами.

Алгоритм його роботи заключається в тому що він бере з нашого словника в якому ми початково зберігали всі частито біграм різних типів, створюємо змінні для значення, ключа максимального елемента та його топ номер і перебираємо скопійований словнки. При знаходженні найдільшого елемента, ми його видаляємо з копії словника та виводимо на екран його топ номер, і робимо так до поки не дійдемо до топ 5.

Код аналогічною логікою реалізовано для всіх частот як і біграм так і окремих символів.

```
#ймовірність

#1) для файлу з пробілами

#біграми що перетинаються
N1 = sum(bigrams_with_space_p.values())
bigrams_with_space_p_imovirnist = {}
for i in bigrams_with_space_p:
    if i not in bigrams_with_space_p_imovirnist:
        bigrams_with_space_p_imovirnist[i] = bigrams_with_space_p[i] / N1

#біграми що не перетинаються
N2 = sum(bigrams_with_space_np.values())
bigrams_with_space_np_imovirnist = {}
for i in bigrams_with_space_np:
    if i not in bigrams_with_space_np_imovirnist:
        bigrams_with_space_np_imovirnist[i] = bigrams_with_space_np[i] / N2
```

Далі ми знаходмо ймовірність.

Ми знаходимо з кожного словника суму всіх елементів, затім ми створюємо словник який зберігає ймовірність і починаємо перевіряти його через умову якщо у нас даний елемент не міститься у словнику ймовірності, то тоді ми кількість появи даного елемента ділимо на загальну кількість частот і таким чином у нас виходить ймовірність.

ЛОГІКА ТА САМА І ДЛЯ ІНШИХ РЯДКІВ КОДУ

```
#Ентропія H2

#1) для файлу з пробілами

H2_space_p = 0
for i in bigrams_with_space_p_imovirnist:
    H2_space_p -= bigrams_with_space_p_imovirnist[i]* log2(bigrams_with_space_p_imovirnist[i])

H2_space_np = 0
for i in bigrams_with_space_np_imovirnist:
    H2_space_np -= bigrams_with_space_np_imovirnist[i]* log2(bigrams_with_space_np_imovirnist[i])


#2) для файлу без пробілів
H2_no_space_p = 0
for i in bigrams_no_space_p_imovirnist:
    H2_no_space_p -= bigrams_no_space_p_imovirnist[i]* log2(bigrams_no_space_p_imovirnist[i])

H2_no_space_np = 0
for i in bigrams_no_space_np_imovirnist:
    H2_no_space_np -= bigrams_no_space_np_imovirnist[i]* log2(bigrams_no_space_np_imovirnist[i])
```

Знаходимо тепер саму ентропію за формулою (p(i) * log2(p(i)))* -1

В цьому коді я просто у відповідні змінні вписую результат формули для кожної ймовірності окремих біграм як -= значення.

Тобто при додавання в змінну у нас спочатку буде мінусове значення, а потім плюсове.

Дослідження впливу розподілу символів на ентропію

Послідовність Б матиме найменшу ентропію оскільки там просто повторюється 1 символ і це дуже легко передбачити.

Послідовність А є уже з більшою ентропією, бо текст має якийсть сенс і по цьому сенсу можна при читанні слова по буквам якось передбачити яка буде наступна буква, щоб при читанні був якийсь сенс.

Послідовність В є з максимальною ентропією, бо у нас випадокве випадання символа, і тому у нас всі символу мають однакову ймовірність, а отже ентропія максимальна.

```
----------------------------------------
ПУНКТ 3. ВПЛИВ РОЗПОДІЛУ СИМВОЛІВ
----------------------------------------
H1(Б) — один символ 'а' = 0.0
H1(А) — природний текст = 4.468193901173498
H1(В) — випадкова послідовність = 5.044346117180151
PS C:\Users\Tuf\AppData\Local\Programs\Microsoft VS Code>
```

Дослідження залежностей між символами

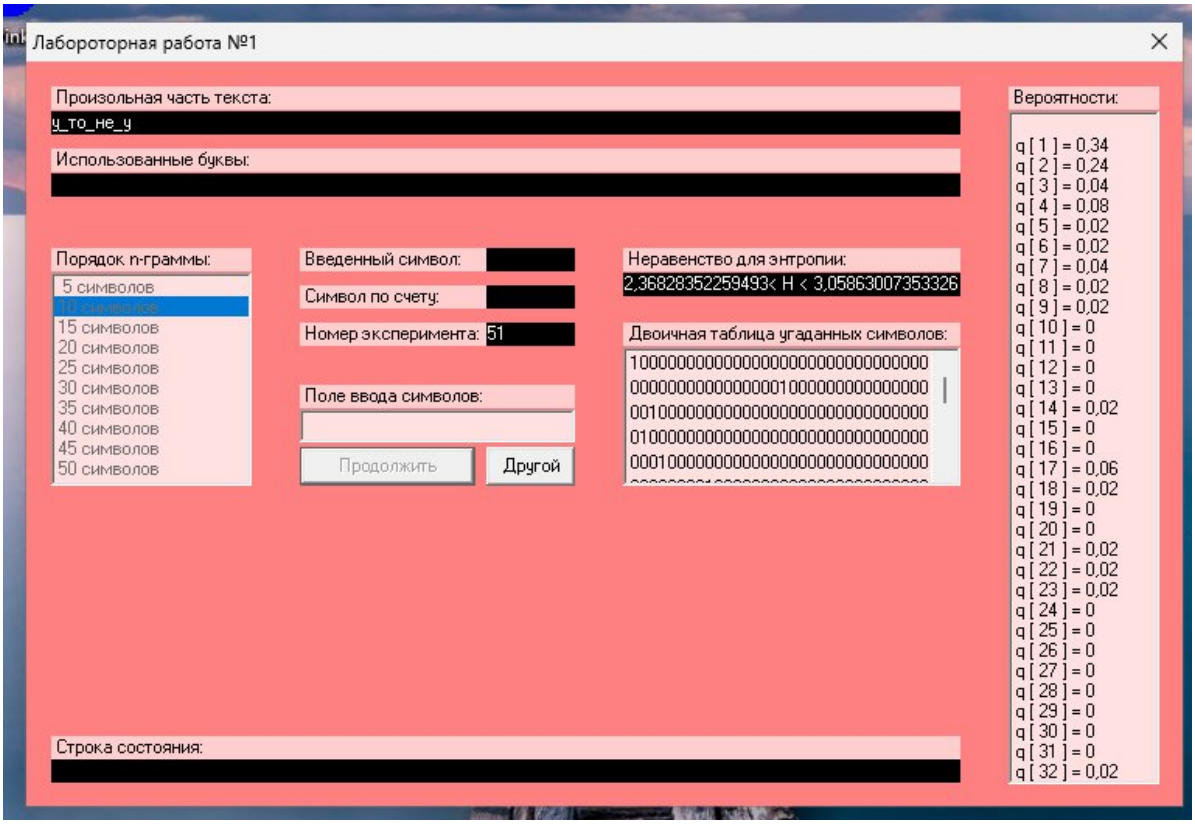
```
PS C:\Users\Tuf\AppData\Local\Programs\Microsoft VS Code> & C:\Users
ПУНКТ 4. ДОСЛІДЖЕННЯ ЗАЛЕЖНОСТЕЙ МІЖ СИМВОЛАМИ
--------------------------------------------------
Використані символи: ['о', 'ю', 'и']
Довжина G: 9999
Довжина D: 9999

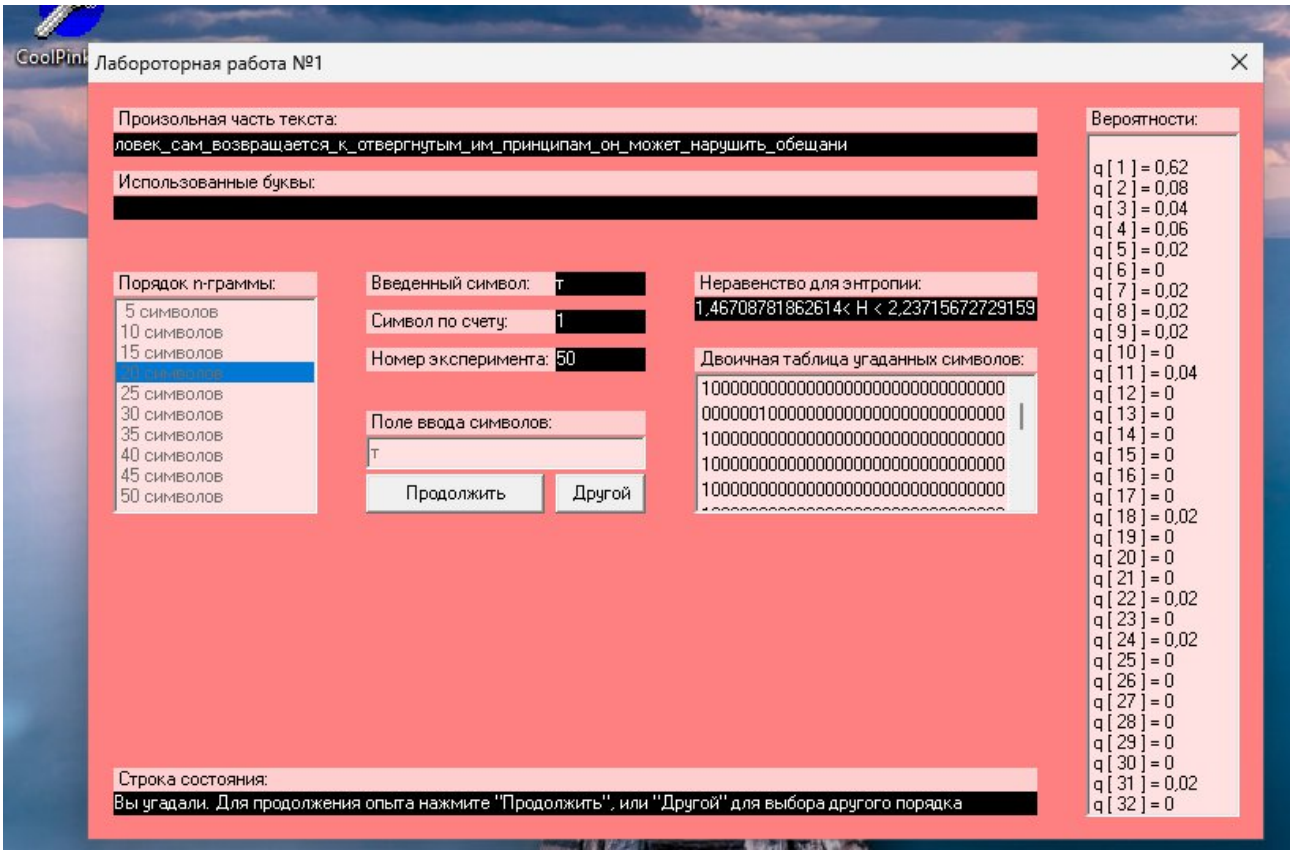
Ентропія H1:
H1(G) — випадкова послідовність: 1.584962500721156
H1(D) — періодична послідовність: 1.584962500721156

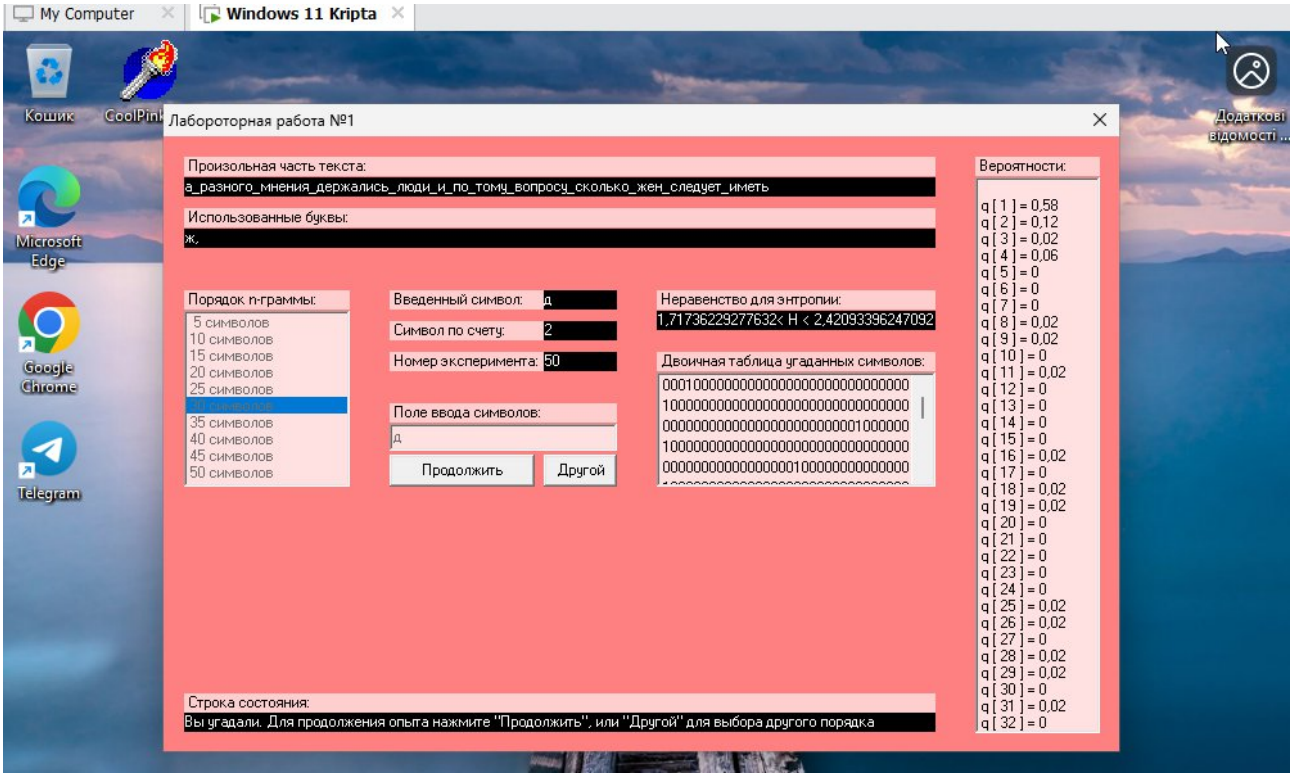
H2 для біграм, що перетинаються:
H2(G): 3.1696843802417307
H2(D): 1.584962486287952

H2 для біграм, що не перетинаються:
H2(G): 3.16846569258832
H2(D): 1.584962442994113
PS C:\Users\Tuf\AppData\Local\Programs\Microsoft VS Code>
```

5 Експериментальна оцінка ентропії джерела


Лабороторная работа №1
Произольная часть текста:
у_то_не_у
Использованные буквы:
Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов
Введенный символ:
Символ по счету:
Номер эксперимента: 51
Поле ввода символов:
Продолжить
Другой
Неравенство для энтропии:
2,36828352259493< H < 3,05863007353326
Двоичная таблица угаданных символов:
Вероятности:
q[1] = 0,34
q[2] = 0,24
q[3] = 0,04
q[4] = 0,08
q[5] = 0,02
q[6] = 0,02
q[7] = 0,04
q[8] = 0,02
q[9] = 0,02
q[10] = 0
q[11] = 0
q[12] = 0
q[13] = 0
q[14] = 0,02
q[15] = 0
q[16] = 0
q[17] = 0,06
q[18] = 0,02
q[19] = 0
q[20] = 0
q[21] = 0,02
q[22] = 0,02
q[23] = 0,02
q[24] = 0
q[25] = 0
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0,02
Строка состояния:


Лабороторная работа №1
Произольная часть текста:
ловек_сам_возвращается_к_отвергнутым_им_принципам_он_может_нарушить_обещани
Использованные буквы:
Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов
Введенный символ: т
Символ по счету: 1
Номер эксперимента: 50
Поле ввода символов:
т
Продолжить
Другой
Неравенство для энтропии:
1,46708781862614< H < 2,23715672729159
Двоичная таблица угаданных символов:
Вероятности:
q[1] = 0,62
q[2] = 0,08
q[3] = 0,04
q[4] = 0,06
q[5] = 0,02
q[6] = 0
q[7] = 0,02
q[8] = 0,02
q[9] = 0,02
q[10] = 0
q[11] = 0,04
q[12] = 0
q[13] = 0
q[14] = 0
q[15] = 0
q[16] = 0
q[17] = 0
q[18] = 0,02
q[19] = 0
q[20] = 0
q[21] = 0
q[22] = 0,02
q[23] = 0
q[24] = 0,02
q[25] = 0
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0,02
q[32] = 0
Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка



Оцінка	Отримане значення
H1	4.3801 біт/символ
H2	7.9271 біт/символ
H(10)	2,3683 < H < 3,0586
H(20)	1,4671 < H < 2,2372
H(30)	1,7174 < H < 2,4209

Проаналізуйте отримані результати та поясніть

1

Кожна оцінка дивиться на текст по-різному. H_1 дивиться тільки на те, які літери трапляються частіше. H_2 додає, які літери ідуть поруч. $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ дивляться на цілий уривок перед літерою. До того ж $H^{(n)}$ ми знаходили вгадуванням, тому це приблизні числа, і вони залежать від людини та від того, що експериментів було лише 50.

2

H_1 враховує тільки частоту окремих літер (наприклад, пробіл і «о» трапляються частіше, ніж «щ»). H_2 враховує ще й пари літер: яка літера найчастіше іде після даної.

3

У мові літери не випадкові. Якщо бачиш початок слова або фрази, то часто можеш здогадатися, що буде далі. Чим більше тексту перед літерою, тим легше її вгадати, тому невизначеність і ентропія зменшуються.

4

Чим довший контекст, тим менша ентропія

6. Оцінювання надлишковості джерела

Надлишковість джерела обчислюється за формулою:

$$R = 1 - \frac{H}{H_0}$$

де $H_0 = \log_2(32) = 5.0000$ біт/символ (максимальна можлива ентропія для алфавіту з 32 символів).

Оцінка надлишковості для різних моделей джерела:

Розрахунок надлишковості за формулою $R = 1 - H/H_0$:

Оцінка	Значення, біт/символ	R
H1	4,3801	13,9 %
H2	3,9636	22,1 %
H(10)	2,3683 – 3,0586	39,9 – 53,4 %
H(20)	1,4671 – 2,2372	56,0 – 71,2 %
H(30)	1,7174 – 2,4209	52,4 – 66,2 %

Аналіз результатів

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

Це через те що природній текст можна по логіці слова дізнатися який символ буде наступним, а у випадковій рівноймовірній послідовності буде максимальна ентропія бо ми не зможемо легко передбачити який символ буде, тільки здогадуватися, це через те що ймовірність випадання кожного елемента рівна між собою.

```
H1(A) – природний текст = 4.468193901173498
H1(B) – випадкова послідовність = 5.044346117180151
```

Ось як в пункті 3, природній текст має меншу ентропію ніж з випадковою постідовністю.

2. Яку інформацію про джерело враховує H_2, але не враховує H_1?

H2 враховує зв'язок між двома сусідніми символами: яка літера найімовірніше стоїть після даної. H1 знає лише частоти окремих літер і не знає, у якому порядку вони йдуть.

Наприклад, після «ь» голосна майже не трапляється, а після пробілу часто йдуть «в», «н», «п». H2 цього не бачить, а H1 бачить, бо рахує частоти пар.

У наших результатах це видно з того, що H2 приблизно 3,96 біт/символ менше за H1 = 4,38 біт/символ. Знаючи попередню літеру, наступну вгадати легше, тому невизначеність менша.

3) Чи можуть два тексти мати однакове H_1, але різне H_2? Наведіть приклад із виконаних експериментів.

Так, можуть. H_1 залежить тільки від частот окремих символів, а H_2 ще й від того, в якому порядку вони йдуть.

Приклад із пункта 4 (послідовності Г і Д).
Обидві послідовності мають однаковий алфавіт, однакову довжину і однакові частоти символів. Тому H_1 у них однакове: **[H_1 для Г і Д]**.

Але порядок різний:

- У **Г** символи йдуть випадково, тому після будь-якого символу може бути будь-який. Біграм багато і вони різноманітні, тож H_2 велике: **[H_2 для Г]**.
- У **Д** (abab…) після «a» завжди йде «b», а після «b» завжди «a». Є лише дві різні біграми, тож H_2 значно менше: **[H_2 для Д]**.

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.

Вилучення пробілів змінює статистичні характеристики тексту, оскільки пробіл є окремим символом і має власну частоту появи. Після його вилучення змінюється розподіл імовірностей символів, тому може змінитися значення ентропії H1. Також змінюється H2, оскільки літери, які раніше були розділені пробілами, стають сусідніми та утворюють нові біграми. Таким чином, вилучення пробілів впливає на частоти символів і біграм, а отже, і на обчислені значення ентропії.

5. Чому оцінки H2, отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Біграми, що перетинаються, формуються зі зміщенням на один символ, тому враховують усі сусідні пари символів у тексті. Біграми, що не перетинаються, формуються зі зміщенням на два символи, тому частина можливих сусідніх пар не враховується. Через це відрізняються кількість використаних біграм і їхні частоти. Відповідно, отримані оцінки H2 можуть дещо відрізнятися. Спосіб із біграмами, що перетинаються, використовує більше статистичних даних, оскільки враховує всі сусідні пари символів.

6. Чому значення H1, H2, H(10), H(20) та H(30) відрізняються?

Ці значення відрізняються через використання різних моделей джерела тексту та різну довжину контексту, який враховується під час оцінювання ентропії. H1 враховує лише частоти окремих символів, а H2 додатково враховує статистичні залежності між сусідніми символами. Оцінки H(10), H(20) та H(30) отримують експериментальним методом CoolPinkProgram із відповідними параметрами контексту. Зі збільшенням довжини контексту можна враховувати більше закономірностей природної мови, тому оцінки можуть змінюватися. Водночас експериментальні результати залежать від випадковості дослідів і особливостей використаного тексту.

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Найкраще наявність залежностей між символами демонструє експеримент із послідовностями Г і Д, у яких частоти окремих символів однакові або максимально близькі, але порядок їх розташування відрізняється. Наприклад, у випадковій послідовності символи розташовані без вираженої закономірності, а в періодичній послідовності «abababab...» чергування символів є передбачуваним. Через це значення H1 можуть бути однаковими або близькими, тоді як значення H2 відрізнятимуться. Це демонструє, що порядок символів і залежності між ними впливають на ентропію джерела.

8. Як отримані результати пов’язані з можливістю стиснення природного тексту без втрати інформації?

Отримані результати показують, що природний текст має статистичні закономірності та залежності між символами, які можна використовувати для стиснення даних без втрати інформації. Оскільки деякі символи й біграми трапляються частіше за інші, для їх кодування можна використовувати коротші кодові слова. Врахування залежностей між символами дає змогу точніше оцінювати ймовірності появи наступних символів і підвищувати ефективність стиснення. Надлишковість

природної мови створює можливість зменшення обсягу тексту, водночас зберігаючи можливість його повного відновлення.

Висновок:

Загальні висновки

Під час виконання лабораторної роботи було досліджено ентропію та надлишковість російськомовного тексту. Було написано програму для підрахунку частот символів і біграм та обчислення значень H1 і H2. Також було досліджено вплив вилучення пробілів, розподілу символів і залежностей між ними на ентропію. За допомогою CoolPinkProgram було проведено додаткові експерименти з різною довжиною контексту. У результаті роботи я краще зрозумів, як обчислюється ентропія тексту та як його статистичні закономірності можна використовувати для стиснення інформації без її втрати.