

Міністерство освіти і науки України  
Національний технічний університет України "Київський  
політехнічний інститут імені Ігоря Сікорського"  
Фізико-технічний інститут

**Лабораторна робота 1  
з предмету «Криптографія»**

**Підготували:  
студенти 3 курсу  
групи ФБ-43  
Бойко Олег  
Бурлачка Артем**

# Експериментальна оцінка ентропії на символ джерела відкритого тексту

Варіант №5

## Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

## Хід роботи

### 1. Підготовка тексту

Для обробки використано роман Ф. М. Достоевського «Преступление и наказание». Розмір початкового файлу original\_text.txt становить приблизно 2 МБ.

Усі літери переведено в нижній регістр, а ё замінено на е. Латиницю, цифри, розділові знаки та інші символи, які не входять до діапазону а-я, замінено пробілами.

Послідовності таких символів і пробілів замінено одним пробілом; пробіли на початку та наприкінці вилучено.

Підготовлений текст записано у text\_with\_spaces.txt. Для другої версії всі пробіли вилучено, результат записано у text\_without\_spaces.txt. Алфавіт містить 32 російські літери без ё. У версії з пробілами розмір алфавіту дорівнює 33.

Довжина тексту з пробілами: 1 010 436 символів; без пробілів: 837 768 символів.

### 2. Розрахунок статистичних характеристик тексту

Програму реалізовано в файлі lab1.py. Counter підраховує символи та біграми, calculate\_entropy обчислює ентропію, а print\_top\_five виводить п'ять найчастіших елементів. Числові результати зберігаються у results.txt.

Частота символу дорівнює його кількості, поділеній на довжину тексту. Частота біграми визначається відносно кількості сформованих пар. Для  $H_1$  та  $H_2$  використано такі формули:

$$H_1 = - \sum_x p(x) \log_2 p(x)$$

$$H_2 = - \frac{1}{2} \sum_b p(b) \log_2 p(b)$$

## Частоти окремих символів

| Символ | Кількість з пробілами | Частота з пробілами | Кількість без пробілів | Частота без пробілів |
|--------|-----------------------|---------------------|------------------------|----------------------|
| пробіл | 172 668               | 0.170885            | —                      | —                    |
| а      | 66 702                | 0.066013            | 66 702                 | 0.079619             |
| б      | 14 570                | 0.014420            | 14 570                 | 0.017391             |
| в      | 38 767                | 0.038367            | 38 767                 | 0.046274             |
| г      | 14 137                | 0.013991            | 14 137                 | 0.016875             |
| д      | 26 844                | 0.026567            | 26 844                 | 0.032042             |
| е      | 73 010                | 0.072256            | 73 010                 | 0.087148             |
| ж      | 9 559                 | 0.009460            | 9 559                  | 0.011410             |
| з      | 12 895                | 0.012762            | 12 895                 | 0.015392             |
| и      | 54 334                | 0.053773            | 54 334                 | 0.064856             |
| й      | 8 372                 | 0.008286            | 8 372                  | 0.009993             |
| к      | 27 664                | 0.027378            | 27 664                 | 0.033021             |
| л      | 38 524                | 0.038126            | 38 524                 | 0.045984             |
| м      | 26 339                | 0.026067            | 26 339                 | 0.031439             |
| н      | 54 492                | 0.053929            | 54 492                 | 0.065044             |
| о      | 96 204                | 0.095210            | 96 204                 | 0.114834             |
| п      | 23 017                | 0.022779            | 23 017                 | 0.027474             |
| р      | 34 976                | 0.034615            | 34 976                 | 0.041749             |
| с      | 44 377                | 0.043919            | 44 377                 | 0.052971             |
| т      | 54 246                | 0.053686            | 54 246                 | 0.064751             |
| у      | 24 867                | 0.024610            | 24 867                 | 0.029682             |
| ф      | 987                   | 0.000977            | 987                    | 0.001178             |
| х      | 7 133                 | 0.007059            | 7 133                  | 0.008514             |
| ц      | 2 307                 | 0.002283            | 2 307                  | 0.002754             |
| ч      | 15 197                | 0.015040            | 15 197                 | 0.018140             |
| ш      | 6 889                 | 0.006818            | 6 889                  | 0.008223             |
| щ      | 2 511                 | 0.002485            | 2 511                  | 0.002997             |
| ъ      | 203                   | 0.000201            | 203                    | 0.000242             |
| ы      | 13 825                | 0.013682            | 13 825                 | 0.016502             |
| ь      | 19 253                | 0.019054            | 19 253                 | 0.022981             |
| э      | 2 961                 | 0.002930            | 2 961                  | 0.003534             |
| ю      | 4 724                 | 0.004675            | 4 724                  | 0.005639             |
| я      | 17 882                | 0.017697            | 17 882                 | 0.021345             |

П'ять найчастіших символів із пробілами: пробіл, о, е, а, н; без пробілів: о, е, а, н, и.

## Найчастіші біграми та значення ентропії

Пробіл у біграмах позначено знаком `_`. Для кожного випадку наведено п'ять біграм із найбільшими частотами.

| Текст і спосіб побудови      | Біграма | Кількість | Частота  |
|------------------------------|---------|-----------|----------|
| 3 пробілами<br>3 перетином   | o_      | 24 705    | 0.024450 |
|                              | e_      | 19 645    | 0.019442 |
|                              | и_      | 17 774    | 0.017590 |
|                              | a_      | 17 411    | 0.017231 |
|                              | _в      | 16 971    | 0.016796 |
| 3 пробілами<br>Без перетину  | o_      | 12 403    | 0.024550 |
|                              | e_      | 9 769     | 0.019336 |
|                              | и_      | 8 890     | 0.017596 |
|                              | a_      | 8 605     | 0.017032 |
|                              | _в      | 8 536     | 0.016896 |
| Без пробілів<br>3 перетином  | то      | 15 175    | 0.018114 |
|                              | ов      | 10 550    | 0.012593 |
|                              | не      | 10 280    | 0.012271 |
|                              | на      | 10 126    | 0.012087 |
|                              | но      | 9 977     | 0.011909 |
| Без пробілів<br>Без перетину | то      | 7 519     | 0.017950 |
|                              | ов      | 5 258     | 0.012552 |
|                              | не      | 5 122     | 0.012228 |
|                              | на      | 5 068     | 0.012099 |
|                              | но      | 4 965     | 0.011853 |

## Результати обчислення ентропії, біт/символ:

| Текст        | $H_1$    | $H_2$ з перетином | $H_2$ без перетину |
|--------------|----------|-------------------|--------------------|
| 3 пробілами  | 4.349475 | 3.935628          | 3.934503           |
| Без пробілів | 4.450226 | 4.126408          | 4.126050           |

Значення  $H_2$  близькі, оскільки обидва способи оцінюють частоти пар у тому самому великому тексті. Відмінності становлять приблизно 0,001125 біт/символ із пробілами та 0,000358 без них. Вони виникають через різний набір врахованих пар.

### 3. Дослідження впливу розподілу символів на ентропію

Підготовлено три послідовності по 100 000 символів: А — початок нормалізованого тексту з пробілами; Б — повторення а; В — випадкові символи 33-символьного алфавіту з однаковою ймовірністю вибору.

До обчислень наш прогноз  $B \rightarrow A \rightarrow V$  за зростанням  $H_1$ . Для Б очікувалося нульове значення, для А — проміжне через нерівні частоти літер, для В — значення поблизу максимуму.

| Послідовність | Характер тексту         | $H_1$ , біт/символ |
|---------------|-------------------------|--------------------|
| А             | Природний текст         | 4.356668           |
| Б             | Повторення а            | 0.000000           |
| В             | Рівноймовірна генерація | 5.044133           |

Прогноз підтвердився. У Б є лише один символ з імовірністю 1, тому  $H_1 = 0$ . У А розподіл нерівномірний. У В частоти близькі до рівних, тому ентропія майже максимальна. Невелика різниця з максимумом пояснюється скінченною довжиною випадкової послідовності.

### 4. Дослідження залежностей між символами

Для цього експерименту використано алфавіт із двох символів - а і б. Послідовність Д утворено повторенням аб 50 000 разів. Для Г ті самі символи випадково перемішано. Обидві послідовності містять рівно 50 000 а та 50 000 б.

Прогноз:  $H_1$  буде однаковим і дорівнюватиме 1, оскільки частоти символів збігаються. Для Г очікувалося  $H_2$  близько 1, можливі всі чотири пари. Для Д очікувалося менше  $H_2$ , приблизно 0,5 із перетином і 0 без перетину.

| Послідовність | $H_1$    | $H_2$ з перетином | $H_2$ без перетину |
|---------------|----------|-------------------|--------------------|
| Г             | 1.000000 | 0.999997          | 0.999993           |
| Д             | 1.000000 | 0.500000          | 0.000000           |

Результати підтвердили прогноз. У Г біграми аа, аб, ба та бб мають близькі частоти. У Д з перетином трапляються аб і ба, а без перетину — лише аб.

## 5. Експериментальна оцінка ентропії джерела

Для порядків 10, 20 і 30 виконано по 50 завершених вгадувань, загалом 150.

Програма підраховує частки вгадувань із першої, другої та наступних спроб і визначає нижню та верхню межі ентропії.  $H^{(n)}$  є оцінкою умовної ентропії наступного символу за попередніми  $n-1$  символами.

The screenshot shows the 'Лабораторная работа №1' window. It displays the results of 50 experiments for order 10. The 'Произвольная часть текста:' field contains 'ц\_ваши\_стандарты\_почти\_всегда\_он\_старается\_показать\_что\_то\_что\_он\_сделал\_на'. The 'Использованные буквы:' field contains 'о, е, и, у'. The 'Порядок n-граммы:' list shows '5 символов' selected. The 'Введенный символ:' field contains 'а'. The 'Символ по счету:' field contains '5'. The 'Номер эксперимента:' field contains '50'. The 'Неравенство для энтропии:' field shows '1.84512544126353 < H < 2.72444203526882'. The 'Двоичная таблица угаданных символов:' field shows a binary table with 32 rows and 10 columns. The 'Вероятности:' list shows probabilities for 32 symbols, with q[1] = 0.5, q[2] = 0.1, q[3] = 0.06, q[4] = 0.04, q[5] = 0.06, q[6] = 0.02, q[7] = 0.04, q[8] = 0.06, q[9] = 0, q[10] = 0.02, q[11] = 0.02, q[12] = 0, q[13] = 0, q[14] = 0.02, q[15] = 0.02, q[16] = 0, q[17] = 0.02, q[18] = 0, q[19] = 0, q[20] = 0, q[21] = 0, q[22] = 0, q[23] = 0.02, q[24] = 0, q[25] = 0, q[26] = 0, q[27] = 0, q[28] = 0, q[29] = 0, q[30] = 0, q[31] = 0, q[32] = 0. The 'Строка состояния:' field shows 'Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка'.

Рисунок 1 — Результат 50 экспериментів для порядку 10

Для порядку 10 отримано  $1,845125 < H^{(10)} < 2,724442$  біт/символ.

The screenshot shows the 'Лабораторная работа №1' window. It displays the results of 50 experiments for order 20. The 'Произвольная часть текста:' field contains 'лый\_рой\_извинений\_и\_пояснений\_но\_в\_данный\_момент\_нас\_не\_интересует\_насколько'. The 'Использованные буквы:' field is empty. The 'Порядок n-граммы:' list shows '20 символов' selected. The 'Введенный символ:' field contains ' (пробел)'. The 'Символ по счету:' field contains '1'. The 'Номер эксперимента:' field contains '50'. The 'Неравенство для энтропии:' field shows '1.87722292509504 < H < 2.60192809488736'. The 'Двоичная таблица угаданных символов:' field shows a binary table with 32 rows and 20 columns. The 'Вероятности:' list shows probabilities for 32 symbols, with q[1] = 0.5, q[2] = 0.08, q[3] = 0.08, q[4] = 0.08, q[5] = 0.04, q[6] = 0, q[7] = 0, q[8] = 0.08, q[9] = 0, q[10] = 0.02, q[11] = 0, q[12] = 0.04, q[13] = 0.02, q[14] = 0, q[15] = 0, q[16] = 0, q[17] = 0.02, q[18] = 0, q[19] = 0, q[20] = 0.02, q[21] = 0, q[22] = 0, q[23] = 0, q[24] = 0, q[25] = 0, q[26] = 0, q[27] = 0, q[28] = 0, q[29] = 0, q[30] = 0.02, q[31] = 0, q[32] = 0. The 'Строка состояния:' field shows 'Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка'.

Рисунок 2 — Результат 50 экспериментів для порядку 20



## 6. Оцінювання надлишковості джерела

$$R = 1 - \frac{H}{H_0}, \quad H_0 = \log_2 m$$

Для нашого тексту з пробілами  $m = 33$ , без пробілів  $m = 32$ . У CoolPink використано 32-символьний алфавіт: 31 літеру без ё та ь і пробіл. Для нього  $H_0 = 5$ . Більшій межі ентропії відповідає менша межа надлишковості.

| Модель або оцінка                 | Надлишковість |
|-----------------------------------|---------------|
| 3 пробілами — $H_1$               | 13.78%        |
| 3 пробілами — $H_2$ з перетином   | 21.98%        |
| 3 пробілами — $H_2$ без перетину  | 22.00%        |
| Без пробілів — $H_1$              | 11.00%        |
| Без пробілів — $H_2$ з перетином  | 17.47%        |
| Без пробілів — $H_2$ без перетину | 17.48%        |
| CoolPink $H^{(10)}$               | 45.51%–63.10% |
| CoolPink $H^{(20)}$               | 47.96%–62.46% |
| CoolPink $H^{(30)}$               | 49.02%–64.10% |

# Аналіз результатів

## 1. Чому природний текст має меншу ентропію на символ ніж випадкова рівномовірна послідовність того самого алфавіту

У природному тексті символи мають нерівні частоти. Наприклад, пробіл становить приблизно 17,09% символів. Для фрагмента А отримано  $H_1 = 4.356668$ , а для рівномовірної В — 5.044133 біт/символ.

## 2. Яку інформацію про джерело враховує $H_2$ але не враховує $H_1$

$H_2$  враховує частоти сусідніх пар, тобто залежність наступного символу від попереднього в межах біграми.  $H_1$  враховує лише частоти окремих символів.

## 3. Чи можуть два тексти мати однакове $H_1$ але різне $H_2$

Так. У Г та Д однакові кількості а і б, тому  $H_1 = 1$  в обох випадках. Після перемішування Г має  $H_2$  із перетином = 0.999997, тоді як періодична Д — 0,500000 біт/символ. Без перетину для Д отримано 0. Відрізняються частоти пар, хоча частоти літер збігаються.

## 4. Як вилучення пробілів вплинуло на отримані значення ентропії

$H_1$  зросло з 4,349475 до 4,450226, а  $H_2$  із перетином — з 3,935628 до 4,126408 біт/символ.

## 5. Чому оцінки $H_2$ за біграмами з перетином і без нього можуть відрізнятися

Способи враховують різні позиції та різну кількість пар. З перетином отримуємо N-1 біграм, без перетину —  $\lfloor N/2 \rfloor$ . Для природного тексту з пробілами оцінки 3,935628 та 3,934503 близькі. Для періодичної Д відмінність велика: 0,5 і 0, бо крок 2 вибирає тільки пару аб.

## 6. Чому значення $H_1$ $H_2$ $H^{(10)}$ $H^{(20)}$ та $H^{(30)}$ відрізняються

$H_1$  описує окремі символи,  $H_2$  - пари, а оцінки CoolPink враховують довший контекст через процес вгадування. Довші залежності можуть зменшувати невизначеність, але на порівняння також впливають різні тексти, алфавіти.

## 7. Який експеримент найкраще демонструє залежності між послідовними символами

Найкраще їх демонструє порівняння Г і Д, оскільки довжина, алфавіт та частоти літер однакові. Змінено лише порядок.

## 8. Як отримані результати пов'язані зі стисненням природного тексту без втрати інформації

Нерівні частоти дозволяють кодувати поширені символи коротше, а залежності між символами дають змогу використовувати контекст. Для нашого тексту з пробілами надлишковість за  $H_1$  становить 13,78%, а за  $H_2$  із перетином — 21,98%.

## Висновок

Під час виконання лабораторної роботи було підготовлено текст, визначено частоти символів та біграм і обчислено  $H_1$  та  $H_2$ . Експерименти А, В підтвердили, що рівномірний розподіл дає найбільшу ентропію, а повторення одного символу — нульову. Порівняння Г і Д показало, що однакові частоти літер можуть поєднуватися з різними частотами біграм та різними  $H_2$ . У CoolPinkProgram виконано 150 експериментів. Результати демонструють передбачуваність природного тексту та його ненульову надлишковість.