

# Криптографія

## Комп'ютерний практикум №1

Експериментальна оцінка ентропії на символ  
джерела відкритого тексту

Виконали: Оліневич Богдан  
та Візгін Климент ФБ-43

## **Мета роботи:**


Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення й порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок оцінки ентропії на символ джерела

## **Порядок виконання роботи**

### **1. Підготовка тексту**

***Завдання:** обрати довільний російськомовний текст обсягом не менше 1 МБ і виконати його попередню обробку (нижній регістр, вилучення символів поза алфавітом, згортання пробілів)*

Для аналізу використано повний текст роману Ф.Достоевського “Браття Карамазові”.



Правила попередньої обробки (реалізовано у функції preprocess):

- усі літери приводяться до нижнього регістру; «ё» зводиться до «е»;
- символи поза алфавітом {а..я, без ё} (латиниця, цифри, пунктуація) вилучаються — замінюються пробілом;
- послідовності пробілів та розділових символів згортаються в один пробіл, пробіли по краях

прибираються;

- для обчислень «без пробілів» з нормалізованого тексту додатково вилучаються всі пробіли.

Довжина тексту з пробілами: 1719594 символів; без пробілів: 1422571 символів.

```
Довжина сирого тексту: 1821802
```

```
Довжина після нормалізації (з пробілами): 1719594
```

```
Довжина без пробілів: 1422571
```

```
Перші 300 символів нормалізованого тексту (з пробілами):
```

```
самый сложный самый многоуровневый и неоднозначный из романов достоевск  
очной русской душе роман легший в основу десятков экранизаций от предел
```

```
PS C:\Users\user\Documents\cryptolabs\lab1\ФБ-43_Олінович_Візгін> █
```

## 2. Розрахунок статистичних характеристик тексту

**Завдання:** реалізувати програму для підрахунку частот символів, частот біграм (що перетинаються і не перетинаються) та обчислення  $H1$  і  $H2$  — для тексту з пробілами і без них.

part1.py X

```
part1.py > ...
1  import math
2  import re
3  from collections import Counter
4
5
6  RUSSIAN_LETTERS = "абвгдежзийклмнопрстуфхцчшщъыьэюя"
7  ALPHABET_WITH_SPACE = set(RUSSIAN_LETTERS + " ")
8
9  def preprocess(raw_text: str, keep_spaces: bool = True) -> str:
10     text = raw_text.lower()
11     text = text.replace("ё", "е")
12     text = "".join(ch if ch in ALPHABET_WITH_SPACE else " " for ch in text)
13     text = re.sub(r" +", " ", text).strip()
14     if not keep_spaces:
15         text = text.replace(" ", "")
16
17     return text
18  file_name = "БратьяКарамазовы_Достоевский.txt"
19
20  with open(file_name, encoding="utf-8", errors="ignore") as f:
21     raw_data = f.read()
22
23     print("Довжина сирого тексту:", len(raw_data))
24
25     text_with_spaces = preprocess(raw_data, keep_spaces=True)
26     text_no_spaces = preprocess(raw_data, keep_spaces=False)
27
28     print("Довжина після нормалізації (з пробілами):", len(text_with_spaces))
29     print("Довжина без пробілів:", len(text_no_spaces))
30     print("\nПерші 300 символів нормалізованого тексту (з пробілами):")
31     print(text_with_spaces[:300])
32
33
34
35  def calc_entropy(counts: Counter, total: int) -> float:
36     h = 0.0
37     for c in counts.values():
38         p = c / total
39         h -= p * math.log2(p)
40     return h
41
42  def analyze_text(text: str, is_spaced: bool):
43     total = len(text)
44     counts = Counter(text)
45     h1 = calc_entropy(counts, total)
46
47     bg_over = [text[i:i+2] for i in range(total - 1)]
```

```

47     bg_over = [text[i:i+2] for i in range(total - 1)]
48     h2_over = calc_entropy(Counter(bg_over), len(bg_over)) / 2.0
49
50     bg_nonover = [text[i:i+2] for i in range(0, total - 1, 2)]
51     h2_nonover = calc_entropy(Counter(bg_nonover), len(bg_nonover)) / 2.0
52
53     label = "ТЕКСТ З ПРОБІЛОМ" if is_spaced else "ТЕКСТ БЕЗ ПРОБІЛІВ"
54     alpha_size = 33 if is_spaced else 32
55
56     print("=" * 60)
57     print(f"{label} (алфавіт із {alpha_size} символів)")
58     print("=" * 60)
59
60     print("Топ-5 символів (символ, кількість, частка):")
61     for ch, n in counts.most_common(5):
62         display_ch = "'пробіл'" if ch == " " else f"'{ch}'"
63         print(f"{display_ch:>15} {n:>10} {n/total:>8.4f}")
64
65     print("Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:")
66     for bg, n in Counter(bg_over).most_common(5):
67         display_bg = f"'{bg}'"
68         print(f"{display_bg:>15} {n:>10} {n/len(bg_over):>8.4f}")
69
70     print("Топ-5 біграм, що НЕ перетинаються:")
71     for bg, n in Counter(bg_nonover).most_common(5):
72         display_bg = f"'{bg}'"
73         print(f"{display_bg:>15} {n:>10} {n/len(bg_nonover):>8.4f}")
74
75     print(f"{'H1':<15} = {h1:.4f} біт/симв.")
76     print(f"{'H2 (перетин.)':<15} = {h2_over:.4f} біт/симв.")
77     print(f"{'H2 (без перет.)':<15} = {h2_nonover:.4f} біт/симв.")
78     print("\n")
79
80     analyze_text(text_with_spaces, True)
81     analyze_text(text_no_spaces, False)

```

Програма написана мовою Python з використанням стандартних бібліотек math та collections. Для підрахунку частот символів та біграм використовується структура даних Counter, яка автоматично створює словник із частотами унікальних елементів.

Формування біграм реалізовано за допомогою генераторів списків:

Для біграм, що перетинаються, береться зріз тексту з кроком 1:

```
[text[i:i+2] for i in range(total - 1)]
```

Для біграм, що не перетинаються, використовується крок 2:

```
[text[i:i+2] for i in range(0, total - 1, 2)]
```

Ентропія обчислюється в окремій функції за формулою Шеннона. Для кожного унікального елемента з Counter розраховується його ймовірність (шляхом ділення кількості його входжень на загальну кількість елементів), після чого значення додаються до загальної суми ентропії. Для моделі біграм (H2) отримане значення ентропії додатково ділиться на 2, щоб отримати питому ентропію на один символ.

=====

ТЕКСТ З ПРОБІЛОМ (алфавіт із 33 символів)

=====

Топ-5 символів (символ, кількість, частка):

|          |        |        |
|----------|--------|--------|
| 'пробіл' | 297023 | 0.1727 |
| 'о'      | 162009 | 0.0942 |
| 'е'      | 126830 | 0.0738 |
| 'а'      | 109637 | 0.0638 |
| 'и'      | 96289  | 0.0560 |

Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:

|      |       |        |
|------|-------|--------|
| 'о ' | 42886 | 0.0249 |
| 'е ' | 33590 | 0.0195 |
| 'и ' | 31305 | 0.0182 |
| ' в' | 29024 | 0.0169 |
| ' с' | 28055 | 0.0163 |

Топ-5 біграм, що НЕ перетинаються:

|      |       |        |
|------|-------|--------|
| 'о ' | 21436 | 0.0249 |
| 'е ' | 16798 | 0.0195 |
| 'и ' | 15451 | 0.0180 |
| ' в' | 14731 | 0.0171 |
| ' с' | 14111 | 0.0164 |

H1 = 4.3544 біт/симв.

H2 (перетин.) = 3.9432 біт/симв.

H2 (без перет.) = 3.9429 біт/симв.

```

=====
ТЕКСТ БЕЗ ПРОБІЛІВ (алфавіт із 32 символів)
=====
Топ-5 символів (символ, кількість, частка):
      'о'      162009   0.1139
      'е'      126830   0.0892
      'а'      109637   0.0771
      'и'       96289   0.0677
      'т'       93717   0.0659
Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:
      'то'      25690   0.0181
      'не'      17767   0.0125
      'ов'      17171   0.0121
      'ст'      17102   0.0120
      'но'      16802   0.0118
Топ-5 біграм, що НЕ перетинаються:
      'то'      12702   0.0179
      'не'       8913   0.0125
      'ст'       8583   0.0121
      'ов'       8523   0.0120
      'но'       8380   0.0118
Н1          = 4.4611 біт/симв.
Н2 (перетин.) = 4.1412 біт/симв.
Н2 (без перет.) = 4.1409 біт/симв.

```

## Таблиці частот символів та біграм

### Текст з пробілом (алфавіт із 33 символів)

| Характеристика | Символ / Біграма | Кількість | Частка (Ймовірність) |
|----------------|------------------|-----------|----------------------|
| Топ-5 символів | пробіл           | 297023    | 0.1727               |
|                | о                | 162009    | 0.0942               |
|                | е                | 126830    | 0.0738               |
|                | а                | 109637    | 0.0638               |
|                | и                | 96289     | 0.0560               |

| Характеристика                  | Символ / Біграма | Кількість | Частка (Ймовірність) |
|---------------------------------|------------------|-----------|----------------------|
| Топ-5 біграм (перетинаються)    | о (з пробілом)   | 42886     | 0.0249               |
|                                 | е (з пробілом)   | 33590     | 0.0195               |
|                                 | и (з пробілом)   | 31305     | 0.0182               |
|                                 | (пробіл) в       | 29024     | 0.0169               |
|                                 | (пробіл) с       | 28055     | 0.0163               |
| Топ-5 біграм (НЕ перетинаються) | о (з пробілом)   | 21436     | 0.0249               |
|                                 | е (з пробілом)   | 16798     | 0.0195               |
|                                 | и (з пробілом)   | 15451     | 0.0180               |
|                                 | (пробіл) в       | 14731     | 0.0171               |
|                                 | (пробіл) с       | 14111     | 0.0164               |

## Текст без пробілів (алфавіт із 32 символів)

| Характеристика               | Символ / Біграма | Кількість | Частка (Ймовірність) |
|------------------------------|------------------|-----------|----------------------|
| Топ-5 символів               | о                | 162009    | 0.1139               |
|                              | е                | 126830    | 0.0892               |
|                              | а                | 109637    | 0.0771               |
|                              | и                | 96289     | 0.0677               |
|                              | т                | 93717     | 0.0659               |
| Топ-5 біграм (перетинаються) | то               | 25690     | 0.0181               |

| Характеристика                  | Символ / Біграма | Кількість | Частка (Ймовірність) |
|---------------------------------|------------------|-----------|----------------------|
|                                 | не               | 17767     | 0.0125               |
|                                 | ов               | 17171     | 0.0121               |
|                                 | ст               | 17102     | 0.0120               |
|                                 | но               | 16802     | 0.0118               |
| Топ-5 біграм (НЕ перетинаються) | то               | 12702     | 0.0179               |
|                                 | не               | 8913      | 0.0125               |
|                                 | ст               | 8583      | 0.0121               |
|                                 | ов               | 8523      | 0.0120               |
|                                 | но               | 8380      | 0.0118               |

## Зведена таблиця значень ентропії

| Показник              | Текст з пробілами | Текст без пробілів |
|-----------------------|-------------------|--------------------|
| H1                    | 4.3544 біт/симв.  | 4.4611 біт/симв.   |
| H2 (перетинаються)    | 3.9432 біт/симв.  | 4.1412 біт/симв.   |
| H2 (не перетинаються) | 3.9429 біт/симв.  | 4.1409 біт/симв.   |

Спосіб із біграмами, що перетинаються (зміщення на один символ), використовує рівно вдвічі більше статистичних даних. Для тексту довжиною  $N$  символів цей метод аналізує  $N-1$  пар, тоді як метод без перетину формує лише  $N/2$  пар. Зібрана статистика підтверджує це: кількість найчастіших біграм, що перетинаються, є вдвічі більшою за

кількість тих, що не перетинаються (наприклад, біграма «то» зустрічається 25690 разів із перетином та 12702 рази без перетину).

Значення ентропії  $H_2$ , отримані обома способами, є дуже близькими, але не ідентичними. Для тексту з пробілами різниця складає 0.0003 біт/символ (3.9432 проти 3.9429), а для тексту без пробілів — 0.0003 біт/символ (4.1412 проти 4.1409). Ця невелика відмінність виникає через те, що неперекривний метод відкидає половину можливих переходів між літерами, що робить його вибірку менш репрезентативною та більш чутливою до специфічної ритміки слів (наприклад, чергування голосних і приголосних). Метод із перекривними біграмами охоплює всі без винятку зв'язки між сусідніми літерами тексту, тому він забезпечує точнішу та стабільнішу оцінку ентропії джерела.

### **3. Дослідження впливу розподілу символів на ентропію**

**Завдання:** підготувати послідовності А (фрагмент природного тексту), Б (повторення одного символу) і В (рівноімовірна випадкова послідовність), спрогнозувати порядок зростання  $H_1$ , обчислити  $H_1$  для кожної й порівняти з прогнозом

```

83  SEQ_LENGTH = 20000
84  seq_a = text_no_spaces[:SEQ_LENGTH]
85
86  most_common_char = Counter(text_no_spaces).most_common(1)[0][0]
87  seq_b = most_common_char * SEQ_LENGTH
88
89  alphabet = sorted(list(set(text_no_spaces)))
90
91  rng = random.Random(42)
92  seq_v = "".join(rng.choice(alphabet) for _ in range(SEQ_LENGTH))
93
94  print("=" * 60)
95  print("ЕТАП 3: ДОСЛІДЖЕННЯ ВПЛИВУ РОЗПОДІЛУ СИМВОЛІВ")
96  print("=" * 60)
97
98  for name, seq in [("А (Природний текст)", seq_a),
99                  | ("Б (Один символ)", seq_b),
100                 | ("В (Рівноймовірна)", seq_v)]:
101      counts = Counter(seq)
102      h1 = calc_entropy(counts, len(seq))
103      print(f"Послідовність {name}:")
104      print(f"  Довжина: {len(seq)}")
105      print(f"  Унікальних символів: {len(counts)}")
106      print(f"  H1 = {h1:.4f} біт/символ\n")

```

Очікуваний порядок зростання ентропії  $H_1$ :  $B < A < V$ .  
**Послідовність Б (найменша ентропія, очікується 0):**  
 Оскільки текст складається лише з одного символу, його ймовірність дорівнює 1, а ймовірність усіх інших — 0. Невизначеність відсутня повністю, тому  $H_1 = 0$ .

**Послідовність А (середня ентропія):** У природному тексті символи з'являються з різною частотою (наприклад, голосні зустрічаються набагато частіше за рідкісні приголосні типу «ф» чи «щ»). Ця нерівномірність зменшує загальну невизначеність порівняно з абсолютно випадковим текстом, але вона значно більша за нуль.

**Послідовність В (найбільша ентропія):** Якщо всі символи алфавіту генеруються з однаковою

ймовірністю, невизначеність появи наступного символу є максимальною. Для алфавіту з 32 символів очікується максимальне значення  $H_1 = \log_2(32) = 5$  біт/символ.

```
=====
ЕТАП 3: ДОСЛІДЖЕННЯ ВПЛИВУ РОЗПОДІЛУ СИМВОЛІВ
=====
Послідовність А (Природний текст):
  Довжина: 20000
  Унікальних символів: 32
  H1 = 4.4453 біт/символ

Послідовність Б (Один символ):
  Довжина: 20000
  Унікальних символів: 1
  H1 = 0.0000 біт/символ

Послідовність В (Рівноймовірна):
  Довжина: 20000
  Унікальних символів: 32
  H1 = 4.9989 біт/символ
```

Отримані результати повністю підтверджують попередній прогноз:  $B < A < V$ .

**Як характер розподілу ймовірностей впливає на ентропію:**

Ентропія безпосередньо залежить від ступеня нерівномірності розподілу ймовірностей символів.

Вироджений розподіл (послідовність Б), де один символ має ймовірність 1, дає нульову ентропію, оскільки джерело є абсолютно передбачуваним і не генерує нової інформації.

Рівномірний розподіл (послідовність В), де кожен із 32 символів має ймовірність  $p = 1/32$ , максимізує ентропію. Формула Шеннона в цьому випадку досягає своєї верхньої межі  $\log_2(32) = 5$  біт/символ.

Розподіл природної мови (послідовність А) лежить посередині. Завдяки наявності статистичних закономірностей (часті та рідкісні літери), природна мова має меншу невизначеність, ніж абсолютно випадкове джерело, що і підтверджується значенням  $H_1 = 4.45$  біт/символ. Чим сильніше реальний розподіл відхиляється від рівномірного, тим меншою стає ентропія.

#### **4. Дослідження залежностей між символами**

***Завдання:** сформувати послідовності Г (символи у випадковому порядку) і Д (виражена періодична структура) з однаковими або близькими частотами символів, спрогнозувати й порівняти  $H_1$  та  $H_2$  (для перетинних і неперетинних біграм)*

#### **Прогноз до виконання обчислень:**

1. Значення  $H_1$  для послідовностей Г і Д не відрізнятимуться. Формула  $H_1$  не враховує порядок символів, тому за умови однакових частот результат буде ідентичним.

2. Значення H2 суттєво відрізнятимуться.

3. Значно менше значення H2 очікується для послідовності Д. Періодична структура робить появу наступного символу майже повністю передбачуваною, зводячи невизначеність до мінімуму.

4. Значення H2 для біграм, що перетинаються та не перетинаються, у послідовності Д дещо відрізнятимуться через циклічність зсуву, але обидва будуть значно нижчими за відповідні значення у послідовності Г.

```
random.seed(42)
random.shuffle(base_chars)
seq_g = "".join(base_chars)

counts = Counter(text_no_spaces[:SEQ_LENGTH])
symbols_sorted = sorted(counts.keys())
remaining = dict(counts)
pattern = []

while sum(remaining.values()) > 0:
    for s in symbols_sorted:
        if remaining.get(s, 0) > 0:
            pattern.append(s)
            remaining[s] -= 1
seq_d = "".join(pattern)

print("=" * 60)
print("ЕТАП 4: ДОСЛІДЖЕННЯ ЗАЛЕЖНОСТЕЙ МІЖ СИМВОЛАМИ")
print("=" * 60)

for name, seq in [("Г (Випадковий порядок)", seq_g), ("Д (Періодична структура)", seq_d)]:
    h1 = calc_entropy(Counter(seq), len(seq))

    bg_over = [seq[i:i+2] for i in range(len(seq) - 1)]
    h2_over = calc_entropy(Counter(bg_over), len(bg_over)) / 2.0

    bg_nonover = [seq[i:i+2] for i in range(0, len(seq) - 1, 2)]
    h2_nonover = calc_entropy(Counter(bg_nonover), len(bg_nonover)) / 2.0

    print(f"Послідовність {name}:")
    print(f"  H1 = {h1:.4f} біт/символ")
    print(f"  H2 (перекривні) = {h2_over:.4f} біт/символ")
    print(f"  H2 (неперекривні) = {h2_nonover:.4f} біт/символ\n")
```

```
=====
ЕТАП 4: ДОСЛІДЖЕННЯ ЗАЛЕЖНОСТЕЙ МІЖ СИМВОЛАМИ
=====
```

```
Послідовність Г (Випадковий порядок):
```

```
Н1 = 4.4453 біт/символ
```

```
Н2 (перекривні) = 4.4280 біт/символ
```

```
Н2 (неперекривні) = 4.4090 біт/символ
```

```
Послідовність Д (Періодична структура):
```

```
Н1 = 4.4453 біт/символ
```

```
Н2 (перекривні) = 2.7364 біт/символ
```

```
Н2 (неперекривні) = 2.6619 біт/символ
```

**Чому тексти з однаковими частотами мають однакові значення Н1:** Величина Н1 фіксує виключно одновимірний розподіл ймовірностей — скільки разів трапився кожен символ, повністю ігноруючи їхнє розташування в тексті. Оскільки набори літер в обох послідовностях ідентичні, рівняння ентропії видає однаковий результат.

**Чому значення Н2 відрізняються:** Ентропія Н2 базується на умовній структурі пар символів. У послідовності Г пари утворюються хаотично, тому знання першого символу не допомагає вгадати другий, що зберігає невизначеність високою. У послідовності Д символи підпорядковуються жорсткому циклічному правилу. Знаючи одну літеру, можна практично безпомилково визначити наступну, тому ентропія різко падає.

**Інформація, яку враховує модель біграм:** Модель біграм виявляє структурну передбачуваність та внутрішні зв'язки джерела. На відміну від моделі незалежних символів, яка бачить лише ізольовані

букви, модель біграм фіксує статистику поєднання сусідніх елементів, демонструючи наявність "пам'яті" та правил сполучуваності у джерела тексту.

## 5. Експериментальна оцінка ентропії джерела

**Завдання:** за допомогою програми CoolPinkProgram оцінити значення  $H^{(10)}$ ,  $H^{(20)}$ ,  $H^{(30)}$ , виконавши для кожного не менше 50 експериментів, і порівняти з  $H_1$  та  $H_2$ , обчисленими власною програмою.

Лабораторная работа №1

Произвольная часть текста:  
одыскивае

Использованные буквы:

Порядок n-граммы:  
5 символов  
10 символов  
15 символов  
20 символов  
25 символов  
30 символов  
35 символов  
40 символов  
45 символов  
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:  
 $5,26563986825754 < H < 4,23127238011291$

Двоичная таблица угаданных символов:

|                                  |
|----------------------------------|
| 00000010000000000000000000000000 |
| 00000000000001000000000000000000 |
| 00000000000100000000000000000000 |
| 00000000000000010000000000000000 |
| 00000000000000000000000100000000 |
| 00000000000000000000000000000000 |

Вероятности:

|                |
|----------------|
| $q[1] = 0$     |
| $q[2] = 0$     |
| $q[3] = 0$     |
| $q[4] = 0$     |
| $q[5] = 0,08$  |
| $q[6] = 0,08$  |
| $q[7] = 0,04$  |
| $q[8] = 0,04$  |
| $q[9] = 0,06$  |
| $q[10] = 0,02$ |
| $q[11] = 0$    |
| $q[12] = 0,06$ |
| $q[13] = 0,02$ |
| $q[14] = 0,08$ |
| $q[15] = 0,02$ |
| $q[16] = 0$    |
| $q[17] = 0,06$ |
| $q[18] = 0$    |
| $q[19] = 0$    |
| $q[20] = 0,02$ |
| $q[21] = 0$    |
| $q[22] = 0,02$ |
| $q[23] = 0,02$ |
| $q[24] = 0,06$ |
| $q[25] = 0,1$  |
| $q[26] = 0,02$ |
| $q[27] = 0$    |
| $q[28] = 0,02$ |
| $q[29] = 0,04$ |
| $q[30] = 0,02$ |
| $q[31] = 0,04$ |
| $q[32] = 0,08$ |

Строка состояния:



| Оцінка | Отримане значення     |
|--------|-----------------------|
| H1     | 4.3544 біт/симв.      |
| H2     | 3.9432 біт/симв.      |
| H10    | $4.2312 < H < 5.2656$ |
| H20    | $2.9806 < H < 3.5622$ |
| H30    | $2.5831 < H < 3.1292$ |

**Чому наведені оцінки ентропії не повинні обов'язково збігатися:** Оцінки не збігаються, оскільки вони базуються на різних наближених моделях джерела тексту, які враховують різну глибину контексту. H1 розглядає текст як послідовність повністю незалежних символів, H2 враховує зв'язок лише з одним попереднім символом, а моделі для H10, H20 та H30 враховують пам'ять джерела на

глибину 10, 20 та 30 символів відповідно. Врахування довшого контексту потенційно дозволяє використовувати більше статистичних закономірностей мови, через що умовна невизначеність наступного символу зменшується. Проте експериментальна оцінка методом вгадування має обмежену точність.

**Які статистичні залежності враховуються при визначенні  $H_1$  та  $H_2$ :** При визначенні  $H_1$  враховується виключно одновимірний розподіл ймовірностей — наскільки часто кожна окрема літера зустрічається в тексті в цілому, незалежно від її позиції. При визначенні  $H_2$  додатково враховуються парні залежності або статистика біграм. Це дозволяє зафіксувати базові правила сполучуваності сусідніх символів (наприклад, після яких літер найчастіше йдуть голосні або неможливість певних буквосполучень).

**Чому врахування довгих залежностей між символами може змінювати оцінку ентропії природної мови:** Природна мова підпорядковується глибоким морфологічним, синтаксичним та лексичним правилам, які діють на рівні цілих слів або речень. Контекст із 10–30 символів охоплює від одного до кількох слів, що дозволяє розпізнати корінь, граматичну форму або вгадати наступне слово за змістом. Це різко звужує кількість можливих варіантів наступної літери, радикально зменшуючи ентропію.

**Яку тенденцію можна спостерігати при переході від H1 до оцінок, що враховують дедалі довший контекст:** У теорії зі збільшенням відомого контексту умовна ентропія джерела має тенденцію до зменшення. У проведеному експерименті ця тенденція чітко спостерігається при переході від H10 до H20}та H30: межі оцінки зміщуються вниз. Водночас отриманий інтервал для 10 є досить широким, тому безпосередньо встановити монотонне співвідношення між H<sub>2</sub> та H10 за отриманими даними неможливо.

## **6. Оцінювання надлишковості джерела**

Максимальна ентропія джерела для алфавіту з 33 символів становить  $H_0 = \log_2(33) = 5.0444$  біт/символ. Надлишковість R розраховується за формулою  $R = 1 - H/H_0$ .

Використовуючи раніше отримані значення ентропії, оцінки надлишковості становлять:

**R1** (модель незалежних символів):  $1 - (4.3544 / 5.0444) = 0.1368$  (13.68%)

**R2** (модель перекривних біграм):  $1 - (3.9432 / 5.0444)$   
 $= 0.2183$  (21.83%)

**R30** (глибокий контекст, інтервал  $2.5831 < H < 3.1292$ ):  
від  $1 - (3.1292 / 5.0444) = 37.97\%$  до  $1 - (2.5831 / 5.0444) = 48.80\%$

### **Порівняння та пояснення:**

**Як змінюється оцінка надлишковості при врахуванні залежностей:** Оцінка надлишковості монотонно зростає при збільшенні глибини врахованого контексту. У моделі незалежних символів (H1) вона становить близько 13.6% і відображає лише нерівномірну частоту появи різних літер та пробілу. При врахуванні довгих залежностей на рівні 30 символів (H30), які охоплюють морфологію, лексику та синтаксис, оцінка надлишковості зростає майже до 49%. Це свідчить про те, що при врахуванні всіх структурних зв'язків тексту майже половина символів стає повністю передбачуваною.

**Чому природна мова має ненульову надлишковість:**  
Ненульова надлишковість є фундаментальною властивістю природних мов, яка виникає через наявність суворих орфографічних, граматичних та

синтаксичних правил. Далеко не всі з можливих комбінацій літер є допустимими словами, а не всі комбінації слів утворюють правильні речення. Крім того, надлишковість забезпечує завадостійкість — саме завдяки їй людина здатна читати текст із помилками, відновлювати пропущені літери або розуміти співрозмовника в шумному середовищі.

**Зв'язок між передбачуваністю, ентропією та надлишковістю:** Що вища передбачуваність наступного символу (завдяки знанню попереднього контексту або правил мови), то меншою є невизначеність його появи, а отже, нижчою є ентропія ( $H$ ). Оскільки надлишковість ( $R$ ) визначається як  $1 - H/H_0$ , чим менше значення ентропії наближається до максимального, тим вищим стає значення надлишковості. Отже, висока передбачуваність тексту означає його низьку ентропію, що зумовлює високу надлишковість джерела.

## Аналіз результатів

**Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?** У природному тексті символи з'являються з суттєво різною частотою (наприклад, пробіл чи літера «о» зустрічаються значно частіше, ніж приголосна «ф»), що від початку зменшує загальну невизначеність. Випадкова рівноймовірна послідовність має максимальну невизначеність, оскільки передбачити наступний символ неможливо. Це підтверджує експеримент 3: для фрагмента природного тексту отримано  $H_1 = 4.4453$  біт/символ, тоді як для рівноймовірної випадкової послідовності того самого алфавіту —  $H_1 = 4.9989$  біт/символ, тобто майже теоретичні 5 біт/символ.

**Яку інформацію про джерело враховує  $H_2$ , але не враховує  $H_1$ ?**  $H_2$  додатково враховує парні статистичні залежності між сусідніми символами (біграмами), фіксуючи правила їхньої сполучуваності (наприклад, після яких літер найчастіше йдуть голосні, або неможливість певних буквосполучень). Натомість  $H_1$  обчислюється лише за загальною частотою появи ізольованих символів. У наших розрахунках

врахування парних зв'язків знизило ентропію тексту з пробілами з 4.3544 (H1) до 3.9432 (H2) біт/символ.

**Чи можуть два тексти мати однакове H1, але різне H2? Наведіть приклад із виконаних експериментів.**

Так, можуть. У четвертому експерименті послідовності Г (випадковий порядок) та Д (періодична структура) були згенеровані з абсолютно однакового набору літер. Через це їхні значення H1 повністю збіглися (4.4453 біт/символ). Однак ентропія H2 у них суттєво відрізнялася (4.4280 для випадкової проти 2.7364 для періодичної), оскільки жорстка структура пар у періодичній послідовності робить її дуже передбачуваною.

**Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.**

Вилучення пробілів призвело до збільшення оцінок ентропії (H1 зросло з 4.3544 до 4.4611, а H2 — з 3.9432 до 4.1412 біт/символ). Пробіл є найчастішим символом (частка понад 17% у нашому тексті), який стабілізує статистику і розбиває потік на короткі, передбачувані блоки (слова). Його відсутність робить текст менш упорядкованим, згладжує загальний розподіл частот і підвищує невизначеність.

**Чому оцінки H2, отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися? Спосіб із біграмами, що перетинаються, використовує вибірку розміром  $N - 1$ , охоплюючи всі можливі пари сусідів. Неперекривний спосіб**

(зміщення на два символи) відкидає половину можливих переходів, використовуючи вдвічі меншу вибірку ( $N/2$ ). Ця втрата статистичних даних робить неперекривний метод більш чутливим до специфічної ритміки тексту (наприклад, чергування голосних і приголосних на парних та непарних позиціях), що призводить до відхилень. У нашому експерименті різниця склала лише 0.0003 біт/символ.

### **Чому значення $H_1$ , $H_2$ , $H_{10}$ , $H_{20}$ та $H_{30}$**

**відрізняються?** Ці оцінки базуються на моделях із різною глибиною пам'яті джерела.  $H_1$  розглядає символи ізольовано,  $H_2$  спирається на 1 попередній символ, а  $H_{10}$ - $H_{30}$  враховують контекст із 10, 20 та 30 літер відповідно. Що довший відомий контекст (який охоплює морфологію, закінчення слів та цілі фрази), то легше застосувати правила мови для вгадування наступної літери. Це постійно зменшує невизначеність: у нашому дослідженні значення впали з 4.35 біт/символ для  $H_1$  до нижньої межі 2.58 біт/символ для  $H_{30}$ .

**Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?** Експеримент 4 із порівнянням послідовностей Г (перемішані символи) та Д (періодична структура). Він ізолює вплив структурної залежності, чітко демонструючи, як наявність жорстких правил слідування символів радикально знижує ентропію біграм  $H_2$  (до 2.73

біт/символ) при абсолютно незмінному одновимірному розподілі частот ізольованих символів  $H_1$ .

### **Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?**

Значення ентропії визначає теоретичну нижню межу кількості бітів, необхідних для кодування одного символу без втрат. Максимальна ємність нашого алфавіту —  $= 5.04$  біт/символ. Проте експериментальна ентропія природного тексту з урахуванням глибокого контексту ( $H_{30}$ ) впала до  $= 2.58$  біт/символ. Це доводить, що текст має високу надлишковість (майже 49%), і за допомогою ефективних алгоритмів архівації його обсяг можна зменшити практично вдвічі без жодної втрати початкової інформації.

### **Висновок:**

У ході виконання лабораторної роботи експериментально доведено, що ентропія природного тексту суттєво залежить від глибини врахованого контексту. Модель незалежних символів ( $H_1$ ) показала найвищу невизначеність ( $4.35$  біт/символ), оскільки відображає лише базову частоту літер. Врахування парних залежностей ( $H_2$ ) та

глибшого контексту ( $H_{10}$ - $H_{30}$ ) поступово знижує ентропію до 2.58 біт/символ. Це підтверджує, що природна мова підпорядковується строгим лексико-граматичним правилам, які роблять текст високопередбачуваним. Розрахована надлишковість на рівні 49% свідчить про високу завадостійкість джерела та наявність значного потенціалу для стиснення даних без втрати інформації.