

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

Національний технічний університет України

«Київський політехнічний інститут імені Ігоря Сікорського»

Навчально-науковий Фізико-технічний інститут

## **ЗВІТ**

з комп'ютерного практикуму №1

з дисципліни «Криптографія»

**Виконали:**

студентки третього курсу

групи ФБ-41

**Борис Марія,**

**Касян Софія**

**Перевірила:**

**Селюх П. В.**

м. Київ – 2026

**Тема.** Експериментальна оцінка ентропії на символ джерела відкритого тексту

**Мета:** Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

### Порядок виконання роботи

#### **1. Підготовка тексту**

Для дослідження використано російськомовний текст «Гарри Поттер и Кубок огня» обсягом 1,56 МБ

У програмі були використані такі правила попередньої обробки:

1. усі літери переводяться у нижній регістр;
2. дозволеними вважаються символи російського алфавіту:  
абвгдеёжзийклмнопрстуфхцчшщъыьэюя;
3. усі символи, що не входять до заданого алфавіту, замінюються пробілами;
4. послідовності кількох пробілів замінюються одним пробілом;
5. пробіли на початку та в кінці тексту видаляються;
6. для обчислень без пробілів усі пробіли вилучаються з уже нормалізованого тексту.

Функція `normalize_text()` переводить текст у нижній регістр, залишає лише символи заданого російського алфавіту та замінює всі інші символи пробілами. За допомогою регулярного виразу кілька пробілів підряд об'єднуються в один. Варіант без пробілів утворюється методом `replace()`

```
ALPHABET = "абвгдеёжзийклмнопрстуфхцчщъыьэюя"
```

```
def normalize_text(text):  
    text = text.lower()  
    text = "".join(  
        symbol if symbol in ALPHABET else "  
    )  
    text = re.sub(r" +", "", text)  
    return text.strip()
```

```
58 # Зчитування початкового тексту з файлу  
59 folder = Path(__file__).resolve().parent  
60 input_file = folder / "harry_potter_4.txt"  
61  
62 text = input_file.read_text(encoding="utf-8")  
63  
64 print(  
65     "Розмір файлу:",  
66     round(input_file.stat().st_size / 1024 / 1024, 2),  
67     "МБ"  
68 )  
69  
70 print("Кількість символів:", len(text))  
71  
72  
73 text_with_spaces = normalize_text(text)  
74 text_without_spaces = text_with_spaces.replace(" ", "")  
75  
76 # Збереження нормалізованого тексту з пробілами  
77 (folder / "text_normalized.txt").write_text(  
78     text_with_spaces,  
79     encoding="utf-8"  
80 )  
81  
82 # без пробілів  
83 (folder / "text_no_spaces.txt").write_text(  
84     text_without_spaces,  
85     encoding="utf-8"  
86 )  
87  
88 print("\nНормалізацію завершено.")  
89 print("Початковий текст:", len(text), "символів")  
90 print("Нормалізований текст:", len(text_with_spaces), "символів")  
91 print("Текст без пробілів:", len(text_without_spaces), "символів")  
92  
93 print("\nПерші 400 символів:")  
94 print(text_with_spaces[:400])  
95
```

У результаті нормалізації з початкових 904795 символів було отримано 849493 символи у тексті з пробілами та 711959 символів у тексті без пробілів

```

Розмір файлу: 1.56 МБ
Кількість символів: 904795

Нормалізацію завершено.
Початковий текст: 904795 символів
Нормалізований текст: 849493 символів
Текст без пробілів: 711959 символів

Перші 400 символів:
дж к роулинг гарри поттер и кубок огня питеру ролингу в память о мистере реддле и сызвен сладден выпустившей гарри из чулана глава дом реддлов в литтл хэнглтоне по преж
нему зовут его домом реддлов хотя семья реддлов давным давно там не живет дом возвышается на холме над деревней окна его заколочены с крыши осыпается черепица а фасада
почти не видно за буйно разросшимся плющом прекрасный когда то о

```

## 2. Розрахунок статистичних характеристик тексту

Для нормалізованого тексту було обчислено частоти окремих символів і біграм, а також значення ентропій  $H_1$  та  $H_2$ . Обчислення виконувались окремо для тексту з пробілами та без пробілів. Для біграм розглядалися два способи формування: зі зміщенням на один символ та зі зміщенням на два символи.

### 2.1. Обчислення частот символів і $H_1$

За допомогою Counter підраховується кількість входжень кожного символу. Ймовірність символу визначається як відношення кількості його появ до загальної довжини тексту. Значення  $H_1$  обчислюється за формулою  $H_1 = -\sum p_i \log_2 p_i$

```

18 def calculate_h1(text):
19     counts = Counter(text)
20     total = len(text)
21     h1 = 0
22
23     # Обчислення ймовірності кожного символу та ентропії
24     for count in counts.values():
25         p = count / total
26         h1 -= p * math.log2(p)
27     return counts, h1

```

```

# Обчислення H1 для тексту з пробілами
counts_spaces, h1_spaces = calculate_h1(text_with_spaces)
print("\n--- Текст з пробілами ---")
print("H1 =", round(h1_spaces, 5))

```

```

# Обчислення H1 для тексту без пробілів
counts_no_spaces, h1_no_spaces = calculate_h1(text_without_spaces)
print("\n--- Текст без пробілів ---")
print("H1 =", round(h1_no_spaces, 5))

```

Для тексту з пробілами отримано  $H_1 = 4.377$  біт/символ, а для тексту без пробілів  $H_1 = 4.46029$  біт/символ. Після видалення пробілів значення ентропії дещо збільшилось

```
--- Текст з пробілами ---  
H1 = 4.377  
Топ-5 символів:  
пробіл - 0.161901  
о - 0.090646  
а - 0.069503  
е - 0.064878  
и - 0.059237  
  
--- Текст без пробілів ---  
H1 = 4.46029  
Топ-5 символів:  
о - 0.108157  
а - 0.082929  
е - 0.07741  
и - 0.07068  
н - 0.063091
```

П'ять символів із найбільшими частотами

Текст з пробілами

| Символ | Частота  |
|--------|----------|
| пробіл | 0,161901 |
| о      | 0,090646 |
| а      | 0,069503 |
| е      | 0,064878 |
| и      | 0,059237 |

Текст без пробілів

| Символ | Частота  |
|--------|----------|
| о      | 0,108157 |
| а      | 0,082929 |
| е      | 0,077410 |
| и      | 0,070680 |
| н      | 0,063091 |

Для тексту з пробілами найчастішим символом є пробіл, а серед літер - о. Після видалення пробілів найчастішою також залишається літера о.

## 2.2. Обчислення біграм і $H_2$

Біграми формуються попарно. При  $\text{step} = 1$  використовуються біграми, що перетинаються, а при  $\text{step} = 2$  - біграми, що не перетинаються. Після визначення їх частот обчислюється ентропія біграм, яка ділиться на 2 для отримання ентропії на один символ

Формула:  $H_2 = -1/2 \sum p_{ij} \log_2 p_{ij}$

```
30 # Обчислення частот біграм та H2
31 def calculate_h2(text, step):
32     bigrams = []
33
34     # Формування біграм зі зміщенням на 1 або 2 символи
35     for i in range(0, len(text) - 1, step):
36         bigrams.append(text[i:i + 2])
37     counts = Counter(bigrams)
38     total = len(bigrams)
39     h = 0
40
41     # Обчислення ентропії біграм
42     for count in counts.values():
43         p = count / total
44         h -= p * math.log2(p)
45
46     # Перерахунок ентропії біграми на один символ
47     h2 = h / 2
48     return counts, h2, total
49
```

```
119
120 # Обчислення H2 для тексту з пробілами та біграм, що перетинаються
121 bigram_spaces_overlap, h2_spaces_overlap, total1 = calculate_h2(
122     text_with_spaces, 1
123 )
124
125 # Обчислення H2 для тексту з пробілами та біграм, що не перетинаються
126 bigram_spaces_no_overlap, h2_spaces_no_overlap, total2 = calculate_h2(
127     text_with_spaces, 2
128 )
129
```

```
--- H2 для тексту з пробілами ---
З перетином = 3.99692
Без перетину = 3.99658
Топ-5 біграм з перетином:
и_ - 0.020285
о_ - 0.019336
а_ - 0.017735
_п - 0.017327
е_ - 0.015787
Топ-5 біграм без перетину:
и_ - 0.020309
о_ - 0.019282
а_ - 0.017667
_п - 0.017323
е_ - 0.015765

--- H2 для тексту без пробілів ---
З перетином = 4.16862
Без перетину = 4.1681
Топ-5 біграм з перетином:
то - 0.013327
на - 0.011933
ст - 0.011704
он - 0.01169
по - 0.011182
Топ-5 біграм без перетину:
то - 0.013509
он - 0.011883
на - 0.011852
ст - 0.011661
по - 0.011273
```

Значення  $H_2$ , отримані для біграм з перетином і без перетину, майже не відрізняються. Невелика різниця пов'язана з тим, що використовуються різні набори біграм. Спосіб із перетином використовує більше статистичних даних, оскільки біграми формуються зі зміщенням на один символ

| Текст        | $H_2$ з перетином | $H_2$ без перетину |
|--------------|-------------------|--------------------|
| З пробілами  | 3,99692           | 3,99658            |
| Без пробілів | 4,16862           | 4,16810            |

Текст з пробілами, біграми з перетином

| Біграма | Частота  |
|---------|----------|
| и_      | 0,020285 |
| о_      | 0,019336 |
| а_      | 0,017735 |
| _п      | 0,017327 |
| е_      | 0,015787 |

Текст з пробілами, біграми без перетину

| Біграма | Частота  |
|---------|----------|
| и_      | 0,020309 |
| о_      | 0,019282 |
| а_      | 0,017667 |
| _п      | 0,017323 |
| е_      | 0,015765 |

Текст без пробілів, біграми з перетином

| Біграма | Частота  |
|---------|----------|
| то      | 0,013327 |
| на      | 0,011933 |
| ст      | 0,011704 |
| он      | 0,011690 |
| по      | 0,011182 |

Текст без пробілів, біграми без перетину

| Біграма | Частота  |
|---------|----------|
| то      | 0,013509 |
| он      | 0,011883 |
| на      | 0,011852 |
| ст      | 0,011661 |
| по      | 0,011273 |

У таблицях символ \_ позначає пробіл. Для тексту з пробілами серед найчастіших біграм переважають сполучення літери з пробілом, а після вилучення пробілів найчастішими стають буквені сполучення то, на, ст, он, по.

### **3. Дослідження впливу розподілу символів на ентропію**

Підготуйте три послідовності достатньої для проведення експерименту довжини:

- А — фрагмент природного російськомовного тексту;
- Б — послідовність, утворену повторенням одного символу;
- В — випадкову послідовність символів того самого алфавіту, в якій усі символи генеруються з однаковою ймовірністю.

Очікувався такий порядок зростання ентропії:  $H_1(B) < H_1(A) < H_1(V)$

Для послідовності Б ентропія повинна бути найменшою, оскільки всі символи однакові. Для природного тексту очікується проміжне значення, а для випадкової рівноймовірної послідовності - найбільше

```

172 # Експеримент А, Б, В
173 length = 50000
174
175 # Послідовність А — фрагмент природного російськомовного тексту
176 sequence_a = text_without_spaces[:length]
177 # Послідовність Б — повторення одного символу
178 sequence_b = "А" * length
179 # Послідовність В — випадкова рівномірна послідовність
180 random.seed(42)
181 sequence_v = ""
182 for i in range(length):
183     sequence_v += random.choice(ALPHABET)
184
185
186 # Обчислення H1 для послідовностей А, Б, В
187 counts_a, h1_a = calculate_h1(sequence_a)
188 counts_b, h1_b = calculate_h1(sequence_b)
189 counts_v, h1_v = calculate_h1(sequence_v)
190
191 # Виведення результатів експерименту А, Б, В
192 print("\n--- Експеримент А, Б, В ---")
193 print("А — природний текст")
194 print("H1 =", round(h1_a, 5))
195 print("Б — повторення одного символу")
196 print("H1 =", round(h1_b, 5))
197 print("В — випадкова рівномірна послідовність")
198 print("H1 =", round(h1_v, 5))
199

```

Для послідовності А використано фрагмент нормалізованого природного тексту. Послідовність Б складається лише з одного символу, що повторюється. Послідовність В генерується випадковим вибором символів із заданого алфавіту з однаковою ймовірністю

```

--- Експеримент А, Б, В ---
А — природний текст
H1 = 4.47421

Б — повторення одного символу
H1 = 0.0

В — випадкова рівномірна послідовність
H1 = 5.04397

```

Отримані результати підтвердили прогноз:  $H_1(B) < H_1(A) < H_1(V)$

Характер розподілу ймовірностей символів безпосередньо впливає на ентропію джерела. Якщо один символ має ймовірність 1, а всі інші - 0, ентропія дорівнює нулю, як у послідовності Б. Якщо ймовірності символів розподілені нерівномірно, ентропія має проміжне значення, як у природному тексті А. Найбільша ентропія спостерігається тоді, коли всі символи мають приблизно однакові ймовірності появи, як у випадковій послідовності В

Отже, чим рівномірніший розподіл імовірностей символів, тим більшою є ентропія джерела

#### 4. Дослідження залежностей між символами

Сформууйте дві послідовності однакової довжини, побудовані на однаковому алфавіті та з однаковими або максимально близькими частотами окремих символів:

- Г — символи розташовані у випадковому порядку;
- Д — символи утворюють виражену періодичну структуру, наприклад abababab....

До виконання обчислень сформулювала прогноз:

- Значення  $H_1$  для послідовностей Г і Д не повинні суттєво відрізнятися, оскільки частоти окремих символів у них однакові.
- Значення  $H_2$  повинні відрізнятися, оскільки  $H_2$  враховує розташування сусідніх символів.
- Менше значення  $H_2$  очікується для послідовності Д, оскільки вона має чітку періодичну структуру і є більш передбачуваною.
- Для послідовності Д очікується різниця між  $H_2$ , обчисленим для біграм з перетином і без перетину, оскільки при різному способі розбиття періодична структура дає різні набори біграм.

Для послідовності Г створено однакову кількість символів а і б, після чого їх порядок випадково перемішано. Послідовність Д сформовано як регулярне чергування символів а та б.

```

201 # Експеримент Г, Д
202 length_gd = 50000
203 half = length_gd // 2
204
205 # Послідовність Г – однакова кількість символів "a" і "b" у випадковому порядку
206 sequence_g_list = ["a"] * half + ["b"] * half
207 random.seed(123)
208 random.shuffle(sequence_g_list)
209 sequence_g = "".join(sequence_g_list)
210
211 # Послідовність Д – періодична структура "абабаб..."
212 sequence_d = "ab" * half
213
214
215 # Обчислення H1 для послідовностей Г і Д
216 counts_g, h1_g = calculate_h1(sequence_g)
217 counts_d, h1_d = calculate_h1(sequence_d)
218
219 # Обчислення H2 для біграм, що перетинаються
220 _, h2_g_overlap, _ = calculate_h2(sequence_g, 1)
221 _, h2_d_overlap, _ = calculate_h2(sequence_d, 1)
222 # Обчислення H2 для біграм, що не перетинаються
223 _, h2_g_no_overlap, _ = calculate_h2(sequence_g, 2)
224 _, h2_d_no_overlap, _ = calculate_h2(sequence_d, 2)
225
226
227 # Виведення результатів експерименту Г, Д
228 print("\n--- Експеримент Г, Д ---")
229 print("Г – випадковий порядок")
230 print("H1 =", round(h1_g, 5))
231 print("H2 з перетином =", round(h2_g_overlap, 5))
232 print("H2 без перетину =", round(h2_g_no_overlap, 5))
233
234 print("\nД – періодична послідовність")
235 print("H1 =", round(h1_d, 5))
236 print("H2 з перетином =", round(h2_d_overlap, 5))
237 print("H2 без перетину =", round(h2_d_no_overlap, 5))

```

```

--- Експеримент Г, Д ---
Г – випадковий порядок
H1 = 1.0
H2 з перетином = 1.0
H2 без перетину = 0.99997

Д – періодична послідовність
H1 = 1.0
H2 з перетином = 0.5
H2 без перетину = 0.0

```

Порівнюю результати з прогнозом та пояснюю їх:

- чому тексти з однаковими частотами окремих символів можуть мати однакові або близькі значення  $H_1$ ;

$H_1$  залежить лише від частот окремих символів і не враховує порядок їх розташування. У послідовностях Г і Д символи а та б мають однакові частоти 0,5, тому в обох випадках отримано  $H_1=1$

- чому їхні значення  $H_2$  можуть відрізнитися;

$H_2$  враховує частоти пар сусідніх символів. У випадковій послідовності Г утворюються різні біграми, а в періодичній послідовності Д структура значно більш регулярна. Тому при однаковому  $H_1$  значення  $H_2$  можуть суттєво відрізнитися

- яку інформацію про джерело дозволяє врахувати модель біграм порівняно з моделлю незалежних символів.

Модель біграм враховує залежності між сусідніми символами та порядок їх появи. На відміну від моделі  $H_1$ , яка розглядає символи незалежно,  $H_2$  дозволяє виявити регулярність, повторюваність і передбачуваність послідовності

## 5. Експериментальна оцінка ентропії джерела

За допомогою програми **CoolPinkProgram** оцініть значення

$H^{(10)}$ ,  $H^{(20)}$ ,  $H^{(30)}$ .

Для оцінювання кожного значення виконайте не менше 50 експериментів.

Порівняйте отримані значення з  $H_1$  та  $H_2$ , обчисленими власною програмою.

Результати подайте в одній порівняльній таблиці:

| Оцінка     | Отримане значення |
|------------|-------------------|
| $H_1$      | 4,377             |
| $H_2$      | 3,99692           |
| $H^{(10)}$ | 2,567228          |
| $H^{(20)}$ | 2,692795          |
| $H^{(30)}$ | 1,544514          |

Для таблиці та порівняння були взяті середні значення інтервалу.

Произвольная часть текста:  
нибудь\_страны\_могут\_утверждать\_что\_договоры\_не\_имеют\_никакого\_значения\_но\_в

Использованные буквы:

Порядок n-граммы:  
5 символов  
10 символов  
15 символов  
20 символов  
25 символов  
30 символов  
35 символов  
40 символов  
45 символов  
50 символов

Введенный символ: р

Символ по счету: 1

Номер эксперимента: 50

Неравенство для энтропии:  
 $2.28886850083168 < H < 2.84558812981002$

Двоичная таблица угаданных символов:

|                                  |   |
|----------------------------------|---|
| 00100000000000000000000000000000 | ▲ |
| 10000000000000000000000000000000 | ■ |
| 01000000000000000000000000000000 |   |
| 00000000000001000000000000000000 |   |
| 10000000000000000000000000000000 | ▼ |

Поле ввода символов:  
р

Продолжить Другой

Вероятности:

|              |
|--------------|
| q[1] = 0.48  |
| q[2] = 0.1   |
| q[3] = 0.06  |
| q[4] = 0.04  |
| q[5] = 0     |
| q[6] = 0     |
| q[7] = 0     |
| q[8] = 0     |
| q[9] = 0.04  |
| q[10] = 0    |
| q[11] = 0.02 |
| q[12] = 0    |
| q[13] = 0.02 |
| q[14] = 0.02 |
| q[15] = 0.06 |
| q[16] = 0    |
| q[17] = 0    |
| q[18] = 0    |
| q[19] = 0    |
| q[20] = 0    |
| q[21] = 0.02 |
| q[22] = 0    |
| q[23] = 0    |
| q[24] = 0    |
| q[25] = 0    |
| q[26] = 0.02 |
| q[27] = 0.02 |
| q[28] = 0    |
| q[29] = 0.06 |
| q[30] = 0.02 |
| q[31] = 0.02 |
| q[32] = 0    |

Строка состояния:  
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

Произвольная часть текста:  
подлинное\_существование\_добра\_и\_зла\_временами\_люди\_могут\_ошибаться\_в\_опред

Использованные буквы:

Порядок n-граммы:  
5 символов  
10 символов  
15 символов  
20 символов  
25 символов  
30 символов  
35 символов  
40 символов  
45 символов  
50 символов

Введенный символ: в

Символ по счету: 2

Номер эксперимента: 50

Неравенство для энтропии:  
 $2.29276679121529 < H < 3.09282218990196$

Двоичная таблица угаданных символов:

|                                  |   |
|----------------------------------|---|
| 10000000000000000000000000000000 | ▲ |
| 00100000000000000000000000000000 | ■ |
| 00000001000000000000000000000000 |   |
| 01000000000000000000000000000000 |   |
| 00001000000000000000000000000000 | ▼ |

Поле ввода символов:  
в

Продолжить Другой

Вероятности:

|              |
|--------------|
| q[1] = 0.46  |
| q[2] = 0.12  |
| q[3] = 0.04  |
| q[4] = 0     |
| q[5] = 0.04  |
| q[6] = 0.04  |
| q[7] = 0     |
| q[8] = 0.02  |
| q[9] = 0.02  |
| q[10] = 0.02 |
| q[11] = 0    |
| q[12] = 0.02 |
| q[13] = 0.02 |
| q[14] = 0    |
| q[15] = 0    |
| q[16] = 0.02 |
| q[17] = 0.02 |
| q[18] = 0    |
| q[19] = 0    |
| q[20] = 0.02 |
| q[21] = 0.02 |
| q[22] = 0.04 |
| q[23] = 0    |
| q[24] = 0.02 |
| q[25] = 0.02 |
| q[26] = 0.02 |
| q[27] = 0.02 |
| q[28] = 0    |
| q[29] = 0    |
| q[30] = 0    |
| q[31] = 0    |
| q[32] = 0    |

Строка состояния:  
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

Произвольная часть текста:  
 дь\_возьмет\_на\_себя\_труд\_сравнить\_учения\_о\_морали\_господствовавшие\_скажем\_в\_

Использованные буквы:  
 е,

Порядок n-граммы:  
 5 символов  
 10 символов  
 15 символов  
 20 символов  
 25 символов  
 30 символов  
 35 символов  
 40 символов  
 45 символов  
 50 символов

Введенный символ: и

Символ по счету: 2

Номер эксперимента: 50

Неравенство для энтропии:  
 $1.34261592579985 < H < 1.74641243869299$

Двоичная таблица угаданных символов:  
 1000000000000000000000000000000000  
 1000000000000000000000000000000000  
 0000000000000000010000000000000000  
 1000000000000000000000000000000000  
 1000000000000000000000000000000000

Поле ввода символов:  
 и

Продолжить Другой

Вероятности:

|       |        |
|-------|--------|
| q[1]  | = 0.72 |
| q[2]  | = 0.04 |
| q[3]  | = 0    |
| q[4]  | = 0.02 |
| q[5]  | = 0    |
| q[6]  | = 0.02 |
| q[7]  | = 0    |
| q[8]  | = 0.02 |
| q[9]  | = 0    |
| q[10] | = 0    |
| q[11] | = 0    |
| q[12] | = 0    |
| q[13] | = 0    |
| q[14] | = 0    |
| q[15] | = 0    |
| q[16] | = 0.06 |
| q[17] | = 0.02 |
| q[18] | = 0.02 |
| q[19] | = 0    |
| q[20] | = 0    |
| q[21] | = 0    |
| q[22] | = 0    |
| q[23] | = 0.02 |
| q[24] | = 0    |
| q[25] | = 0    |
| q[26] | = 0.04 |
| q[27] | = 0    |
| q[28] | = 0.02 |
| q[29] | = 0    |
| q[30] | = 0    |
| q[31] | = 0    |
| q[32] | = 0    |

Строка состояния:  
 Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

Проаналізуйте отримані результати та поясніть:

1. чому наведені оцінки ентропії не повинні обов'язково збігатися;

Наведені оцінки враховують різний обсяг контексту та різні типи залежностей у тексті:

- $H_1$  спирається виключно на частоту появи окремих символів, розглядаючи їх як незалежні події.
- $H_2$  урахує взаємозв'язок лише між двома сусідніми літерами (біграмами).
- Експериментальні оцінки  $H^{(10)}$ ,  $H^{(20)}$  та  $H^{(30)}$  відображають умовну ентропію за наявності контексту довжиною  $N-1$ . Оскільки людина під час експерименту задіює складну мовну модель (знання граматики, орфографії, синтаксису та змісту), ці оцінки враховують набагато глибші зв'язки, які недоступні простим статистичним моделям.

2. які статистичні залежності враховуються при визначенні  $H_1$  та  $H_2$ ;

- При  $H_1$ : Враховуються монограмні залежності (одновимірний розподіл ймовірностей  $p_i$ ). Символи вважаються незалежними один від одного, враховується лише нерівномірність частот окремих букв алфавіту.

- При  $H_2$ : Ураховуються біграмні (двовимірні) залежності (умовні ймовірності  $p_{ij}$ ). Враховується ймовірність появи певної літери після попередньої (наприклад, висока ймовірність появи «о» після «т» або «ь» після «с»).

3. чому врахування довших залежностей між символами може змінювати оцінку ентропії природної мови;

Природна мова володіє високою надлишковістю. Окремі букви пов'язуються не лише у пари, а й у корені, слова та цілі фрази. Чим довший контекст відомий, тим сильніше правила мови та зміст тексту обмежують вибір наступного символу, тим самим суттєво знижуючи невизначеність (ентропію). На довжині контексту у 20–30 символів людині часто стає зрозумілим конкретне слово або граматична конструкція, завдяки чому ймовірність вгадати наступну літеру різко зростає.

4. яку тенденцію можна спостерігати при переході від  $H_1$  до оцінок, що враховують дедалі довший контекст.

Спостерігається загальна тенденція до зменшення ентропії зі збільшенням довжини контексту:

$H_1 (4,377) > H_2 (3,99692) > H^{(10)} (2,567228) > H^{(30)} (1,544514)$   
 (Невелике відхилення на значення  $H^{(20)} = 2,692795$  обумовлене суб'єктивним фактором та випадковою похибкою під час проведення вгадувань людиною, що є цілком припустимим для даного експерименту).

Підсумковий висновок: Зі збільшенням довжини контексту  $N$  умовна ентропія прямує до свого граничного значення - істинної ентропії мови  $H_\infty$ . Чим більше інформації про контекст нам відомо, тим меншою є невизначеність джерела.

## 6.Оцінювання надлишковості джерела

Використовуючи отримані значення ентропії, оцініть надлишковість російського письмового тексту для досліджених моделей джерела.

Використовуючи отримані значення ентропії, оцінимо надлишковість російського письмового тексту для всіх досліджених моделей джерела за формулою:

$$R = 1 - \frac{H}{H_0}$$

Де  $H_0 = \log_2 m$  — максимальна можлива ентропія для рівноймовірного та незалежного розподілу символів. Для дослідженого російського алфавіту з урахуванням пробілу ( $m = 34$  символи: 33 літери + пробіл):

$$H_0 = \log_2(34) \approx 5,0875 \text{ біт/символ}$$

Розрахунок надлишковості для досліджених моделей джерела:

1. Для монограмної моделі  $H_1 = 4,377$ :

$$R_1 = 1 - (4.377/5.0875) = 1 - 0.8603 = 0.1397 \text{ (13.97\%)}$$

2. Для біграмної моделі  $H_2 = 3,99692$ :

$$R_2 = 1 - (3.99692/5.0875) = 1 - 0.7856 = 0.2144 \text{ (21.44\%)}$$

3. Для моделі з контекстом 10 символів  $H^{(10)} = 2,567228$ :

$$R^{(10)} = 1 - (2.567228/5.0875) = 1 - 0.5046 = 0.4954 \text{ (49.54\%)}$$

4. Для моделі з контекстом 20 символів  $H^{(20)} = 2,692795$ :

$$R^{(20)} = 1 - (2.692795/5.0875) = 1 - 0.5293 = 0.4707 \text{ (47.07\%)}$$

5. Для моделі з контекстом 30 символів  $H^{(30)} = 1,544514$ :

$$R^{(30)} = 1 - (1.544514/5.0875) = 1 - 0.3036 = 0.6964 \text{ (69.64\%)}$$

Порівняйте отримані оцінки та поясніть:

- як змінюється оцінка надлишковості при врахуванні залежностей між символами;

При переході від простих моделей ( $H_1$ ) до моделей із урахуванням довших залежностей ( $H_2 \dots H^{(30)}$ ) оцінка надлишковості суттєво зростає (від 14% до 70%). Це відбувається тому, що врахування контексту зменшує невизначеність (ентропію  $H$ ), а оскільки  $R = 1 - H/H_0$ , зменшення  $H$  безпосередньо збільшує частку надлишкової інформації  $R$ .

- чому природна мова має ненульову надлишковість;

Природна мова має високу ненульову надлишковість завдяки наявності жорстких правил граматики, орфографії, синтаксису, нерівномірності

частот літер та узгодження слів. Завдяки такій «запасній» інформації людина здатна легко розуміти текст із опечатками, відновлювати пошкоджені фрази або вгадувати пропущені букви в словах.

- який зв'язок існує між передбачуваністю наступних символів тексту, ентропією та надлишковістю джерела.

Між цими поняттями існує обернена залежність відносно ентропії та пряма відносно надлишковості:

- Чим вища передбачуваність наступних символів (завдяки довгому контексту чи знанню правил мови), тим нижчою є ентропія  $H$  (менша невизначеність).
- Чим нижча ентропія  $H$ , тим вищою є надлишковість  $R$ . Висока надлишковість означає, що значну частину символів у тексті можна завчасно передбачити або ущільнити без втрати змісту за допомогою методів стиснення даних.

## Аналіз результатів

За результатами виконаних експериментів дайте обґрунтовані відповіді на такі

питання:

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

Природний текст має меншу ентропію через нерівномірний розподіл частот символів та наявність суворих мовних правил.

- У випадковій рівноймовірній послідовності  $V$  використовувалося 33 символи російського алфавіту без пробілу, тому максимальна ентропія становить  $H_{\max} = \log_2 33$  це приблизно 5,04439 біт/символ. Експериментально було отримано  $H_1(V) = 5,04397$ , тобто значення практично максимальне.
- Для природної послідовності  $A$  отримано  $H_1(A) = 4,47421$  біт/символ. Це значення менше, оскільки в природній мові символи мають нерівні ймовірності появи та їх розподіл не є рівномірним.

2. Яку інформацію про джерело враховує  $H_2$ , але не враховує  $H_1$ ?

Оцінка  $H_1$  враховує лише одновимірну статистику (частоту появи окремих ізольованих літер - монограм) і розглядає символи як повністю незалежні події.

Натомість  $H_2$  враховує двовимірну статистику та контекстні залежності першого порядку - ймовірності появи пар сусідніх символів (біграм) та порядок їх прямоування один за одним. Це дозволяє врахувати, які саме літери найчастіше сполучаються між собою в мові (наприклад, біграми «то», «на», «ст», «он»).

3. Чи можуть два тексти мати однакове  $H_1$ , але різне  $H_2$ ? Наведіть приклад із виконаних експериментів.

Так, можуть. Це яскраво продемонстровано в розділі 4 експерименту на послідовностях Г та Д:

- Послідовність Г (випадковий порядок символів «а» та «б») і послідовність Д (періодична структура «abababab...») мають однакову кількість та частоти символів ( $p(a) = p(b) = 0,5$ ), тому їхня монограмна ентропія є повністю однаковою ( $H_1(\Gamma) = H_1(D)$ ).
- Проте значення  $H_2$  для них суттєво відрізняються: у періодичній послідовності Д виникають лише конкретні біграми «ab» та «ba», що робить її структуру повністю передбачуваною та суттєво знижує  $H_2$  порівняно з випадковою послідовністю Г, де утворюються всі можливі комбінації («aa», «ab», «ba», «bb»).

При цьому  $H_1(\Gamma)=H_1(D)=1$ , тоді як для біграм з перетином  $H_2(\Gamma)=1$ , а  $H_2(D)=0,5$ ; для біграм без перетину  $H_2(D)=0$

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.

Вилучення пробілів призвело до дещо більшого значення ентропії як для  $H_1$ , так і для  $H_2$ :

- Для  $H_1$ : з 4,3770 біт/символ (з пробілами) зросла до 4,46029\$ біт/символ (без пробілів).
- Для  $H_2$  (з перетином): з 3,99692 зросла до 4,16862 біт/символ.

Пробіл у тексті є найчастішим символом (його частота становить 16,19%). Він суттєво переважав усі інші літери та робив загальний розподіл ймовірностей більш нерівномірним. Коли пробіл вилучили, залишковий алфавіт з 33 літер став розподілений більш рівномірно щодо відносних частот, що й спричинило зростання невизначеності (ентропії) на один символ.

5. Чому оцінки  $H_2$ , отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Різниця (3,99692 для перетинів проти 3,99658 без перетинів) виникає через різні способи формування вибірки біграм:

- З перетином (зміщення  $\text{step} = 1$ ): формується з усіх можливих пар (1-а+2-а, 2-а+3-я, 3-я+4-та ...), що охоплює майже повний обсяг статистичних даних ( $N-1$  біграм).
- Без перетину (зміщення  $\text{step} = 2$ ): текст розбивається на паралельні пари (1-а+2-а, 3-я+4-та, 5-та+6-та ...), через що вибірка містить удвічі менше біграм ( $N/2$ ).

Оскільки вибірки мають різний обсяг і формуються з різним кроком, підсумкові статистичні частоти окремих пар та незначні крайові ефекти дають мінімальну розбіжність у значеннях.

6. Чому значення  $H_1$ ,  $H_2$ ,  $H^{(10)}$ ,  $H^{(20)}$  та  $H^{(30)}$  відрізняються?

Ці значення відрізняються, тому що кожна наступна оцінка враховує більшу глибину контексту (довжину залежностей) між символами:

- $H_1$  та  $H_2$  враховують лише 1 та 2 сусідні символи за суто статистичними частотами.
- $H^{(10)}$ ,  $H^{(20)}$  та  $H^{(30)}$  задіюють людину та її знання природної мови (синтаксис, морфологія, граматики, семантика).

Чим довшу послідовність  $N-1$  бачить людина, тим сильніше мовні правила обмежують множину можливих наступних літер. Це зменшує невизначеність і робить прогнозування наступного символу точнішим, через що оцінки ентропії послідовно зменшуються від  $H_1 = 4,377$  до  $H^{(30)} = 1,5445$ .

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Найкраще наявність залежностей демонструє експеримент із суб'єктивного вгадування символів ( $H^{(30)}$ ), а також порівняння періодичної (Д) та випадкової (Г) послідовностей:

- На рівні  $H^{(30)}$  довгий контекст у 30 символів дозволив людині знизити невизначеність джерела до 1,5445 біт/символ (падіння невизначеності майже в 3 рази порівняно з  $H_1 = 4,377$ ), що доводить наявність у мові глибоких синтаксичних та змістових зв'язків.
- В експеримент Г–Д при однаковому  $H_1=1$  отримано різні  $H_2$ . Це прямо показує, що різниця виникла саме через порядок і залежність між сусідніми символами.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Отримані результати безпосередньо визначили теоретичну межу стиснення даних :

1. Надлишковість джерела: Проведені розрахунки показали, що надлишковість  $R$  природного російського тексту при контексті 30 символів сягає  $\approx 69,64\%$  ( $R^{(30)}=0,6964$ ).
2. Потенціал стиснення: Це означає, що майже 70% інформації в тексті є структурно надлишковою (повторюваною та передбачуваною).
3. Практичний висновок: Кодери та алгоритми стиснення без втрат, які враховують контекст та нерівномірність частот символів, спроможні ущільнити такий природний текст приблизно в 3 рази (знизивши середню довжину коду з  $H_0 \approx 5,09$  біт/символ до межі ентропії  $H_\infty \approx 1,5$  біт/символ) без жодної втрати початкового змісту.

### **Загальні висновки**

1. Засвоєння базових понять теорії інформації:

У ході виконання лабораторної роботи було практично досліджено поняття ентропії на символ джерела відкритого тексту та його надлишковості. Дослідження показує, що ентропія є мірою невизначеності

джерела: чим більшою є передбачуваність наступного символу, тим нижчою є його ентропія  $H$  і вищою надлишковість  $R$ .

## 2. Вплив розподілу ймовірностей на ентропію ( $H_1$ ):

Експериментально підтверджено, що ентропія залежить від рівномірності розподілу частот символів в алфавіті. Для абсолютно випадкової рівностеймовірної послідовності досягається максимальна ентропія ( $H_0 \approx 5,09$  біт/символ). У природному тексті («Гарри Поттер и Кубок огня») нерівномірний розподіл частот літер знижує ентропію до  $H_1 = 4,377$  біт/символ. Вилучення пробілу (найчастішого символу з частотою 16,19%) робить розподіл літер більш рівномірним, що трохи підвищує ентропію до 4,460 біт/символ.

## 3. Врахування контекстних залежностей ( $H_2$ та експеримент Шеннона):

Збільшення глибини досліджуваного контексту дозволяє виявити статистичні та мовні залежності між символами. Перехід від монограмної моделі ( $H_1 = 4,377$ ) до біграмної ( $H_2 = 3,997$ ) та суб'єктивного оцінювання за методом Шеннона ( $H^{(10)} = 2,567$ ,  $H^{(30)} = 1,545$ ) демонструє загальну тенденцію до зменшення ентропії зі збільшенням довжини контексту. При довжині контексту в 30 символів людина, спираючись на знання граматики та синтаксису, здатна передбачати наступні літери з високою точністю.

## 4. Оцінка надлишковості та потенціал стиснення:

Розрахунок надлишковості показав її зростання від 13,97% (для  $H_1$ ) до 69,64% (для  $H^{(30)}$ ). Висока надлишковість природної мови ( $\approx 70\%$ ) забезпечує стійкість тексту до завад та опечаток, а з точки зору криптографії та стиснення даних вказує на теоретичну можливість ущільнення природного тексту приблизно в 3 рази без жодної втрати інформації.