

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

З дисципліни

"КРИПТОГРАФІЯ"

"Експериментальна оцінка ентропії на символ джерела відкритого тексту"

Виконали:

Студенти 3-го курсу, групи ФБ-42

Кмець М.І. та Гатченко Я.Р.

Перевірила: Селюх Поліна Валентинівна

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

1. Підготовка тексту


Оберіть довільний текст російською мовою обсягом не менше 1 МБ.

Виконайте попередню обробку тексту відповідно до таких правил:

- усі літери привести до нижнього регістру;
- символи, що не належать до заданого алфавіту, вилучити або замінити пробілами;
- послідовності пробілів та інших розділових символів трактувати як один пробіл;
- для обчислень без пробілів вилучити всі пробіли з попередньо нормалізованого тексту.

Зафіксуйте правила попередньої обробки, використані у вашій програмі.

Було обрано наступний файл:



Зробимо попередню обробку:

```
1 import re
2
3 def preprocess_text(text: str, alphabet: str) -> tuple[str, str]:
4     text = text.lower()
5     alphabet = alphabet.lower()
6
7     escaped_alphabet = re.escape(alphabet)
8     pattern = f"^[{escaped_alphabet}]"
9     text_with_spaces = re.sub(pattern, ' ', text)
10
11     normalized_text = re.sub(r'\s+', ' ', text_with_spaces).strip()
12     text_without_spaces = normalized_text.replace(' ', '')
13
14     return normalized_text, text_without_spaces
15
16 if __name__ == "__main__":
17     input_file = "Zavgorodnyaya_Tayna-treh-zerkal.txt"
18     output_file_spaces = "output_with_spaces.txt"
19     output_file_nospaces = "output_without_spaces.txt"
20     russian_alphabet = "абвгдежзийклмнопрстуфхцчщъьъьюя"
21
```

```

22     try:
23         with open(input_file, 'r', encoding='utf-8') as f:
24             text_from_file = f.read()
25
26         lines_before = len(text_from_file.splitlines())
27         chars_before = len(text_from_file)
28
29         norm_text, no_space_text = preprocess_text(text_from_file, russian_alphabet)
30
31         lines_after_norm = 1 if norm_text else 0
32         chars_after_norm = len(norm_text)
33
34         lines_after_nospace = 1 if no_space_text else 0
35         chars_after_nospace = len(no_space_text)
36
37         with open(output_file_spaces, 'w', encoding='utf-8') as f:
38             f.write(norm_text + "\n")
39
40         with open(output_file_nospaces, 'w', encoding='utf-8') as f:
41             f.write(no_space_text + "\n")
42
43         print(f"Кількість символів до нормалізації: {chars_before}")
44         print(f"Кількість символів після нормалізації: {chars_after_norm}")
45         print(f"Кількість символів після нормалізації та без пробілів: {chars_after_nospace}")
46
47     except FileNotFoundError:
48         print(f"Помилка: файл '{input_file}' не знайдено.")

```

Алфавіт 33 літери російської мови

Правила обробки:

- Всі літери приведені в нижній регістр
- Всі символи поза алфавітом замінюються на пробіли
- Послідовність з пробілів замінюється на один пробіл
- Створення нормалізованого файлу з текстом без пробілів

2. Розрахунок статистичних характеристик тексту

Підрахунок частот символів та H_1 за їх частотами

```
1 import math
2 from collections import Counter
3
4
5 def analyze_monograms(text: str) -> dict:
6     n_chars = len(text)
7     if n_chars == 0:
8         return {}
9
10    # Підрахунок частот символів
11    char_counts = Counter(text)
12    char_freqs = {
13        char: count / n_chars for char, count in char_counts.items()
14    }
15
16    # Обчислення H1
17    h1 = -sum(p * math.log2(p) for p in char_freqs.values() if p > 0)
18
19    return {
20        "length": n_chars,
21        "char_freqs": char_freqs,
22        "h1": h1,
23    }
24
25
26 def print_top_chars(freq_dict: dict, title: str, top_n: int = 5):
27
28     sorted_items = sorted(
29         freq_dict.items(), key=lambda x: x[1], reverse=True
30     )[:top_n]
31     print(f"--- {title} (Top-{top_n}) ---")
32     for item, freq in sorted_items:
33         display_item = item.replace(" ", "_")
34         print(f" '{display_item}': (freq:.6f) ({freq * 100:.2f}%)")
35
36
37 def run_monogram_analysis(file_spaces: str, file_nospaces: str):
38     files = [
39         ("Текст З ПРОБІЛАМИ", file_spaces),
40         ("Текст БЕЗ ПРОБІЛІВ", file_nospaces),
41     ]
42
43     for label, filepath in files:
44         try:
45             with open(filepath, "r", encoding="utf-8") as f:
46                 text = f.read().strip()
47         except FileNotFoundError:
48             print(f"Помилка: Файл '{filepath}' не знайдено.\n")
49             continue
50
51         res = analyze_monograms(text)
52
53         print(label)
54         print(f"Загальна кількість символів: {res['length']}")
55         print(f"Ентропія H1 (на символ): {res['h1']:.6f} біт/символ\n")
56
57         print_top_chars(res["char_freqs"], "Символи")
58         print("\n")
59
60
61 if __name__ == "__main__":
62     run_monogram_analysis("output_with_spaces.txt", "output_without_spaces.txt")
```

```
Текст З ПРОБІЛАМИ
Загальна кількість символів: 698828
Ентропія H1 (на символ): 4.363778 біт/символ
```

```
--- Символи (Top-5) ---
' ': 0.164487 (16.45%)
'o': 0.094829 (9.48%)
'a': 0.074828 (7.48%)
'e': 0.065536 (6.55%)
'm': 0.053858 (5.31%)
```

```
Текст БЕЗ ПРОБІЛІВ
Загальна кількість символів: 577189
Ентропія H1 (на символ): 4.458983 біт/символ
```

```
--- Символи (Top-5) ---
'o': 0.112542 (11.25%)
'a': 0.089568 (8.96%)
'e': 0.078439 (7.84%)
'm': 0.063516 (6.35%)
'i': 0.063451 (6.35%)
```

Підрахунок біграм та H_2 :

```
1 import math
2 from collections import Counter
3
4
5 def analyze_bigrams(text: str) -> dict:
6
7     n_chars = len(text)
8     if n_chars < 2:
9         return {}
10
11     overlap_bigrams = [text[i : i + 2] for i in range(n_chars - 1)]
12     n_overlap = len(overlap_bigrams)
13     overlap_counts = Counter(overlap_bigrams)
14     overlap_freqs = {
15         (bg: count / n_overlap for bg, count in overlap_counts.items())
16         if n_overlap > 0
17         else {}
18     }
19
20     h2_overlap = (
21         -0.5
22         + sum(p * math.log2(p) for p in overlap_freqs.values() if p > 0)
23         if overlap_freqs
24         else 0.0
25     )
26
27     non_overlap_bigrams = [
28         text[i : i + 2]
29         for i in range(0, n_chars - 1, 2)
30         if len(text[i : i + 2]) == 2
31     ]
32     n_non_overlap = len(non_overlap_bigrams)
33     non_overlap_counts = Counter(non_overlap_bigrams)
34     non_overlap_freqs = {
35         (bg: count / n_non_overlap for bg, count in non_overlap_counts.items())
36         if n_non_overlap > 0
37         else {}
38     }
39
40     h2_non_overlap = (
41         -0.5
42         + sum(p * math.log2(p) for p in non_overlap_freqs.values() if p > 0)
43         if non_overlap_freqs
44         else 0.0
45     )
46
47     return {
48         "length": n_chars,
49         "overlap_freqs": overlap_freqs,
50         "h2_overlap": h2_overlap,
51         "n_overlap": n_overlap,
52         "non_overlap_freqs": non_overlap_freqs,
53         "h2_non_overlap": h2_non_overlap,
54         "n_non_overlap": n_non_overlap,
55     }
56
```

```
58 def print_top_bigrams(freq_dict: dict, title: str, top_n: int = 5):
59
60     sorted_items = sorted(
61         freq_dict.items(), key=lambda x: x[1], reverse=True
62     )[:top_n]
63     print(f"--- {title} (Top-{top_n}) ---")
64     for item, freq in sorted_items:
65         display_item = item.replace(" ", "_")
66         print(f" '{display_item}': {freq:.6f} ({freq * 100:.2f}%)")
67
68
69 def run_bigram_analysis(file_spaces: str, file_nospaces: str):
70
71     files = [
72         (f"Текст з ПРОБІЛАМИ", file_spaces),
73         (f"Текст БЕЗ ПРОБІЛІВ", file_nospaces),
74     ]
75
76     for label, filepath in files:
77         try:
78             with open(filepath, "r", encoding="utf-8") as f:
79                 text = f.read().strip()
80         except FileNotFoundError:
81             print(f"Помилка: файл '{filepath}' не знайдено.\n")
82             continue
83
84         res = analyze_bigrams(text)
85
86         print(label)
87
88         print(f"Загальна кількість символів у тексті: {res['length']}\n")
89
90         print(
91             f"Біграми з ПЕРЕТНЮМ | Всього біграм: {res['n_overlap']}"
92         )
93         print(
94             f"Ентропія H2 (з перетнями): {res['h2_overlap']:.6f} біт/символ"
95         )
96         print_top_bigrams(res["overlap_freqs"], "Біграми з перетнями")
97         print()
98
99         print(
100             f"Біграми БЕЗ ПЕРЕТНЮ | Всього біграм: {res['n_non_overlap']}"
101         )
102         print(
103             f"Ентропія H2 (без перетнів): {res['h2_non_overlap']:.6f} біт/символ"
104         )
105         print_top_bigrams(res["non_overlap_freqs"], "Біграми без перетнів")
106         print("\n")
107
108
109 if __name__ == "__main__":
110     run_bigram_analysis("output_with_spaces.txt", "output_without_spaces.txt")
```

```

Текст З ПРОБІЛАМИ
Загальна кількість символів у тексті: 690828

Біграми З ПЕРЕТИНОМ | Всього біграм: 690827
Ентропія H2 (з перетином): 3.943959 біт/символ
--- Біграми з перетином (Тор-5) ---
'a_': 0.023488 (2.35%)
'o_': 0.021350 (2.13%)
'_п': 0.017909 (1.79%)
'e_': 0.016807 (1.68%)
'и_': 0.015985 (1.60%)

Біграми БЕЗ ПЕРЕТИНУ | Всього біграм: 345414
Ентропія H2 (без перетину): 3.943773 біт/символ
--- Біграми без перетину (Тор-5) ---
'a_': 0.023398 (2.34%)
'o_': 0.021282 (2.13%)
'_п': 0.017727 (1.77%)
'e_': 0.016997 (1.70%)
'и_': 0.015992 (1.60%)

Текст БЕЗ ПРОБІЛІВ
Загальна кількість символів у тексті: 577189

Біграми З ПЕРЕТИНОМ | Всього біграм: 577188
Ентропія H2 (з перетином): 4.123943 біт/символ
--- Біграми з перетином (Тор-5) ---
'то': 0.015945 (1.59%)
'ла': 0.014543 (1.45%)
'по': 0.012779 (1.28%)
'на': 0.012481 (1.25%)
'ст': 0.011615 (1.16%)

Біграми БЕЗ ПЕРЕТИНУ | Всього біграм: 288594
Ентропія H2 (без перетину): 4.123930 біт/символ
--- Біграми без перетину (Тор-5) ---
'то': 0.015953 (1.60%)
'ла': 0.014345 (1.43%)
'по': 0.012738 (1.27%)
'на': 0.012533 (1.25%)
'не': 0.011625 (1.16%)

```

Аналіз отриманих результатів:

Найчастішими символами тексту з пробілами є пробіл (16,45%), «о» (9,48%), «а» (7,48%), «е» (6,53%), «и» (5,31%) — розподіл типовий для російської мови, де голосні «о», «а», «е» є найуживанішими.

H1 з пробілами = 4,363770 біт/символ, без пробілів = 4,458983 біт/символ: вилучення пробілу (дуже частого й тому малоінформативного символу) підвищує ентропію на символ, оскільки після його виключення розподіл частот решти літер стає відносно рівномірнішим.

Для біграм спостерігається та сама тенденція: H2 (з пробілами, з перетином) = 3,943959 біт/символ проти H2 (без пробілів, з перетином) = 4,123943 біт/символ. Пробіл бере участь у дуже частих і передбачуваних біграмах («а_», «о_», «_п»), тому його наявність знижує ентропію.

Порівняння H_1 і H_2 в межах одного тексту (з пробілами) показує $H_2 < H_1$ ($3,94 < 4,36$), що підтверджує наявність міжсимвольних залежностей: знання попереднього символу зменшує невизначеність наступного.

Значення H_2 , обчислені за біграмами, що перетинаються і що не перетинаються, практично збігаються: $3,943959$ проти $3,943773$ (з пробілами) та $4,123943$ проти $4,123930$ (без пробілів). Це означає, що при достатньо великому обсязі тексту (сотні тисяч символів) обидва способи дають узгоджену оцінку. Спосіб із перетином використовує вдвічі більше біграм (690827 проти 345414), тобто вдвічі більше статистичних даних, і тому теоретично є трохи надійнішим (менша дисперсія оцінки), хоча в даному випадку різниця виявилась мінімальною завдяки великому обсягу тексту.

3. Дослідження впливу розподілу символів на ентропію

Очікуваний прогноз:

$$B < A < V$$

Обґрунтування прогнозу:

Послідовність B складається з повторення одного й того самого символу, тому ймовірність цього символу дорівнює 1 , а всіх інших — 0 . За визначенням ентропії, для виродженого розподілу $H(Z)=0$, отже очікуване $H_1(B)=0$.

Послідовність A — фрагмент природного тексту, в якому літери зустрічаються з різними (нерівними) частотами, тому очікується $0 < H_1(A) < \log_2(m)$.

Послідовність V формується рівноймовірним і незалежним вибором символів алфавіту, тому її ентропія має наближатися до максимально можливого значення $H_0 = \log_2(m)$.

Отже, очікуваний порядок зростання: $B (=0) < A$ (природний текст) $< V$ (рівноймовірна, $\approx \log_2(m)$).

Код:

```

3.entropy.py > ...
1  import math
2  import random
3  from collections import Counter
4
5
6  def calculate_h1(text: str) -> float:
7
8      n = len(text)
9      if n == 0:
10         return 0.0
11     freqs = Counter(text)
12     return -sum((count / n) * math.log2(count / n) for count in freqs.values())
13
14
15  def run_experiment(input_filepath: str):
16
17      try:
18         with open(input_filepath, "r", encoding="utf-8") as f:
19             seq_a = f.read().strip()
20     except FileNotFoundError:
21         print(f"Файл {input_filepath} не знайдено.")
22         return
23
24     n = len(seq_a)
25     alphabet = "абвгдеёжзийклмнопрстуфхцчщъыьэюя"
26     m = len(alphabet)
27
28     seq_b = alphabet[0] * n
29
30     random.seed(42)
31     seq_v = "".join(random.choice(alphabet) for _ in range(n))
32
33     # Обчислення H1
34     h1_a = calculate_h1(seq_a)
35     h1_b = calculate_h1(seq_b)
36     h1_v = calculate_h1(seq_v)
37     h1_max = math.log2(m)
38
39     print(f"Довжина послідовностей (N): {n} символів")
40     print(f"Потужність алфавіту (m): {m} символів")
41     print(f"Теоретичний максимум H_max = log2({m}): {h1_max:.6f} біт/символ\n")
42
43     print(f"1. Послідовність Б (один символ): H1 = {h1_b:.6f} біт/символ")
44     print(f"2. Послідовність А (природний текст): H1 = {h1_a:.6f} біт/символ")
45     print(f"3. Послідовність В (рівномовірні): H1 = {h1_v:.6f} біт/символ")
46
47
48  if __name__ == "__main__":
49
50     run_experiment("output_without_spaces.txt")

```

Результат:

```

Довжина послідовностей (N): 690828 символів
Потужність алфавіту (m): 33 символів
Теоретичний максимум H_max = log2(33): 5.044394 біт/символ

1. Послідовність Б (один символ): H1 = -0.000000 біт/символ
2. Послідовність А (природний текст): H1 = 4.363770 біт/символ
3. Послідовність В (рівномовірні): H1 = 5.044366 біт/символ

```

Довжина послідовностей: $N=690828$ символів; потужність алфавіту $m=33$;
теоретичний максимум $H_0=\log_2(33)=5,044394$ біт/символ.

1) Послідовність Б (один символ, повторений N разів): $H_1=0,000000$ біт/символ.

2) Послідовність А (природний текст): $H_1=4,363770$ біт/символ.

3) Послідовність В (рівномовірна випадкова послідовність тих самих 33 символів):
 $H_1=5,044366$ біт/символ, тобто практично збігається з теоретичним максимумом

$H_0=5,044394$ (мізерне відхилення в п'ятому знаку зумовлене статистичною похибкою генератора псевдовипадкових чисел при скінченному N).

Отримані результати повністю підтверджують прогноз: $0 = H_1(B) < H_1(A) = 4,363770 < H_1(B) = 5,044366 \approx H_0 = 5,044394$. Це наочно демонструє, що ентропія джерела визначається формою (нерівномірністю) розподілу ймовірностей символів: чим “зосередженіший” розподіл (аж до виродженого), тим менша невизначеність (менша ентропія), а чим ближче розподіл до рівноймовірного — тим ближче ентропія до свого максимуму.

4. Дослідження залежностей між символами

Прогноз:

1) Оскільки послідовності Γ і D побудовані на одному алфавіті $\{a,b\}$ з однаковими (рівними) частотами символів (по 5000 разів кожного), значення H_1 для обох послідовностей мають збігатися і дорівнювати максимально можливому для двосимвольного алфавіту: $H_1 = \log_2(2) = 1$ біт/символ, оскільки H_1 враховує лише частоти окремих символів і не залежить від їхнього взаємного розташування.

2) Значення H_2 для Γ і D мають суттєво відрізнитися, оскільки H_2 враховує залежності між сусідніми символами (спільний розподіл біграм), а розташування символів у Γ (випадкове) і D (сувора періодичність) принципово різне.

3) Менше значення H_2 очікується для послідовності D , оскільки в періодичній структурі « $abab\dots$ » наступний символ практично однозначно визначається попереднім (зустрічаються лише біграми « ab » і « ba »), тобто невизначеність мінімальна; у Γ символи йдуть у випадковому порядку, тому всі 4 можливі біграми (« aa », « ab », « ba », « bb ») зустрічаються майже з однаковою ймовірністю, і $H_2(\Gamma)$ має бути близьким до 1 біт/символ.

4) Для Γ значення H_2 , обчислені за біграмами з перетином і без перетину, мають бути близькими, оскільки порядок символів випадковий і немає жорсткої періодичної структури. Для D , навпаки, значення можуть суттєво відрізнитися: при зсуві на 2 символи (крок дорівнює довжині періоду) послідовність неперетинних біграм для « $abab\dots$ » складається із самих однакових біграм (завжди « ab » або завжди « ba », залежно від фази), тобто розподіл вироджується і H_2 (без перетину) прямує до 0.

```

4.dependence.py > ...
1  import random
2  from collections import Counter
3  from math import log2
4
5  PATTERN = "ab"    # періодичний фрагмент
6  N = 10000        # довжина послідовностей
7  SEED = 42
8
9
10 def entropy(counter):
11     total = sum(counter.values())
12     return -sum((c / total) * log2(c / total) for c in counter.values()) + 0.0
13
14
15 def bigrams(seq, overlapping=True):
16     step = 1 if overlapping else 2
17     return [seq[i:i + 2] for i in range(0, len(seq) - 1, step)]
18
19
20 def h1(seq):
21     return entropy(Counter(seq))
22
23
24 def h2(seq, overlapping=True):
25     return entropy(Counter(bigrams(seq, overlapping))) / 2
26
27
28 random.seed(SEED)
29 D = (PATTERN * (N // len(PATTERN) + 1))[:N]    # періодична
30 letters = list(D)
31 random.shuffle(letters)
32 G = "".join(letters)                            # випадкова (ті самі частоти)
33
34 for name, s in (("Г", G), ("Д", D)):
35     print(f"Послідовність {name}: довжина = {len(s)}, "
36           f"H1 = {h1(s):.4f}, "
37           f"H2 (з перетином) = {h2(s, True):.4f}, "
38           f"H2 (без перетину) = {h2(s, False):.4f}")

```

Результат:

```

Послідовність Г: довжина = 10000, H1 = 1.0000, H2 (з перетином) = 1.0000, H2 (без перетину) = 0.9996
Послідовність Д: довжина = 10000, H1 = 1.0000, H2 (з перетином) = 0.5000, H2 (без перетину) = 0.0000

```

Довжина послідовностей: N=10000 символів; алфавіт {a,b}.

Послідовність Г (випадковий порядок): H1=1,0000, H2 (з перетином)=1,0000, H2 (без перетину)=0,9996.

Послідовність Д (періодична «abab...»): H1=1,0000, H2 (з перетином)=0,5000, H2 (без перетину)=0,0000.

Отримані результати повністю узгоджуються з прогнозом. H1 в обох послідовностях однакове (1,0000 біт/символ), оскільки частоти символів «a» та «b» в Г і Д однакові (по 50%), а H1 не враховує порядок символів. H2 натомість суттєво відрізняється: для Г $H2 \approx 1,0$ (максимально можливе значення для алфавіту з двох

Для D значення H_2 з перетином (0,5000) і без перетину (0,0000) кардинально різняться: при зсуві на 2 символи (крок дорівнює довжині періоду «ab») усі отримані неперетинні біграми виявляються однаковими, тому їхній розподіл вироджений і $H_2=0$. Для Γ відмінність між двома способами мінімальна (1,0000 проти 0,9996), оскільки випадковий порядок символів не створює залежності від кроку вибірки біграм.

5. Експериментальна оцінка ентропії джерела

[illegible]

Оцінка $H^{(20)}$:

Произвольная часть текста:
мы_подыскиваем_пояс

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить

Другой

Неравенство для энтропии:
1.87617310670393< H < 2.52462408236634

Двоичная таблица угаданных символов:
10000000000000000000000000000000
01000000000000000000000000000000
00100000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
.....

Вероятности:

q[1] = 0.6
q[2] = 0.02
q[3] = 0.06
q[4] = 0.02
q[5] = 0
q[6] = 0.02
q[7] = 0.04
q[8] = 0
q[9] = 0
q[10] = 0
q[11] = 0
q[12] = 0.02
q[13] = 0.02
q[14] = 0
q[15] = 0.02
q[16] = 0.04
q[17] = 0.02
q[18] = 0
q[19] = 0.02
q[20] = 0
q[21] = 0.02
q[22] = 0
q[23] = 0
q[24] = 0
q[25] = 0
q[26] = 0.02
q[27] = 0.02
q[28] = 0
q[29] = 0
q[30] = 0.02
q[31] = 0
q[32] = 0.02

Строка состояния:

Оцінка $H^{(30)}$:

Лабораторная работа №1

X

Произвольная часть текста:
ное_как_образованные_так_и_не

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить

Другой

Неравенство для энтропии:
1.36367172424205< H < 2.02622721260073

Двоичная таблица угаданных символов:
00001000000000000000000000000000
10000000000000000000000000000000
00010000000000000000000000000000
01000000000000000000000000000000
00000000000010000000000000000000
.....

Вероятности:

q[1] = 0.58
q[2] = 0.16
q[3] = 0.04
q[4] = 0.04
q[5] = 0.08
q[6] = 0
q[7] = 0
q[8] = 0
q[9] = 0.04
q[10] = 0
q[11] = 0
q[12] = 0
q[13] = 0.02
q[14] = 0
q[15] = 0
q[16] = 0
q[17] = 0
q[18] = 0
q[19] = 0
q[20] = 0
q[21] = 0.04
q[22] = 0
q[23] = 0
q[24] = 0
q[25] = 0
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0

Строка состояния:

Порівняння отриманих значень:

Оцінка	Отримане значення
--------	-------------------

H_1	4.363770
H_2	3.943959
$H^{(10)}$	$1.706355 < H < 2.404624$
$H^{(20)}$	$1.876173 < H < 2.524624$
$H^{(30)}$	$1.363672 < H < 2.026227$

6. Оцінювання надлишковості джерела:

Надлишковість джерела обчислюється за формулою $R=1-H^\infty/H_0$, де $H_0=\log_2(m)$ — максимально можлива ентропія для алфавіту потужністю m . Приймаємо $H_0=\log_2(33)=5,044394$ біт/символ (та сама потужність алфавіту $m=33$, що спостерігалась експериментально в п.3). Для оцінок $H(10)$, $H(20)$, $H(30)$, заданих у вигляді нерівності (межі "вилка"), надлишковість обчислена за середнім значенням меж:

Оцінка	Значення ентропії, біт/символ	Надлишковість R
H_1	4,363770	0,1349 (13,5%)
H_2	3,943959	0,2182 (21,8%)
$H(10)$	2,055490 (середнє з 1,706355–2,404624)	0,5925 (59,3%)
$H(20)$	2,200399 (середнє з 1,876173–2,524624)	0,5638 (56,4%)
$H(30)$	1,694950 (середнє з 1,363672–2,026227)	0,6640 (66,4%)

Із зростанням довжини врахованого контексту (від одиничних символів через біграми до умовних ентропій $H(10)$, $H(20)$, $H(30)$) оцінка надлишковості загалом зростає: H_1 дає лише близько 13,5%, тоді як моделі з довшим контекстом — від 56% до понад 66%. Це узгоджується з відомим фактом, що реальна надлишковість природних мов є значно вищою за ту, яку дає найпростіша модель незалежних символів, і зазвичай оцінюється дослідниками в діапазоні приблизно 50–75%.

Водночас самі оцінки $H(10)$, $H(20)$ і $H(30)$ (а відповідно і R для них) змінюються немонотонно: $H(20)$ виявилося навіть дещо вищим за $H(10)$, а $H(30)$ — помітно нижчим за обидва. Це прямо узгоджується з теоретичним застереженням методичних вказівок: нерівність, яка використовується для оцінки $H(n)$ через імовірності вгадування символів, не гарантує збіжності лівої й правої меж до єдиної границі при зростанні n , а сама оцінка, як правило, є завищеною через обмежену здатність експериментатора (людини) врахувати всі закономірності мови. Крім того, при відносно невеликій кількості випробувань (50 на кожне n)

оцінка має помітний статистичний розкид, тому отримані значення варто сприймати як орієнтовні межі, а не точні значення H_∞ .

Природна мова має ненульову надлишковість, оскільки її символи не є ані рівноймовірними, ані незалежними: одні літери й сполучення літер зустрічаються значно частіше за інші, а поява кожного наступного символу значною мірою визначається попередніми (граматика, типові сполучення літер, морфологія тощо). Саме ця передбачуваність і є джерелом надлишковості. Що вища передбачуваність наступних символів (тобто що менша умовна ентропія $H(n)$ порівняно з H_0), то вища надлишковість джерела — прямий наслідок формули $R=1-H_\infty/H_0$. Ця сама передбачуваність і дозволяє стискати природні тексти без втрати інформації (наприклад, алгоритмами стиснення на основі статистичних або контекстних моделей мови) приблизно на величину, близьку до оцінки R .

Аналіз результатів:

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

Тому що в природному тексті символи алфавіту зустрічаються з різними (нерівними) ймовірностями, і, крім того, є залежності між сусідніми символами. Ентропія максимальна ($=\log_2(m)$) лише за рівноймовірного й незалежного розподілу; будь-яке відхилення від рівноймовірності зменшує H . У власному експерименті (п.3) це підтверджено: H_1 природного тексту (A)=4,363770 біт/символ помітно менше за H_1 рівноймовірної послідовності (B)=5,044366 біт/символ, яке практично збігається з теоретичним максимумом $H_0=\log_2(33)=5,044394$.

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_2 враховує спільний розподіл пар сусідніх символів (біграм), тобто статистичні залежності (кореляції) між сусідніми символами тексту, тоді як H_1 враховує лише частоти окремих символів і вважає їх незалежними. У власних даних це видно з різниці $H_1=4,363770$ і $H_2=3,943959$ (текст з пробілами): урахування зв'язку між сусідніми літерами (наприклад, типових біграм «а_», «о_», «_п», «то», «ла», «по») зменшує оцінку ентропії, бо частина невизначеності наступного символу вже знімається знанням попереднього.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ? Наведіть приклад із виконаних експериментів.

Так, можуть — це прямо продемонстровано в п.4 роботи послідовностями Г і Д. Обидві побудовані на алфавіті {a,b} з однаковими частотами символів (по 50%),

тому $H_1(\Gamma) = H_1(D) = 1,0000$ біт/символ. Але порядок символів різний: у Γ — випадковий, у D — сувора періодична структура «abab...». Через це $H_2(\Gamma) \approx 1,0000$ (з перетином) / $0,9996$ (без перетину), тоді як $H_2(D) = 0,5000$ (з перетином) і навіть $0,0000$ (без перетину). Це показує, що однакові частоти символів (однакове H_1) не гарантують однакової ентропії вищого порядку — вирішальну роль відіграє взаємне розташування символів.

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.

Вилучення пробілів підвищило обидва значення ентропії: H_1 зросло з $4,363770$ до $4,458983$ біт/символ, а H_2 (з перетином) — з $3,943959$ до $4,123943$ біт/символ. Пояснення в тому, що пробіл — найчастіший символ тексту (16,45% усіх символів з пробілами), тобто дуже передбачуваний і малоінформативний елемент; крім того, біграми, що містять пробіл («a_», «o_», «_p»), мають високу частоту й низьку невизначеність. Коли пробіл вилучається, розподіл частот решти літер стає відносно рівномірнішим, а найпередбачуваніші (пов'язані з пробілом) біграми зникають, тому загальна невизначеність на символ зростає.

5. Чому оцінки H_2 , отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Біграми, що перетинаються, отримуються послідовним зсувом на 1 символ, тому їх удвічі більше (690827 проти 345414 для тексту з пробілами), і вони частково залежні одна від одної, однак дають повнішу статистичну вибірку. Біграми без перетину (зсув на 2) є взаємно незалежнішими спостереженнями, але їх удвічі менше, тож оцінка частот менш стійка. У власних результатах різниця виявилась мінімальною ($3,943959$ проти $3,943773$ та $4,123943$ проти $4,123930$) саме завдяки великому обсягу вихідного тексту. На коротких послідовностях (як у п.4, $N=10000$, алфавіт лише з 2 символів) різниця може бути значно суттєвішою, аж до кардинальної, як це видно для періодичної послідовності D ($0,5000$ проти $0,0000$).

6. Чому значення H_1 , H_2 , $H(10)$, $H(20)$ та $H(30)$ відрізняються?

Кожна з цих величин оцінює ентропію джерела на основі моделі різної глибини контексту: H_1 — модель незалежних символів, H_2 — модель, що враховує залежність символу від одного попереднього (біграми), а $H(10)$, $H(20)$, $H(30)$ — умовні ентропії, які оцінюють невизначеність наступного символу за відомих 9, 19 і 29 попередніх символів відповідно (методом вгадування). Що довший контекст

враховується, то більше закономірностей мови (граматика, типові слова, стійкі словосполучення) використовується для передбачення наступного символу, тому теоретичні оцінки мають зменшуватися зі зростанням n . У власних результатах ця тенденція простежується лише частково (перехід від $H_1=4,36$ і $H_2=3,94$ до значно нижчих $H(10)\approx 1,7-2,4$, $H(20)\approx 1,9-2,5$, $H(30)\approx 1,4-2,0$), хоча самі оцінки $H(n)$ для різних n не монотонні, що пояснюється особливостями експериментального методу вгадування — обмеженою кількістю дослідів і неповнотою знань експериментатора про закономірності мови, про що прямо попереджає нерівність із теоретичної частини роботи.

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Найяскравіше це демонструє експеримент п.4 з послідовностями Г і Д: за абсолютно однакових частот символів (однакового $H_1=1,0000$) значення H_2 відрізняються в рази — від 1,0000 у випадковій Г до 0,0000 у строго періодичній Д. Це наочно доводить, що саме взаємне розташування (залежність) символів, а не лише їхні частоти, визначає ентропію вищого порядку i , відповідно, реальну інформаційну «ціну» символу джерела.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Надлишковість джерела $R=1-H_\infty/H_0$ безпосередньо показує частку «зайвої», передбачуваної інформації в тексті, яку в принципі можна усунути кодуванням без втрати змісту. За нашими оцінками R зростає від приблизно 13,5% (модель H_1) до 56-66% (моделі $H(20)$, $H(30)$): що точніша (глибша) модель джерела використовується для побудови коду, то сильніше теоретично можна стиснути текст. Це є теоретичним підґрунтям роботи реальних алгоритмів стиснення тексту (зокрема з використанням статистичних і контекстних моделей мови), які можуть стискати природний текст на десятки відсотків без втрати інформації.

Висновки:

У межах комп'ютерного практикуму було експериментально досліджено ентропію на символ джерела відкритого (природного) тексту російською мовою на прикладі фрагменту художнього твору обсягом близько 690 тис. символів. Встановлено, що:

1) ентропія природного тексту ($H_1 \approx 4,36$ біт/символ) істотно нижча за теоретичний максимум для алфавіту такого розміру ($H_0 = \log_2(33) \approx 5,04$ біт/символ), що зумовлено нерівномірністю літер;

2) урахування залежностей між сусідніми символами (модель біграм, $H_2 \approx 3,94$ біт/символ) додатково знижує оцінку ентропії порівняно з моделлю незалежних символів, підтверджуючи наявність внутрішньотекстових кореляцій;

3) видалення пробілів із тексту підвищує обидва значення H_1 і H_2 , оскільки пробіл є найчастішим і дуже передбачуваним символом;

4) експеримент із модельними послідовностями Б, А, В підтвердив теоретичну властивість ентропії: вона мінімальна ($=0$) для виродженого розподілу, максимальна — для рівномірного, і проміжна — для реального тексту;

5) експеримент із послідовностями Г і Д показав, що однакові частоти символів не гарантують однакової ентропії вищих порядків — вирішальну роль відіграє порядок (кореляції) символів, що особливо яскраво продемонстровано різницею $H_2(\Gamma) \approx 1,0$ і $H_2(D) = 0,5$ (з перетином) / $0,0$ (без перетину) за однакового $H_1 = 1,0$ для обох послідовностей;

6) експериментальна оцінка умовної ентропії $H(n)$ методом вгадування символів ($n=10, 20, 30$) дала суттєво нижчі значення порівняно з H_1 та H_2 , що ілюструє зростання передбачуваності тексту зі збільшенням урахovanого контексту, хоча сам метод є наближеним і не гарантує монотонної збіжності оцінок при зростанні n ;

7) надлишковість джерела, обчислена для різних моделей (від H_1 до $H(30)$), зростає приблизно з 13,5% до 56-66%, що узгоджується з відомим фактом про значну надлишковість природних мов і пояснює принципову можливість їх стиснення без втрати змісту.

Отже, мету роботи досягнуто: засвоєно поняття ентропії на символ джерела та його надлишковості, набуто практичних навичок оцінки цих величин на прикладі реального тексту різними методами (частотний аналіз символів і біграм, модельні послідовності, експериментальне вгадування символів).