

Міністерство освіти і науки України Національний технічний університет
України «Київський політехнічний інститут імені Ігоря Сікорського»

Навчально-науковий фізико-технічний інститут Кафедра інформаційної
безпеки

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

З дисципліни «КРИПТОГРАФІЯ»

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Виконали:

Студенти 3-го курсу, групи ФБ-42 Собко А. та Фощій Д.

Перевірів:

Селюх Поліна Валентинівна

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

Підготовка тексту

Оберіть довільний текст російською мовою обсягом не менше 1 МБ.

Виконайте попередню обробку тексту відповідно до таких правил:

- усі літери привести до нижнього регістру;
- символи, що не належать до заданого алфавіту, вилучити або замінити пробілами;
- послідовності пробілів та інших розділових символів трактувати як один пробіл;
- для обчислень без пробілів вилучити всі пробіли з попередньо нормалізованого тексту.

Зафіксуйте правила попередньої обробки, використані у вашій програмі.

Ім'я	Дата змінення	Тип	Розмір
 book.txt	20.09.2026 18:20	Текстовий докум...	4 512 КБ

Для дослідження було обрано російськомовний переклад роману Стівена Кінга «Протистояння» (рос. «Противостояние»). Початковий текст було збережено у форматі .txt (кодування UTF-8) у файлі book.txt. Розмір вихідного файлу становить 4 512 КБ, що повністю задовольняє технічну вимогу лабораторної роботи щодо мінімального обсягу вибірки (не менше 1 МБ).

Нормалізацію тексту було проведено за такими правилами:

- Переведено у нижній регістр;
- Літеру «ё» замінено на «е»;
- Усі символи, що не входять до алфавіту [а-я], замінено на пробіл;
- Послідовності з кількох пробілів згорнуто в один пробіл.
- Також було створено другий варіант тексту, з якого повністю видалено пробіли

Короткий опис програмної реалізації

Програмний комплекс реалізовано мовою Python із використанням стандартних бібліотек. Логіку програми архітектурно розділено на кілька функціональних блоків:

1. Зчитування та нормалізація даних Зчитування файлу відбувається у кодуванні UTF-8 із механізмом ігнорування битих байтів, що гарантує стабільність роботи на великих текстах. Початкова обробка включає переведення всіх літер у нижній регістр та заміну літери «ё» на «е». Для глибокої нормалізації застосовується регулярний вираз, який ефективно знаходить усі неалфавітні символи (розділові знаки, цифри, латиницю, спецсимволи) і замінює їхні безперервні послідовності на єдиний пробіл. Додатково програма формує другий масив даних, з якого всі пробіли вилучаються повністю.

2. Збір частотної статистики Для збору статистики створено універсальну функцію, яка проходить по всьому тексту із заданим кроком і передає знайдені комбінації до спеціалізованого лічильника частот. Механізм кроку дозволяє керувати типом вибірки:

- При кроці в 1 символ реалізується модель «вікна, що ковзає» — програма генерує біграми, що перетинаються.
- При кроці у 2 символи текст розбивається на суворо фіксовані незалежні пари — генеруються біграми без перетину.

3. Розрахунок ентропії та надлишковості Математичне ядро програми обчислює ентропію за класичним алгоритмом Шеннона. Функція приймає словник із частотами, знаходить їх загальну суму та розраховує ймовірність появи кожного елемента. Далі обчислюється ентропія як від'ємна сума добутків імовірностей на їхні двійкові логарифми. Отриманий результат ділиться на довжину біграми чи літери, щоб отримати питому ентропію на один символ тексту. Паралельно скрипт розраховує максимальну ентропію (як логарифм за основою два від потужності алфавіту) та визначає надлишковість джерела як відносну різницю між практичною та максимальною ентропією.

4. Генерація тестових послідовностей Для проведення експериментів із різних частин завдання скрипт автоматично генерує синтетичні масиви даних:

- Послідовність із рівномірним розподілом створюється функцією, яка незалежно та рівноймовірно вибирає символи з алфавіту.
- Для створення псевдовипадкової послідовності, яка має повністю зберігати частоти іншої заданої послідовності, застосовується алгоритм перемішування елементів масиву. Це повністю руйнує структурні залежності між літерами, але залишає їхню кількість незмінною.
- Для забезпечення повної відтворюваності результатів експерименту встановлено жорстко фіксований стан генератора псевдовипадкових чисел.

Розрахунок статистичних характеристик тексту

Обробка файлу: book.txt (4.41 МБ)

1. Текст з пробілами ($m = 33$, $H_0 = 5.0444$, довжина = 2391156 симв.):

$H_1 = 4.3836$, $R = 0.1310$

Топ-5 символів: [(' ', 387422), ('о', 226649), ('а', 164096), ('е', 160336), ('и', 132240)]

H_2 (перетин) = 3.9950, $R = 0.2080$

Топ-5 біграм: [('о ', 47619), ('и ', 43480), ('а ', 43453), (' п', 40215), ('е ', 39284)]

H_2 (без перетину) = 3.9946, $R = 0.2081$

Топ-5 біграм: [('о ', 23865), ('а ', 21797), ('и ', 21621), (' п', 19991), ('е ', 19885)]

ΔH_2 (різниця перетину) = 0.000424

1. Текст із пробілами (Алфавіт $m = 33$, максимальна ентропія $H_0 = 5.0444$)

- Ентропія та надлишковість (1-грами): $H_1 = 4.3836$, $R_1 = 0.1310$
- Ентропія та надлишковість (біграми з перетином): $H_2 = 3.9950$, $R_2 = 0.2080$
- Ентропія та надлишковість (біграми без перетину): $H_2 = 3.9946$, $R_2 = 0.2081$
- Різниця ΔH_2 : 0.000424

Топ-5 біграм (з перетином): ('о ', 47619), ('и ', 43480), ('а ', 43453), (' п', 40215), ('е ', 39284)

Топ-5 біграм (без перетину): ('о ', 23865), ('а ', 21797), ('и ', 21621), (' п', 19991), ('е ', 19885)

Таблиця частот символів (з пробілами):

Символ	Кількість	Ймовірність	Символ	Кількість	Ймовірність	Символ	Кількість	Ймовірність
' ':	387422	0.1620	к:	67512	0.0282	б:	31840	0.0133
о:	226649	0.0948	м:	63150	0.0264	ч:	30516	0.0128
а:	164096	0.0686	д:	63005	0.0263	й:	22903	0.0096
е:	160336	0.0671	у:	58732	0.0246	ж:	20232	0.0085
и:	132240	0.0553	п:	57464	0.0240	ш:	17207	0.0072
н:	132227	0.0553	ь:	42428	0.0177	х:	17147	0.0072
т:	122951	0.0514	я:	39189	0.0164	ю:	13648	0.0057
л:	110094	0.0460	г:	37660	0.0157	э:	9340	0.0039
с:	104614	0.0438	ы:	35044	0.0147	ц:	6718	0.0028
р:	91493	0.0383	з:	32675	0.0137	щ:	6479	0.0027
в:	81186	0.0340	ф:	4506	0.0019	ъ:	453	0.0002

2. Текст без пробілів (Алфавіт $m = 32$, максимальна ентропія $H_0 = 5.0000$)

2. Текст без пробілів ($m = 32$, $H_0 = 5.0000$, довжина = 2003734 симв.):

$H_1 = 4.4685$, $R = 0.1063$

Топ-5 символів: [('о', 226649), ('а', 164096), ('е', 160336), ('и', 132240), ('н', 132227)]

Повна таблиця частот символів:

'о': 226649 (0.1131)

'а': 164096 (0.0819)

H_2 (перетин) = 4.1674, $R = 0.1665$

Топ-5 біграм: [('то', 33024), ('на', 26236), ('ст', 25178), ('ал', 23291), ('по', 23228)]

H_2 (без перетину) = 4.1674, $R = 0.1665$

Топ-5 біграм: [('то', 16459), ('на', 13092), ('ст', 12710), ('по', 11601), ('ал', 11589)]

ΔH_2 (різниця перетину) = 0.000000

- Ентропія та надлишковість (1-грами): $H_1 = 4.4685$, $R_1 = 0.1063$
- Ентропія та надлишковість (біграми з перетином): $H_2 = 4.1674$, $R_2 = 0.1665$
- Ентропія та надлишковість (біграми без перетину): $H_2 = 4.1674$, $R_2 = 0.1665$
- Різниця ΔH_2 : 0.000000

Топ-5 біграм (з перетином): ('то', 33024), ('на', 26236), ('ст', 25178), ('ал', 23291), ('по', 23228)
Топ-5 біграм (без перетину): ('то', 16459), ('на', 13092), ('ст', 12710), ('по', 11601), ('ал', 11589)

Таблиця частот символів (без пробілів):

Символ	Кількість	Ймовірність	Символ	Кількість	Ймовірність	Символ	Кількість	Ймовірність
о:	226649	0.1131	м:	63150	0.0315	ч:	30516	0.0152
а:	164096	0.0819	д:	63005	0.0314	й:	22903	0.0114
е:	160336	0.0800	у:	58732	0.0293	ж:	20232	0.0101
и:	132240	0.0660	п:	57464	0.0287	ш:	17207	0.0086
н:	132227	0.0660	ь:	42428	0.0212	х:	17147	0.0086
т:	122951	0.0614	я:	39189	0.0196	ю:	13648	0.0068
л:	110094	0.0549	г:	37660	0.0188	э:	9340	0.0047
с:	104614	0.0522	ы:	35044	0.0175	ц:	6718	0.0034
р:	91493	0.0457	з:	32675	0.0163	щ:	6479	0.0032
в:	81186	0.0405	б:	31840	0.0159	ф:	4506	0.0022
к:	67512	0.0337	ъ:	453	0.0002			

Аналіз перетину біграм: Метод збору біграм із перетином формує вибірку розміром $N-1$ пар символів, тоді як метод без перетину розбиває текст на жорсткі блоки по два символи, формуючи вибірку розміром $N/2$. Таким чином, перший алгоритм аналізує майже вдвічі більший обсяг статистичних даних. Проте, як свідчать отримані результати ($\Delta H_2 = 0.000000$ для тексту без пробілів), розраховані значення ентропії H_2 виявилися ідентичними. Це пояснюється законом великих чисел: оскільки обсяг досліджуваного файлу перевищує 4 МБ, навіть зменшена вдвічі вибірка (метод без перетину) є більш ніж достатньою для стабілізації частот появи кожної біграми та формування репрезентативного розподілу ймовірностей, який повністю відповідає загальним закономірностям російської мови.

Дослідження розподілу символів (Розділ 3)

```
3. Дослідження розподілу символів:  
Прогноз:  $H_1(B) < H_1(A) < H_1(V)$   
Послідовність Б детермінована, В має максимальну ентропію, А - посередині.  
Послідовність А (природний текст):  $H_1 = 4.3687$   
Послідовність Б (один символ):  $H_1 = -0.0000$   
Послідовність В (рівноймовірна):  $H_1 = 5.0414$ 
```

- **Прогноз:** $H_1(B) < H_1(A) < H_1(V)$. Послідовність Б складається з однакових символів, тому є абсолютно передбачуваною (детермінованою), її ентропія дорівнюватиме нулю. Послідовність В генерується апаратним або програмним генератором псевдовипадкових чисел з рівномірним розподілом, тому матиме максимально можливу ентропію (рівну H_0). Природний текст А знаходитиметься між цими крайніми значеннями через нерівномірність частотного розподілу літер у реальній мові.
- **Фактичні результати вимірювань:**
 - Послідовність А (природний текст): $H_1 = 4.3687$
 - Послідовність Б (один символ): $H_1 = 0.0000$
 - Послідовність В (рівноймовірна): $H_1 = 5.0414$
- **Висновок:** Проведений експеримент на 100% підтвердив висунутий прогноз. Результати наочно демонструють математичну суть ентропії як міри невизначеності: від повної відсутності невизначеності (послідовність Б) до повного хаосу (послідовність В).

Дослідження залежностей між символами (Розділ 4)

```
4. Дослідження залежностей між символами:  
Прогноз:  
1.  $H_1(\Gamma)$  і  $H_1(D)$  будуть ідентичними.  
2.  $H_2(D)$  буде суттєво меншим за  $H_2(\Gamma)$ .  
3.  $H_2$ (без перетину) для Д впаде до нуля.  
4.  $H_2$ (перетин) для Д покаже ненульову ентропію.
```

- ### Експериментальна оцінка ентропії джерела (CoolPinkProgram)

Лабораторная работа №1

Произвольная часть текста:
век должен подчиняться различным биологическим законам которые он не может

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: н

Символ по счету: 1

Номер эксперимента: 52

Неравенство для энтропии:
 $2.39943289905055 < H < 2.97133581432888$

Двоичная таблица угаданных символов:

000000000000000000010000000000
000000000000000000000000000010
00000000000000000000000000000010
00100000000000000000000000000000
10000000000000000000000000000000

Вероятности:

q [1] = 0.4615384
q [2] = 0.0961538
q [3] = 0.0576923
q [4] = 0.0192307
q [5] = 0.0576923
q [6] = 0
q [7] = 0
q [8] = 0.0192307
q [9] = 0
q [10] = 0
q [11] = 0
q [12] = 0
q [13] = 0.019230
q [14] = 0
q [15] = 0.038461
q [16] = 0
q [17] = 0
q [18] = 0
q [19] = 0.019230
q [20] = 0.038461
q [21] = 0.019230

Лабораторная работа №1

Произвольная часть текста:
ч_где_восхищаются_людьми_которые_убегают_с_поля_битвы_или_где_человек_горди

Использованные буквы:
и, к, е, н, г, ш, щ, э, х,

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: ю

Символ по счету: 10

Номер эксперимента: 52

Неравенство для энтропии:
 $2,27203125456867 < H < 3,05521471826343$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
00100000000000000000000000000000
10000000000000000000000000000000

Поле ввода символов:
ю

Продолжить Другой

Вероятности:

q[1] = 0,4423076
q[2] = 0,0384615
q[3] = 0,1153846
q[4] = 0,0384615
q[5] = 0,0192307
q[6] = 0,0769230
q[7] = 0,0384615
q[8] = 0,0192307
q[9] = 0,0192307
q[10] = 0,0384615
q[11] = 0,0192307
q[12] = 0
q[13] = 0
q[14] = 0,0192307
q[15] = 0
q[16] = 0
q[17] = 0,0192307
q[18] = 0
q[19] = 0
q[20] = 0,0192307
q[21] = 0
q[22] = 0,0384615

Лабораторная работа №1

Произвольная часть текста:
тогда_следует_что_мы_вынуждены_верить_в_подлинное_существование_добра_и_зла

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: ы

Символ по счету: 1

Номер эксперимента: 53

Неравенство для энтропии:
 $3,54968206355771 < H < 3,8492858995576$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
00000000000000000000000000000000
00000000000000000000000000000000

Поле ввода символов:
ы

Продолжить Другой

Вероятности:

q[1] = 0,2641509
q[2] = 0,1132075
q[3] = 0,0188679
q[4] = 0,0188679
q[5] = 0,0188679
q[6] = 0,0188679
q[7] = 0,0188679
q[8] = 0,0188679
q[9] = 0
q[10] = 0
q[11] = 0,0188679
q[12] = 0
q[13] = 0,037735
q[14] = 0,0188679
q[15] = 0
q[16] = 0,075471
q[17] = 0,037735
q[18] = 0,037735
q[19] = 0
q[20] = 0,0188679
q[21] = 0,0188679

Порівняльна таблиця отриманих оцінок ентропії (для тексту без пробілів, $H_0 = 5.0$)

Оцінка	Отримане значення (біт/символ)	Оцінка надлишковості (R)
H_1	4.4685	0.1063 (10.6%)
H_2 (перетин)	4.1674	0.1665 (16.6%)
$H^{(10)}$	2.6854	0.4629 (46.3%)
$H^{(20)}$	2.6636	0.4673 (46.7%)
$H^{(30)}$	3.6994	0.2601 (26.0%)

Аналіз результатів

1. **Чому оцінки ентропії не обов'язково збігаються:** Різні методи оцінки ентропії базуються на різному обсязі апіорної інформації, тобто контексту, який

враховується при розрахунках. Оцінка H_1 розглядає кожен символ тексту абсолютно ізольовано. Оцінка H_2 враховує короткий контекст із одного попереднього символу. Оцінки вищих порядків ($H^{(10)}$, $H^{(20)}$, $H^{(30)}$) враховують значні масиви попереднього тексту. Що більше інформації про минуле джерела нам відомо, то легше спрогнозувати його майбутній стан. Тому із розширенням контексту розрахована невизначеність (ентропія) закономірно спадає.

2. **Які статистичні залежності враховуються при визначенні H_1 та H_2 :** При обчисленні H_1 враховується лише базова частотність (статистика ймовірності появи) окремих, незалежних один від одного символів в алфавіті. При обчисленні H_2 враховуються парні статистичні залежності — марковський ланцюг першого порядку. Ця оцінка відображає умовну ймовірність появи певного символу за умови, що нам точно відомий один попередній символ.
3. **Вплив довгих залежностей між символами:** Природна мова — це не випадковий набір літер, а складна система із жорсткими правилами (синтаксис, морфологія, словниковий запас). Аналізуючи довгий контекст (10–30 літер), людина здатна виявляти не просто пари символів, а цілі префікси, коріння слів та типові граматичні закінчення. Врахування таких багаторівневих залежностей робить появу наступного символу майже детермінованою, що радикально знижує ентропію тексту порівняно з аналізом коротких біграм.
4. **Тенденція при збільшенні контексту:** Спостерігається чітка математична тенденція: при послідовному переході від H_1 до оцінок вищих порядків значення ентропії спадає. У теорії ці оцінки мають поступово та асимптотично наближатися до істинної ентропії джерела відкритого тексту (граничної ентропії H^∞). Збільшення експериментального значення $H^{(30)}$ у нашому дослідженні є очікуваною статистичною флуктуацією, що виникла через похибку методу ручного вгадування під час обробки нетипових слів або складних авторських неологізмів художнього тексту.

Оцінювання надлишковості джерела

1. **Зміна оцінки надлишковості:** Спостерігається обернено пропорційна залежність між ентропією та надлишковістю. При врахуванні складніших та довгих статистичних залежностей, перехід від 1 до 20 символів контексту, ентропія падає, а розрахована надлишковість тексту закономірно зростає від 10.6% для ізольованих літер до понад 46%. Це означає, що заглиблюючись у контекст, ми виявляємо все більше прихованих структурних обмежень, які зменшують інформаційну місткість кожного окремого символу.
2. **Причини ненульової надлишковості природної мови:** Надлишковість мови не є недоліком, а слугує фундаментальним еволюційним механізмом захисту інформації від завад. Вона зумовлена наявністю суворих лінгвістичних законів. Переважна більшість можливих математичних комбінацій літер (наприклад, п'ять

приголосних поспіль) ніколи не утворюють валідне слово російської чи української мови. Саме ця штучна обмеженість і формує надлишковість, яка дозволяє людині легко розуміти текст навіть за наявності друкарських помилок або пропущених літер.

3. **Зв'язок між передбачуваністю, ентропією та надлишковістю:** Ці три параметри жорстко пов'язані між собою. Що вищою є передбачуваність наступних літер у тексті (завдяки жорстким правилам мови та знанню контексту), то нижчою є реальна невизначеність або ентропія цього тексту. Математичним наслідком падіння ентропії є збільшення надлишковості джерела — тобто збільшення тієї частки обсягу повідомлення, яка не несе нової унікальної інформації і теоретично може бути стиснена алгоритмами архівації без жодних втрат змісту.

Загальні висновки

У ході виконання лабораторної роботи було успішно досліджено інформаційні характеристики джерела відкритого тексту. Розроблено та протестовано програмне забезпечення для статистичного аналізу частот символів та n-грам, яке дозволило експериментально розрахувати базові ентропійні оцінки. Доведено, що значення H_1 завжди менше за максимально можливу ентропію H_0 через нерівномірний, специфічний для конкретної мови розподіл літер в алфавіті. Також підтверджено, що $H_2 < H_1$ завдяки наявності стійких статистичних зв'язків між сусідніми символами (наприклад, часте чергування голосних та приголосних).

Експериментальна оцінка ентропії вищих порядків за класичним методом вгадування Шеннона ($H^{(10)}$, $H^{(20)}$) переконливо показала, що врахування широкого лексичного контексту суттєво зменшує загальну невизначеність джерела, збільшуючи його оціночну надлишковість до майже 47%. Отримані результати підтверджують ключовий принцип криптоаналізу: природна мова має високий рівень структурної надлишковості, що робить можливим проведення ефективного частотного аналізу та дешифрування класичних шифрів, побудованих на заміні символів.

