

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ

імені ІГОРЯ СІКОРСЬКОГО

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

Комп'ютерний практикум №1

з дисципліни “Криптографія”

Тема:

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Виконали:

Бойко Євгеній, ФБ-42

Сушко Ілля, ФБ-43

Київ - 2026

Мета: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Нормалізація тексту

Текст був вибраний зі статей на Wikipedia у випадковому порядку (близько 600т. символів)

Нормалізація за допомогою регулярних виразів

```
import re

CLEAN_PATTERN = re.compile(r'^[a-яё]+' )

def normalize_text(text: str) -> str:
    text = text.lower()

    text = CLEAN_PATTERN.sub(' ', text)

    return text.strip()

with open('Crypto.txt', 'r', encoding='utf-8') as f:
    text = f.read()

normalized = normalize_text(text)

with open('Crypto_normalized.txt', 'w', encoding='utf-8') as f:
    f.write(normalized)

with open('Crypto_normalized_no_spaces.txt', 'w', encoding='utf-8') as f:
    f.write(normalized.replace(' ', ''))
```

Підрахунок статистичних характеристик тексту (з пробілами)

Підрахунок частот окремих символів реалізовано наступним алгоритмом:

```
from collections import Counter

with open('Crypto_normalized.txt', 'r', encoding='utf-8') as f:
    text = f.read()
frequencies = Counter(text)
```

```
for key in frequencies.most_common(5):
    print(f"'{key[0]}': {key[1]/len(text):.4f}")
```

Таблиця частот окремих символів

Символ	Частота
_	0.1339
о	0.0896
и	0.0750
а	0.0705
е	0.0704

Аналіз за біграмами

```
from collections import Counter

with open('Crypto_normalized.txt', 'r', encoding='utf-8') as f:
    text = f.read()

bigrams = [text[i:i+2] for i in range(0, len(text)-1, 1)] # Тут змінюємо 3
# range(), для
# перекриттів
bigram_counts = Counter(bigrams)

for key in bigram_counts.most_common(5):
    print(f"'{key[0]}': {key[1]/len(bigrams):.4f}")
```

Таблиця топ-5 біграм, що перетинаються

Біграма	Частота
и_	0.0182
_п	0.0157
_в	0.0144
ст	0.0140

Біграма	Частота
е_	0.0140

Таблиця топ-5 біграм (без перетину)

Біграма	Частота
и_	0.0183
_п	0.0158
_в	0.0143
ст	0.0141
е_	0.0141

Розрахунок ентропії на символ (H_1)

```
import math
from collections import Counter

with open('Crypto_normalized.txt', 'r', encoding='utf-8') as f:
    text = f.read()

frequencies = Counter(text)
total_chars = len(text)

h1 = 0.0

for key in sorted(frequencies.keys()):
    p_i = frequencies[key] / total_chars

    h1 -= p_i * math.log2(p_i)

print(f"Ентропія H1: {h1:.4f} біт на символ")
```

Результат виконання:

Ентропія H1: 4.4316 біт на символ

Розрахунок ентропії на символ за біграмною моделлю (H_2)

```

import math
from collections import Counter

with open('Crypto_normalized.txt', 'r', encoding='utf-8') as f:
    text = f.read()

bigrams = [text[i:i+2] for i in range(0, len(text)-1, 1)]
total_bigrams = len(bigrams)

bigram_counts = Counter(bigrams)

h_bigram = 0.0

for count in bigram_counts.values():
    p_i = count / total_bigrams
    h_bigram -= p_i * math.log2(p_i)

h2 = h_bigram / 2

print(f"Ентропія H2: {h2:.4f} біт")

```

Результат виконання (з перетинами):

Ентропія H2: 4.0346 біт

Без перетинів:

Ентропія H2: 4.0338 біт

Підрахунок статистичних характеристик тексту (без пробілів)

Таблиця частот окремих символів

Символ	Частота
о	0.1035
и	0.0866
а	0.0814

Символ	Частота
е	0.0813
н	0.0675

Таблиця топ-5 біграм, що перетинаються

Біграма	Частота
ст	0.0164
ен	0.0129
ни	0.0128
ра	0.0122
ов	0.0121

Таблиця топ 5 біграм (без перетину)

Біграма	Частота
ст	0.0161
ен	0.0129
ни	0.0127
ов	0.0121
ра	0.0121

Розрахунок ентропії на символ (H_1)

Ентропія H_1 : 4.4609 біт на символ

Розрахунок ентропії на біграму (H_2 з перетинами)

Ентропія H_2 : 4.1423 біт

Розрахунок ентропії на біграму (H_2 без перетинів)

Ентропія H_2 : 4.1409 біт

Відповіді до пункту 2

Для тексту з пробілами відхилення між ентропіями біграм з перетинами та біграм без перетинів становить $\sim 0,02\%$; для тексту без пробілів $\sim 0,033\%$.

Більше статистичних даних використовує спосіб з перетином, оскільки він вивчає всі природні поєднання символів (N-1 пар), тоді як спосіб без перетинів вивчає у два рази менше (N/2)

Дослідження впливу розподілу на ентропію

Для експерименту обрано наступні послідовності однакової довжини:

A - нормалізована стаття про фільм "Замок Диявола"

Б - послідовність букви **ы**

В - випадковий набір букв

Передбачаємо наступні ентропії: Б; А; В

Чим рівніше будуть ймовірності кожного символу, тим більша буде ентропія

Випадковий текст був згенерований цим скриптом:

```
import random

ALPHABET = "абвгдеёжзийклмнопрстуфхцчщъыьэюя "

def generate_max_entropy_text(length):
    return "".join(random.choices(ALPHABET, k=length))

random_text = generate_max_entropy_text(34279)

with open('Task3_random_no_spaces.txt', 'w', encoding='utf-8') as f:
    f.write(random_text)
```

H_1 для випадкового набору букв (з пробілами)

Ентропія H_1 : 5.0870 біт на символ

H_1 для випадкового набору букв (без пробілів)

Ентропія H_1 : 5.0435 біт на символ

H_1 для натурального тексту (з пробілами)

Ентропія H_1 : 4.4439 біт на символ

H_1 для натурального тексту (без пробілів)

Ентропія H_1 : 4.4667 біт на символ

H_1 для послідовності літери **ы**

Ентропія H_1 : 0.0000 біт на символ

Результати дослідження збігаються із передбаченням. Для випадкового набору символів ентропія H_1 близька до $H_0 = \log_2(n)$, якщо порівняти результати, то похибка мінімальна (що для тексту з пробілами, що без).

Оскільки пробіл є найчастішим символом мови, то у випадку натуральної мови він забирає на себе найбільшу ймовірність, тим самим "згладжуючи" різницю ймовірностей інших літер, тому ентропія тексту без пробілів дещо вища за ентропію тексту з ними.

Ентропія для послідовності однієї букви нульова, оскільки єдина ймовірність $P(ы) = 1$, а $\log_2(1) = 0$, тому $-\sum_{i=1}^n p_i * \log_2(p_i) = 0$

Дослідження залежностей між символами

Тексти згенеруємо за допомогою цього скрипта

```
import random

alphabet_pattern = "абвгдеёжзийклмнопрстуфхцчшщъыьэюя "
sequence_d = alphabet_pattern * 10000

sequence_g_list = list(sequence_d)

random.shuffle(sequence_g_list)

sequence_g = "".join(sequence_g_list)

with open('Task4_periodic.txt', 'w', encoding='utf-8') as f:
```



```
f.write(sequence_d)

with open('Task4_random.txt', 'w', encoding='utf-8') as f:
    f.write(sequence_g)
```

Прогнозуємо, що ентропії H_1 будуть приблизно однаковими, тоді як значень H_2 уже буде суттєва різниця. Ентропія H_2 має бути меншою у періодичного тексту. Оскільки вибірка біграм з перетинами приблизно у два рази більше, то результати можуть змінитись, але зважаючи на періодичність, ймовірності перерозподіляться, проте будуть такі ж "гладкі" як і для біграм без перетинів

Результати для H_1 ідентичні

```
Ентропія H1: 5.0875 біт на символ /// для випадкового тексту
Ентропія H1: 5.0875 біт на символ /// для впорядкованого тексту
```

Результати для H_2 з перетинами біграм

```
Ентропія H2: 5.0863 біт /// випадковий текст
Ентропія H2: 2.5437 біт /// впорядкований
```

Результати для H_2 без перетину біграм

```
Ентропія H2: 5.0851 біт
Ентропія H2: 2.0437 біт
```

У загальному прогноз збігся, проте ми не очікували таких розбіжностей для H_2 впорядкованих текстів.

- Оскільки ентропія H_1 не зважає на порядок символів у тексті, а лише на ймовірності конкретних символів, то для рівноможливих появ символів у тексті ентропія буде однакова
- Бо у впорядкованому тексті більшість біграм із випадкового навіть не зустрічаються - передбачувана структура тексту створює піки ймовірностей, що зменшує ентропію
- Модель біграм використовує спільні частоти сусідніх символів, тому розрізняє тексти з однаковими частотами літер, але різними закономірностями їхнього сусідства

Експериментальна оцінка ентропії джерела

За допомогою програми CoolPinkProgram оцінили ентропії $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$. Для кожного порядку провели по 50 експериментів, загалом 150.

У кожному експерименті вгадували наступний символ за показаним фрагментом тексту. Програма враховувала кількість спроб та визначала нижню і верхню межі ентропії.

Результати для $H^{(10)}$

Нижня межа: 2.5961 біт на символ
Верхня межа: 3.2167 біт на символ

Результати для $H^{(20)}$

Нижня межа: 2.3405 біт на символ
Верхня межа: 2.9518 біт на символ

Результати для $H^{(30)}$

Нижня межа: 1.7291 біт на символ
Верхня межа: 2.4111 біт на символ

Порівняльна таблиця оцінок ентропії

Оцінка	Варіант тексту	Ентропія, біт на символ
H_1	3 пробілами	4.4316
H_2 з перетинами	3 пробілами	4.0346
H_2 без перетинів	3 пробілами	4.0338
H_1	Без пробілів	4.4609
H_2 з перетинами	Без пробілів	4.1423
H_2 без перетинів	Без пробілів	4.1409
$H^{(10)}$	Текст CoolPinkProgram	2.5961–3.2167
$H^{(20)}$	Текст CoolPinkProgram	2.3405–2.9518
$H^{(30)}$	Текст CoolPinkProgram	1.7291–2.4111

Межі ентропій округлено до чотирьох знаків після коми. У програмі отримали інтервали, тому зберігаємо обидві межі.

Відповіді до пункту 5

- Значення ентропій не повинні збігатися, оскільки вони отримані для різних моделей джерела. H_1 враховує лише частоти окремих символів, H_2 — частоти сусідніх пар, а $H^{(n)}$ оцінює невизначеність наступного символу за відомого контексту. Також на результати вгадування впливають кількість експериментів і знання мови експериментатором.
- H_1 не враховує порядок символів. H_2 враховує залежності між сусідніми символами через частоти біграм. Для нашого тексту з пробілами $H_1 = 4.4316$, тоді як H_2 з перетинами = 4.0346 біт на символ. H_2 у цій роботі дорівнює половині ентропії пари, а не умовній ентропії наступного символу.
- Довший контекст дозволяє врахувати будову слів, граматику та зміст речення, тому наступний символ стає простіше передбачити. Для порядків 10 і 20 частка вгадувань з першої спроби становила 0.42, а для порядку 30 — 0.58.
- Зі збільшенням порядку обидві межі ентропії зменшились: для $H^{(10)}$ отримали 2.5961–3.2167, а для $H^{(30)}$ — 1.7291–2.4111 біт на символ. Це узгоджується зі зменшенням невизначеності при врахуванні довшого контексту. Водночас інтервали сусідніх порядків перекриваються, тому строгий порядок точних значень ентропії з цих результатів не впливає.

Для H_1 та H_2 використано наш текст, а для $H^{(n)}$ — фрагменти CoolPinkProgram. Алфавіти також відрізняються, тому різниця результатів пов'язана не лише з довжиною контексту.

Оцінювання надлишковості джерела

Надлишковість розрахуємо за формулою

$$R = 1 - H / H_0$$
$$H_0 = \log_2(m)$$

де m — кількість символів алфавіту. Замість невідомої ентропії джерела підставляємо отримані H_1 , H_2 та $H^{(n)}$, тому для кожної моделі маємо свою оцінку надлишковості.

Для нашого тексту з пробілами алфавіт містить 34 символи, без пробілів — 33. Для CoolPinkProgram приймаємо 32 символи відповідно до таблиці ймовірностей q_1 – q_{32} на скриншотах.

$$H_0 \text{ з пробілами: } \log_2(34) = 5.0875 \text{ біт на символ}$$
$$H_0 \text{ без пробілів: } \log_2(33) = 5.0444 \text{ біт на символ}$$
$$H_0 \text{ для CoolPinkProgram: } \log_2(32) = 5 \text{ біт на символ}$$

Приклад розрахунку за H_1 для тексту з пробілами

$$R_1 = 1 - 4.43164949 / 5.08746284 \approx 0.1289 \approx 12.89\%$$

Таблиця надлишковості за частотами символів та біграм

Оцінка	З пробілами	Без пробілів
За H_1	12.89%	11.57%
За H_2 з перетинами	20.69%	17.88%
За H_2 без перетинів	20.71%	17.91%

Для CoolPinkProgram ентропію отримали у вигляді інтервалу. Оскільки зі збільшенням ентропії надлишковість зменшується, межі обчислюємо у зворотному порядку:

$$R_{\min} = 1 - H_{\max} / H_0$$

$$R_{\max} = 1 - H_{\min} / H_0$$

Приклад розрахунку за $H^{(10)}$

$$R_{\min} = 1 - 3.21669456263237 / 5 \approx 0.3567 \approx 35.67\%$$

$$R_{\max} = 1 - 2.59609169269650 / 5 \approx 0.4808 \approx 48.08\%$$

Таблиця надлишковості за результатами CoolPinkProgram

Оцінка	Нижня межа	Верхня межа
За $H^{(10)}$	35.67%	48.08%
За $H^{(20)}$	40.96%	53.19%
За $H^{(30)}$	51.78%	65.42%

У розрахунках використано неокруглені значення ентропій; результати у відсотках округлено до двох знаків після коми.

Відповіді до пункту 6

- При врахуванні залежностей між символами оцінка надлишковості збільшується. Для нашого тексту з пробілами вона зросла з 12.89% за H_1 до 20.69% за H_2 з перетинами. У CoolPinkProgram обидві межі також зросли: від 35.67–48.08% для порядку 10 до 51.78–65.42% для порядку 30.
- Природна мова має ненульову надлишковість, оскільки символи зустрічаються з різними ймовірностями та залежать один від одного. Будова слів, граматики і зміст обмежують можливі продовження тексту. Через це його ентропія менша за максимальну ентропію рівноймовірних незалежних символів того самого алфавіту.
- Чим простіше передбачити наступний символ, тим менша його невизначеність і тим більша надлишковість за однакового алфавіту. Такі закономірності дозволяють стискати текст без втрати інформації. Отримані відсотки характеризують надлишковість моделей, а не фактичний відсоток стиснення файлу конкретним архіватором.

Аналіз результатів

1. Природна мова має значні статистичні обмеження: букви зустрічаються з різною частотою, існують стійкі залежності між символами. Це тягне розподіл ймовірностей у бік статистично ймовірніших символів (наприклад, пробіл чи буква «о»), що зменшує невизначеність. Натомість випадкова рівноймовірна послідовність не містить жодних залежностей, а всі символи з'являються з однаковою частотою, тому її ентропія наближається до максимально можливої ($H_0 = \log_2(m)$). У нашому експерименті H_1 природного тексту склала 4.4439 біт, тоді як для випадкового — 5.0870 біт (що близько до H_0).
2. Ентропія H_1 розглядає текст як набір незалежних символів і враховує лише індивідуальні частоти їх появи. Ентропія H_2 (модель біграм) додатково враховує статистичні зв'язки між сусідніми символами (спільну ймовірність пар). Вона фіксує, які комбінації символів є типовими для мови, а які — неможливими, що дозволяє точніше оцінити реальну невизначеність джерела тексту.
3. Так, безумовно. Це напряду доводить Експеримент 4. Для експерименту було згенеровано два тексти: один із суворою періодичною структурою, а інший — його випадково перемішана копія. Оскільки набір символів та їхня загальна кількість в обох текстах були ідентичними, значення H_1 збіглися. Однак значення H_2 кардинально відрізнялися: для випадкового тексту $H_2 \approx 5.0863$ біт, а для періодичного H_2 знизилась до 2.5437 біт, оскільки модель біграм виявила закономірність сусідства символів у впорядкованому тексті.
4. Вилучення пробілів призвело до незначного **збільшення** ентропії (в Експерименті 2 значення H_1 зросло з 4.4316 до 4.4609 біт, а H_2 з 4.0346 до 4.1423 біт). Пробіл є

найчастішим символом природної мови. Його видалення перерозподіляє загальну ймовірність між іншими, рідкіснішими символами, роблячи їхні ймовірності трохи більш рівномірними ("згладжуючи" загальний розподіл). Чим більш рівномірний розподіл частот, тим вища ентропія.

5. Різниця виникає через обсяг вибірки та повноту врахування природних зв'язків. Метод із перетином збирає всі можливі пари сусідніх символів (всього $N - 1$ пар), фіксуючи повну картину закономірностей у тексті. Метод без перетинів зчитує текст блоками по два символи (всього $N/2$ пар), пропускаючи зв'язок між другою літерою однієї пари та першою літерою наступної. Через це другий метод втрачає частину статистичних даних про сусідство символів, що призводить до відхилень (у нашому досліді розбіжність склала лише $\sim 0,02\%$).
6. Ці оцінки відповідають різним моделям джерела, які враховують різну глибину контексту. H_1 та H_2 - це ентропії для незалежних символів та для пар. Оцінки $H^{(n)}$ показують невизначеність появи наступного символу за умови знання $n - 1$ попередніх. Чим більший контекст нам відомий, тим легше вгадати наступний символ завдяки правилам граматики та лексики. Тому зі збільшенням порядку моделі невизначеність поступово зменшується: від 4.43 біт для H_1 до інтервалу 1.72–2.41 біт для $H^{(30)}$.
7. **Експеримент 4** (періодичний та випадковий тексти), оскільки він наочно доводить, що ентропія H_2 здатна реагувати виключно на зміну порядку символів (залежностей) при незмінних частотах самих символів. **Експеримент 5** (CoolPinkProgram). Він глибше показує, як саме залежності у природній мові впливають на передбачуваність: знання 30 попередніх символів дозволяє вгадувати наступний значно частіше, ніж знання лише 10 символів, що різко зменшує ентропію джерела.
8. Зі збільшенням контексту умовна ентропія тексту суттєво зменшується, що свідчить про наявність великої **надлишковості** у природній мові. Надлишковість $R = 1 - H/H_0$ характеризує можливий ступінь ущільнення інформації. У наших результатах надлишковість зростала від $\sim 12\%$ (за моделлю H_1) до понад 50-65% (за моделлю $H^{(30)}$). Це означає, що понад половина символів у тексті є структурно "зайвими" (їх можна вгадати за попередніми даними), тому застосування алгоритмів архівації дозволяє ефективно стискати такі тексти без жодної втрати змісту.

Висновки

Під час виконання комп'ютерного практикуму було проведено комплексне дослідження ентропії та надлишковості джерела відкритого тексту, що дозволило експериментально підтвердити ключові теоретичні положення теорії інформації.

На основі дослідження нормалізованого російськомовного тексту та згенерованих послідовностей доведено, що найбільшу ентропію має випадковий текст із рівномірним розподілом незалежних символів. Наявність домінуючих символів в природній мові порушує рівномірність розподілу, що призводить до зменшення загальної ентропії H_1

Порівняння моделей джерела довело, що ентропія H_1 є лише грубим наближенням. Перехід до біграмної моделі дозволив врахувати закономірності сусідства символів, що суттєво зменшило показник ентропії.

Експерименти за допомогою CoolPinkProgram підтвердили, що із розширенням контекстного вікна здатність експериментатора передбачати наступний символ зростає. Це призводить до подальшого зниження умовної ентропії джерела

Зі зменшенням ентропії при врахуванні глибшого контексту, оціночний показник надлишковості тексту зростає. Це практично доводить, що природні мови є сильно надлишковими системами.

Отже, експериментальним шляхом доведено, що реальна ентропія природного тексту значно нижча за максимально можливу, а точність її оцінки прямо залежить від глибини врахованого контексту.