КОМП’ЮТЕРНИЙ ПРАКТИКУМ №2

Тема: Криптоаналіз шифру Віженера

Мета роботи: Засвоєння методів частотного криптоаналізу. Здобуття навичок роботи та аналізу потокових шифрів гамування адитивного типу на прикладі шифру Віженера.

Мельниченко Артемій ФБ-41

---

1. Дослідження шифру Віженера

Для дослідження обрано російськомовний текст роману Дж. К. Ролінг “Гарри Поттер и Орден Феникса”, підготовлений у першому практикумі. Із файлу garri_potter_i_orden_feniksa.u_gotovo.txt вилучено пробіли та відібрано перші 1500 літер. Обсяг отриманого фрагмента становить 3000 байтів у кодуванні UTF-8. Використаний алфавіт містить 32 російські літери без ё. Текст збережено у файлі text.txt.

Для обчислень реалізовано програму task1.py. Кожній літері алфавіту відповідає номер від 0 до 31. Під час шифрування до номера літери тексту додається номер відповідної літери ключа за модулем 32. Ключ повторюється до кінця тексту. Один і той самий фрагмент зашифровано ключами “мы”, “кот”, “лиса”, “тайна” та “криптография” довжиною 2, 3, 4, 5 і 12 літер відповідно.

Для відкритого тексту та кожного шифртексту обчислено індекс відповідності. Кількість появ літер підраховано за допомогою Counter. Для кожної літери обчислено добуток $N_t * (N_t - 1)$, де N_t - кількість її появ. Суму цих добутків поділено на $n * (n - 1)$, де n - довжина тексту.

Текст	Ключ	Довжина ключа	Індекс відповідності
Відкритий текст	-	-	0,053258
Шифртекст	мы	2	0,037876
Шифртекст	кот	3	0,039568
Шифртекст	лиса	4	0,035940
Шифртекст	тайна	5	0,038725
Шифртекст	криптография	12	0,032568

У всіх п’яти випадках індекс відповідності після шифрування зменшився. Різні літери ключа задають різні зсуви, тому одна й та сама літера відкритого тексту може перетворюватися на різні літери шифртексту. Це робить загальний розподіл частот більш рівномірним.

Найменший індекс отримано для ключа “криптография” - 0,032568. Він близький до значення 1/32 = 0,03125, що відповідає рівноймовірному вибору літер із використаного алфавіту.

Зі збільшенням довжини ключа індекс зменшувався нерівномірно. Для ключа “кот” він вищий, ніж для “мы”, а для “тайна” - вищий, ніж для “лиса”. Результат залежить не лише від довжини ключа, а й від його конкретних літер та їх повторення, а також від особливостей обраного тексту.

Шифртексти збережено у файлах encrypted_2.txt, encrypted_3.txt, encrypted_4.txt, encrypted_5.txt та encrypted_12.txt. Результати обчислень збережено у results_task1.txt.

---

2. Криптоаналіз шифртексту

Для криптоаналізу використано шифртекст варіанта 8. Після вилучення заголовка, пробілів і переносів рядків отримано 6138 літер. Підготовлений шифртекст збережено у файлі text_8.txt.

Для визначення довжини ключа реалізовано програму task2.py. Перевірено значення r від 2 до 30. Для кожного r шифртекст розділено на блоки: до одного блоку потрапляють літери, розташовані через кожні r позицій. Для кожного блоку обчислено індекс відповідності, після чого знайдено середнє значення.

Якщо довжину ключа визначено правильно, усі літери одного блоку зашифровані тим самим зсувом. Такий зсув зберігає індекс відповідності, тому його значення має бути близьким до показника природного тексту.

Мовний орієнтир обчислено як суму квадратів частот окремих літер без пробілів із файлу frequencies.csv першого практикуму. Отримано значення 0,055405. Для рівноймовірного алфавіту з 32 літер індекс становить 0,031250. Індекс усього шифртексту дорівнює 0,033214.

Результати перевірки можливих довжин ключа:

```
2;0.034814
3;0.033243
4;0.036209
5;0.039787
6;0.034852
7;0.033169
8;0.036129
9;0.033335
10;0.046158
11;0.033223
12;0.036215
13;0.032986
14;0.034661
15;0.039657
16;0.036266
17;0.033340
18;0.034826
19;0.033112
20;0.055714
21;0.033116
22;0.034683
23;0.033208
24;0.036098
25;0.039966
26;0.034913
27;0.033182
28;0.035793
29;0.033108
30;0.046018
```

Найбільше значення отримано при r = 20: 0,055714. Воно відрізняється від мовного орієнтира лише на 0,000309. При цьому кожен блок містить 306 або 307 літер. Як альтернативні кандидати розглянуто r = 5, 10 та 30. Значення 10 і 30 обрано через помітно підвищені індекси, а 5 - як менший дільник основного кандидата 20. При r = 10 середній індекс становить 0,046158, а при r = 30 - 0,046018. Обидва значення вищі за більшість інших результатів, але нижчі за мовний орієнтир. За припущення періоду 20 кроки 10 і 30 почергово вибирають дві позиції ключа, віддалені на 10 літер. Через це в одному блоці змішуються два зсуви, що пояснює подібні проміжні значення індексів. При r = 5 отримано 0,039787. За періоду 20 такий поділ змішує в одному блоці чотири позиції ключа. Розподіл частот стає більш рівномірним, тому індекс нижчий, ніж при r = 10 та r = 20.
За результатами порівняння найбільш імовірною довжиною ключа обрано r = 20. Остаточна перевірка цього припущення виконується під час відновлення ключа та розшифрування тексту. Повні результати обчислень збережено у файлі results_task2.txt.

---

3. Відновлення ключа та відкритого тексту

Для відновлення ключа використано довжину r = 20, визначену в попередньому пункті. У програмі task3.py шифртекст розділено на 20 блоків. Кожен блок містить літери, зашифровані однією літерою ключа, тому його розшифрування зводиться до визначення зсуву шифру Цезаря.
За допомогою Counter для кожного блоку визначено три найчастіші літери та кількість їх появ. Початковий ключ отримано за припущенням, що найчастіша літера кожного блоку відповідає літері “о” відкритого тексту. Для цього від номера найчастішої літери шифртексту віднято номер “о” за модулем 32.

```
1;б: 34, ш: 27, ы: 25;у
2;щ: 34, у: 28, р: 24;л
3;о: 30, а: 29, е: 28;а
4;ы: 46, н: 27, т: 25;н
5;ь: 41, у: 25, о: 23;о
6;п: 28, к: 24, з: 24;б
7;я: 41, г: 27, в: 23;с
8;у: 33, ч: 27, к: 26;е
9;ю: 46, х: 32, р: 26;р
10;у: 30, н: 28, к: 25;е
11;п: 34, б: 30, ж: 30;б
12;х: 29, ю: 27, р: 23;з
13;н: 38, д: 34, я: 22;я
14;ы: 33, т: 25, х: 25;н
15;й: 36, а: 27, г: 25;ы
16;у: 34, к: 28, ц: 23;е
17;э: 46, ч: 23, п: 23;п
18;б: 33, а: 25, ш: 25;у
19;щ: 32, э: 28, р: 26;л
20;н: 33, ц: 29, и: 26;я
```

Наприклад, у першому блоці найчастіше зустрічається “б” - 34 рази. Її номер в алфавіті дорівнює 1, а номер “о” - 14. Різниця за модулем 32 становить 19, що відповідає літері ключа “у”.
Отримано початковий ключ:
уланобсеребзяныепуля

Під час розшифрування цим ключем у тексті з’явилися впізнавані слова, але залишилися помилки. Наприклад, початок мав вигляд “этаситтемакщасногокйрлика”. Це свідчить про те, що припущення щодо найчастішої літери “о” справджується не для всіх блоків.
За змістом ключа та розшифрованого тексту уточнено три позиції: у позиції 6 літеру “б” замінено на “в”, у позиції 12 літеру “з” - на “р”, у позиції 20 літеру “я” - на “и”. Причину помилок можна пояснити частотами окремих блоків. Після уточнення ключа найчастіша літера “п” шостого блоку відповідає відкритій літері “н”, літера “х” дванадцятого блоку - літері “е”, а літера “н” двадцятого блоку - також літері “е”. Отже, у цих блоках найчастішою була не “о”.

Уточнений ключ довжиною 20 літер:
улановсеребряныепули

Для розшифрування від номера кожної літери шифртексту віднято номер відповідної літери циклічно повторюваного ключа за модулем 32. Отриманий текст починається так (пробіли додано для читання):

“эта система красного карлика никогда не имела названия только зубодробительно длинный номер в каталоге исследовавший ее киберзонд отметил наличие трех газовых гигантов двух астероидных полей кометного облака”

Після уточнення ключа наведений фрагмент читається як зв’язний російськомовний текст. Це підтверджує вибір довжини ключа та внесених виправлень. Додатково виконано повторне шифрування отриманого відкритого тексту. Результат повністю збігся з початковим шифртекстом. Ця перевірка підтверджує узгодженість реалізації шифрування та розшифрування, але сама по собі не доводить правильність ключа, оскільки зворотність операцій зберігається і для неправильного ключа.
Повний розшифрований текст збережено у файлі decoded_8.txt, ключ - у key.txt, а проміжні статистичні результати та фрагменти тексту - у results_task3.txt.

---

4. **Дослідження впливу помилки в ключі**

Для експерименту першу літеру правильного ключа “у” замінено на “ф”. Довжина ключа залишилася незмінною - 20 літер.
Прогноз: помилка вплине лише на літери тексту в позиціях 1, 21, 41 і далі з кроком 20. Решта літер залишиться незмінною. Оскільки номер “ф” на одиницю більший за номер “у”, під час розшифрування кожна помилкова літера буде зміщена на одну позицію назад за модулем 32. Для тексту довжиною 6138 літер очікується 307 змінених літер, тобто приблизно 5% тексту.

```
Правильний ключ: улановсеребряныепули
Ключ із помилкою: флановсеребряныепули
Кількість змінених літер: 307 із 6138
Частка змінених літер: 5.0016%
Перші 15 позицій помилок: [1, 21, 41, 61, 81, 101, 121, 141, 161, 181, 201, 221, 241, 261, 281]
Остання позиція помилки: 6121
Позиції відповідають прогнозу: True

Порівняння фрагментів по 20 літер:
Правильно | Із помилкою
этасистемакрасногока | ьтасистемакрасногока
рликаникогданеимелан | пликаникогданеимелан
азваниятолькозубодро | язваниятолькозубодро
бительнодлинныйномер | аительнодлинныйномер
вкаталогеиссследовавш | бкаталогеиссследовавш
```

Після заміни першої літери ключа “у” на “ф” змінилися 307 із 6138 літер відкритого тексту, що становить 5,0016 %. Помилки виникли в позиціях 1, 21, 41, 61 і далі з кроком 20. Остання змінена позиція - 6121. Отримані позиції повністю збіглися з прогнозом. У наведених фрагментах видно, що змінюється лише перша літера кожної групи з 20 літер: “э” перетворилася на “ь”, “р” - на “п”, “а” - на “я”. Це відповідає зсуву на одну позицію назад в алфавіті за модулем 32. Перехід “а” в “я” пояснюється циклічністю алфавіту.

Помилка повторюється з періодом 20, оскільки змінена літера ключа використовується один раз за кожен його повтор. Решта 5831 літери залишилася незмінною. Частка помилок дещо перевищує 5%, оскільки довжина тексту не кратна 20 і останній неповний період також містить змінену позицію.

Отже, помилка в одному символі ключа не поширюється на весь текст, а спричиняє періодичні зміни лише у відповідних позиціях. Результат розшифрування з помилковим ключем збережено у decoded_8_wrong.txt, результати порівняння - у results_task4.txt.

Питання для аналізу результатів

1. Для всіх використаних ключів індекс відповідності шифртексту був нижчим, ніж для відкритого тексту: замість 0,053258 отримано значення від 0,032568 до 0,039568. Найменше значення відповідає ключу довжини 12. Зменшення не було строго послідовним, оскільки результат залежить також від конкретних літер ключа та їх повторення.
2. При r = 20 середній індекс відповідності блоків становив 0,055714. Це найбільше значення серед перевірених і найближче до мовного орієнтира 0,055405. Подальше відновлення змістовного ключа та отримання зв’язного тексту підтвердили вибір.
3. Розглянуто довжини 5, 10 і 30. Значення 10 і 30 обрано через підвищені індекси, а 5 - як менший дільник 20. Для них отримано відповідно 0,039787, 0,046158 та 0,046018. Ці значення нижчі за мовний орієнтир, оскільки такий поділ змішує в одному блоці різні позиції ключа.
4. Використано кількість появ літер у кожному блоці та припущення, що найчастіша літера відповідає “о”. Початковий ключ отримано за різницею номерів цих літер за модулем 32. Три помилкові символи уточнено за змістом ключа та розшифрованого тексту.
5. Правильність ключа можна оцінити за осмисленістю розшифрованого тексту, відсутністю періодичних спотворень і відповідністю статистики природній мові. У роботі отримано змістовний ключ “улановсеребряныепули” та зв’язний

російськомовний текст. Повторне шифрування підтвердило узгодженість програмних операцій, але саме по собі не доводить правильність ключа.

6. Після заміни першої літери ключа змінилися 307 із 6138 літер, тобто 5,0016% тексту. Помилки виникли в позиціях 1, 21, 41 і далі з кроком 20. Це пояснюється повторенням зміненої літери ключа через кожні 20 позицій. Решта тексту залишилася незмінною.
7. Найбільше від обсягу шифртексту залежать визначення періоду та частотне відновлення символів ключа. У коротких блоках частоти сильніше відхиляються від мовних, а найчастішою літерою може бути не “о”. За незмінної довжини тексту збільшення кількості блоків зменшує обсяг статистики в кожному з них.
8. Слабкість шифру найкраще показали виражений максимум середнього індексу при r = 20 та відновлення ключа за частотами літер. Повторення ключа дозволило розділити шифртекст на блоки, кожен із яких зашифрований одним зсувом Цезаря, і відновити відкритий текст без попереднього знання ключа.

Висновки

У роботі реалізовано шифрування та розшифрування шифром Віженера. Для всіх п’яти використаних ключів індекс відповідності шифртексту виявився нижчим, ніж для відкритого тексту. Для варіанта 8 за середніми індексами відповідності блоків визначено довжину ключа 20. За частотами літер і змістом отриманих фрагментів відновлено ключ “улановсеребряныепули” та відкритий текст.

Експеримент із помилкою в одному символі ключа підтвердив прогноз: змінилися 307 із 6138 літер у позиціях із кроком 20. Проведений криптоаналіз показав, що повторення ключа зберігає статистичні закономірності, які дозволяють визначити його довжину та звести розшифрування до аналізу окремих зсувів Цезаря.