

Криптографія. Комп'ютерний практикум №2

Криптоаналіз шифру Віженера

Коротка Ксенія та Тимчак Анастасія, ФБ-43 · Варіант 4

Мета роботи

Засвоєння методів частотного криптоаналізу. Здобуття навичок роботи та аналізу поточкових шифрів гамування адитивного типу на прикладі шифру Віженера.

Вхідні дані та правила їх підготовки

- **Алфавіт:** 32 літери російської мови (а–я без «ё»), $m = 32$; літери замінюються номерами 0–31.
- **Власний відкритий текст:** уривок з роману Л. Толстого «Анна Каренина» (ч. 4, гл. I) — 2509 літер після підготовки (≈ 2.5 КБ в одnobайтовому кодуванні).
- **Підготовка тексту:** нижній регістр, «ё» → «е», вилучення всіх символів поза алфавітом (пробілів, пунктуації, цифр).
- **Шифртекст варіанта 4:** 8061 літера, вже поданий у потрібному алфавіті.
- **Статистика мови** взята з корпусу першого практикуму («Анна Каренина», 1.3 млн літер): найчастіші літери — о, е, а, н, и; теоретичний індекс відповідності $I = \sum p_t^2 = 0.0569$, для рівноімовірного алфавіту $I_0 = 1/m = 0.0312$.

Програмна реалізація

Програма `lab2.py` (Python, лише стандартна бібліотека) містить:

- `normalize` — підготовка тексту;
- `encrypt / decrypt` — шифр Віженера: $y_i = (x_i + k_i \bmod r) \bmod m$;
- `index_of_coincidence` — $I(Y) = \sum N_t(N_t - 1) / (n(n - 1))$;
- `avg_block_ic` — середній індекс відповідності блоків $Y_0, \dots, Y_{r-1}$;
- `coincidences` — статистика D_r (кількість однакових літер на відстані r);
- `key_by_top_letter` — відновлення ключа за формулою $k = (y^* - x^*) \bmod m$.

Результати друкуються в консоль і зберігаються в `results.txt`.

1. Дослідження шифру Віженера

Завдання: зашифрувати власний текст ключами довжини $r = 2, 3, 4, 5$ та 10–20, обчислити індекси відповідності та пояснити результати.

Текст	Ключ	r	$I(Y)$
відкритий текст	—	—	0.0558
шифртекст	да	2	0.0444
шифртекст	кот	3	0.0404
шифртекст	шифр	4	0.0356
шифртекст	лампа	5	0.0367
шифртекст	защита информации	16	0.0327

Індекс відповідності відкритого тексту (0.0558) близький до теоретичного значення мови (0.0569). Зі зростанням довжини ключа індекс падає і наближається до $1/m = 0.0312$: чим більше різних зсувів змішано в одному тексті, тим рівномірніше розподілені літери шифртексту. Невелике порушення монотонності між $r = 4$ і $r = 5$ пояснюється малим обсягом тексту (≈ 500 – 600 літер на блок) і конкретним складом ключа.

2. Криптоаналіз шифртексту

Завдання: визначити довжину ключа статистичними методами, перевіривши r щонайменше до 30, та дослідити альтернативних кандидатів.

Для кожного $r = 2 \dots 30$ шифртекст розбито на r блоків і обчислено середній індекс відповідності блоків (перший метод), а також статистику D_r (другий метод). Індекс відповідності всього шифртексту — 0.0326, тобто близький до $1/m$.




Рисунок 1: Середній індекс відповідності блоків для $r = 2 \dots 30$




Рисунок 2: Статистика співпадінь D_r для $r = 2 \dots 30$

При $r = 13$ середній індекс блоків стрибає до 0.0541, що майже дорівнює індексу мови; для всіх інших r (крім 26) він тримається на рівні $0.0323\text{--}0.0328 \approx 1/m$. Так само $D_{13} = 456$ і $D_{26} = 416$, тоді як решта значень лежить у межах 230–280.

Альтернативні кандидати. Крім $r = 13$, перевірено $r = 26$ (другий пік, кратний 13) та $r = 21$ і $r = 28$ (найбільші D_r серед значень, не кратних 13):

r	Сер. I	D_r	Висновок
13	0.0541	456	істинний період
26	0.0539	416	кратне періоду 13
21	0.0328	278	шум, $I \approx 1/m$
28	0.0325	278	шум, $I \approx 1/m$

Для $r = 21$ і 28 ключ, відновлений за найчастішими літерами, безглуздий («юаиьр-вааьнвдаювааеам»), тож високе D_r — випадкове коливання. Період 26 дає ту саму картину, що й 13, бо кожен його блок є половиною блоку періоду 13. Найменше значення з піком — 13, і 13 не має дільників, крім 1, отже **$r = 13$** .

3. Відновлення ключа та відкритого тексту

Завдання: відновити ключ за методикою $k = (y^* - x^*) \bmod m$, навести проміжні результати, розшифрувати текст і перевірити його.

Для кожного блоку Y_i (≈ 620 літер) знайдено найчастішу літеру y^* і обчислено k при $x^* = \langle \text{о} \rangle$, а також при другій і третій за частотою літерах мови ($\langle \text{е} \rangle$, $\langle \text{а} \rangle$):

i	y*	N(y*)	x* = o	x* = e	x* = a	Обрано
0	с	78	г	м	с	г
1	ю	56	р	щ	ю	р
2	ь	71	о	ч	ь	о
3	ъ	70	м	х	ъ	м
4	ы	56	н	ц	ы	ы
5	ш	62	к	у	ш	к
6	о	64	а	й	о	о
7	р	62	в	л	р	в
8	к	70	ь	е	к	е
9	т	62	д	н	т	д
10	б	78	у	ь	б	ь
11	ъ	68	м	х	ъ	м
12	о	72	а	й	о	а

При $x^* = \langle o \rangle$ для всіх блоків отримано ключ «громнкавьдума». Розшифрування ним частково читається, але містить спотворені літери саме на позиціях блоків 4, 6, 8, 10:

старьиысуаишколачорьдоелпифийиаровцияфакультеаеатоощетичесшочишрй-
ктичесшочмйгсик...

Для цих блоків найчастішою в тексті виявилась не «о», а «а» чи «е». Замінивши x^* на наступну імовірну літеру, отримали змістовний ключ:

Ключ: ГРОМЫКОВЕДЬМА ($r = 13$)

Початок розшифрованого тексту (повністю — `y decrypted_v4.txt`):

старминская школа чародеев пифий и травниц факультет теоретической
и практической магии кафедра магов практиков часть первая социальный
уклад быт и нравы вампирьей общины ...

Перевірка: текст читається без помилок на всій довжині; індекс відповідності розшифрованого тексту $0.0541 \approx I$ мови; ключ є осмисленим словосполученням.

4. Дослідження впливу помилки в ключі

Завдання: змінити один символ правильного ключа, спрогнозувати та перевірити, як це вплине на розшифрування.

Прогноз: кожен символ ключа використовується лише для позицій $i \equiv j \pmod{13}$. Якщо змінити символ ключа з номером $j = 5$, то неправильно розшифруються лише ці позиції — приблизно $8061 / 13 \approx 620$ літер, — і кожна з них зсунеться на ту саму величину. Решта тексту залишиться правильною.

Експеримент: ключ «громыковедьма» замінено на «громыловедьма» ($k \rightarrow l$, зсув $+1$).

правильно: афедрамаговпрактиковчастьперваясоциальныйукладбытинравывампирьейобщинывикачтовычто

з помилкою: афедрямаговпрактикнвчастьперваяроциальныйукладбытинравывалпирьейобщиныбикачтовычто

Результат: змінено рівно 620 літер з 8061, усі на позиціях $i \equiv 5 \pmod{13}$, кожна зсунута на одну літеру назад по алфавіту. Прогноз підтвердився: помилка не поширюється, а повторюється з періодом ключа, тому текст залишається читабельним.

Відповіді на питання

1. Як змінювався індекс відповідності при різних довжинах ключа? Він падав: 0.0558 (ВТ) $\rightarrow 0.0444$ ($r = 2$) $\rightarrow 0.0404$ ($r = 3$) $\rightarrow \approx 0.036$ ($r = 4, 5$) $\rightarrow 0.0327$ ($r = 16$), наближаючись до $1/m$. Довший ключ зміщує більше зсунутих алфавітів, і частоти літер вирівнюються.

2. За якими ознаками визначено довжину ключа? При $r = 13$ середній індекс блоків (0.0541) близький до індексу мови, а для інших r — до $1/m$; $D_{13} = 456$ значно більше фону 230–280; піки повторюються на кратному значенні $r = 26$.

3. Які альтернативні кандидати досліджено? $r = 26$ (другий пік) — кратне 13, тому не є мінімальним періодом; $r = 21$ і 28 (найбільші D_r серед некратних 13) — середній індекс $\approx 1/m$ і безглузді ключі, тобто це випадкові коливання.

4. Яка статистика використовувалась для відновлення ключа? Найчастіша літера y^* кожного блоку та порядок частот літер мови з першого практикуму (o, e, a); $k = (y^* - x^*) \bmod m$.

5. Як перевірити ключ без відкритого тексту? Розшифрований текст читається; його індекс відповідності близький до індексу мови; частоти літер збігаються з частотами мови; ключ змістовний.

6. Як змінився результат після помилки в ключі? Неправильно розшифровано лише кожен 13-ту літеру (620 з 8061), усі на одну літеру назад. Спотворення періодичне з періодом ключа, решта тексту правильна.

7. Які етапи найбільше залежать від обсягу шифртексту? Визначення періоду і особливо відновлення ключа: на кожен блок припадає лише n / r літер (тут ≈ 620). Навіть при такому обсязі у 4 з 13 блоків найчастішою виявилась не «о». Для коротшого тексту або довшого ключа статистика блоків стає ненадійною.

8. Що найкраще демонструє слабкість шифру? Різкий стрибок індексу відповідності при $r = 13$ і відновлення ключа простим підрахунком найчастіших літер: періодичний ключ зводить шифр до 13 незалежних шифрів Цезаря, які зберігають статистику мови.

Висновки

Шифр Віженера з періодичним ключем зберігає статистику мови всередині кожного блоку, тому період легко знаходиться за індексом відповідності та статистикою D_r ($r = 13$), а ключ — частотним аналізом блоків. Для варіанта 4 знайдено ключ «гromыковедьма» і повністю розшифровано текст. Метод найчастішої літери дає помилки в окремих блоках, але вони легко виправляються вибором наступної імовірної літери мови. Помилка в одному символі ключа псує лише кожен r -ту літеру і не поширюється далі.