КРИПТОГРАФІЯ

КОМП’ЮТЕРНИЙ ПРАКТИКУМ №2

Криптоаналіз шифру Віженера
Варіант 10

Виконали: студенти групи ФБ-41
Михайленко Ростислав,
Міроненко Микита.

1. Мета роботи

Засвоїти методи частотного криптоаналізу та набути практичних навичок аналізу потокових шифрів гамування адитивного типу на прикладі шифру Віженера. Дослідити залежність статистичних властивостей шифртексту від довжини періодичного ключа, визначити довжину невідомого ключа за індексом відповідності та статистикою збігів D_r, відновити ключ і відкритий текст, а також дослідити вплив помилки в одному символі ключа на результат розшифрування.

2. Вихідні дані та правила їх підготовки

Використовується алфавіт із 32 літер російської мови: абвгдежзийклмнопрстуфхцчшщъыьэюя (m = 32). Літерам відповідають номери 0–31, додавання та віднімання виконуються за модулем 32. Літера «ё» замінюється на «е», текст переводиться до нижнього регістру, а пробіли, розділові знаки, цифри й символи поза алфавітом вилучаються.

Для першої частини використано власний російськомовний текст обсягом 2187 літер після очищення. Індекс відповідності відкритого тексту становить 0.054446. Для криптоаналізу використано шифртекст варіанта 10; після очищення його довжина n = 6451 літера, індекс відповідності I(ШТ) = 0.032864.

Теоретичний індекс для рівноімовірного алфавіту: $I_0 = 1/32 = 0.03125$. За частотами літер із КП №1 (без пробілів, «ё» об’єднано з «е») індекс мови дорівнює I(мови) = 0.055534. Порогове значення для пошуку періоду: $(I(\text{мови}) + I_0)/2 = 0.043392$.

3. Короткий опис програмних засобів

Програму реалізовано мовою Python і поділено на модулі:

• vigenere.py — алфавіт, нормалізація тексту, шифрування та розшифрування шифром Віженера;

• stats.py — індекс відповідності, статистика збігів D_r, розбиття шифртексту на блоки та середній індекс відповідності блоків;

• attack.py — частоти літер мови та відновлення символів ключа за критерієм χ^2;

• main.py — послідовне виконання завдань практикуму та виведення результатів;

• generate_plots.py — побудова графіків залежності середнього індексу відповідності та нормованої статистики D_r від r.

Використані формули:

• $I(Y) = \Sigma N_i(N_i - 1) / (n(n - 1))$ — індекс відповідності;

• $D_r = \Sigma \delta(y_i, y_{i+r})$ — кількість збігів літер шифртексту на відстані r;

• $k = (y^* - x^*) \bmod 32$ — оцінка символу ключа за найчастішою літерою блока y^* та припущеною літерою мови x^*;

• $\chi^2(k) = \Sigma (O_i - n \cdot p_i)^2 / (n \cdot p_i)$ — критерій порівняння частот розшифрованого блока з частотами російської мови.

Під час пошуку періоду розглядаються r = 2…30. Основним орієнтиром є перевищення середнім індексом відповідності блоків порога 0.043392; результат додатково перевіряється статистикою D_r та кратністю кандидатів.

4. Дослідження шифру на власному тексті

Один і той самий відкритий текст було зашифровано п’ятьма ключами довжини 2, 3, 4, 5 та 13. Очікується, що поєднання різних зсувів Цезаря вирівнюватиме розподіл літер шифртексту, а індекс відповідності наближатиметься до $I_0 = 0.03125$. Орієнтовна модель для r різних зсувів: $I(r) \approx I(\text{мови})/r + (1 - 1/r) \cdot I_0$.

Текст	Ключ	r	I (експеримент)	I (оцінка за моделлю)
Відкритий текст	—	—	0.054446	0.055534
Шифртекст	да	2	0.044884	0.043392
Шифртекст	мир	3	0.040523	0.039345
Шифртекст	ключ	4	0.035051	0.037321
Шифртекст	слово	5	0.038002	0.036107
Шифртекст	шелестстраниц	13	0.033223	0.033118

Таблиця 1 — Індекси відповідності відкритого тексту та шифртекстів для ключів різної довжини

Індекс відповідності зменшився з 0.054446 для відкритого тексту до 0.033223 для ключа довжини 13, наблизившись до I_0. Це підтверджує прогноз. Послідовність не є строго монотонною: для ключа «слово» (r = 5) значення 0.038002 вище, ніж для «ключ» (r = 4), оскільки в ключі «слово» літера «о» повторюється, отже використовується чотири різні зсуви з нерівними частками. Результат також залежить від скінченного обсягу тексту.

5. Криптоаналіз шифртексту варіанта 10: визначення довжини ключа

5.1. Середній індекс відповідності блоків та статистика D_r

Для кожного r = 2…30 шифртекст довжини n = 6451 розбито на r блоків $Y_i = y_i, y_{i+r}, y_{i+2r}, \ldots$. Для кожного блока обчислено індекс відповідності, після чого знайдено середнє значення. Також обчислено кількість збігів D_r та нормовану статистику $D_r/(n - r)$.

r	Avg IC	D_r	$D_r/(n-r)$	Середня довжина блока
2	0.032878	206	0.031943	3225
3	0.035515	187	0.029001	2150
4	0.032861	196	0.030402	1612
5	0.038953	213	0.033044	1290
6	0.035550	217	0.033670	1075
7	0.032812	203	0.031502	921
8	0.032864	217	0.033680	806
9	0.035534	196	0.030425	716
10	0.039067	221	0.034311	645
11	0.032882	205	0.031832	586
12	0.035520	186	0.028886	537
13	0.032756	218	0.033861	496
14	0.032723	209	0.032469	460
15	0.054125	337	0.052362	430
16	0.032808	200	0.031080	403
17	0.032849	194	0.030152	379
18	0.035573	216	0.033577	358
19	0.032595	198	0.030784	339
20	0.039074	181	0.028145	322
21	0.035220	190	0.029549	307
22	0.032950	225	0.034998	293
23	0.032954	214	0.033292	280
24	0.035418	225	0.035009	268
25	0.038955	183	0.028478	258
26	0.032851	214	0.033307	248
27	0.035261	197	0.030666	238
28	0.032531	202	0.031449	230
29	0.032564	193	0.030053	222
30	0.054126	365	0.056845	215

Таблиця 2 — Середній індекс відповідності блоків та статистика D_r для r = 2…30

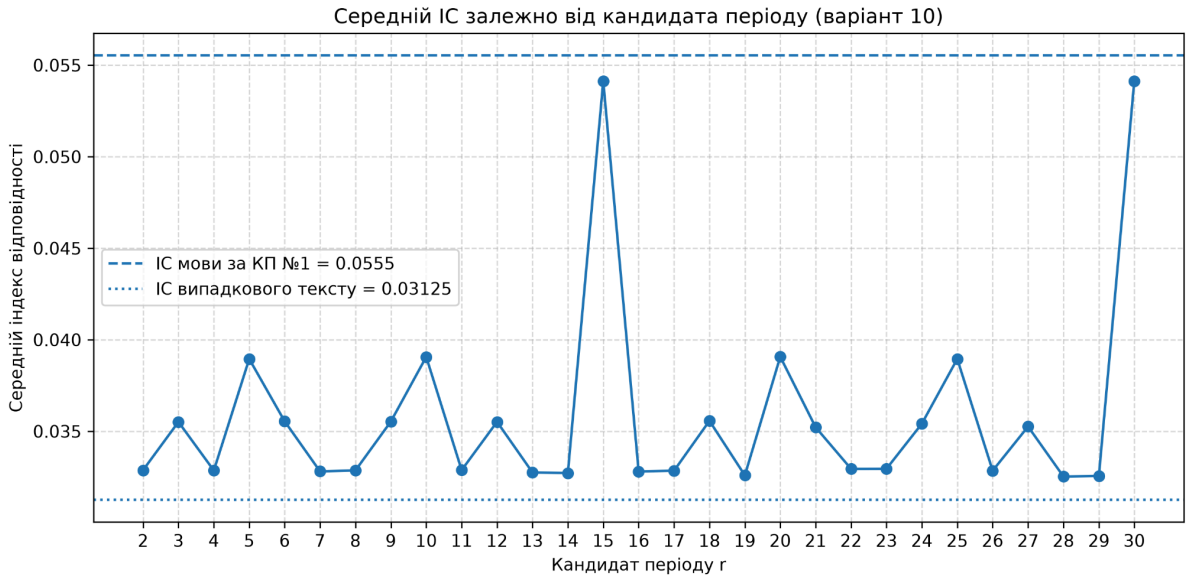


Рисунок 1 — Залежність середнього індексу відповідності блоків від кандидата періоду r

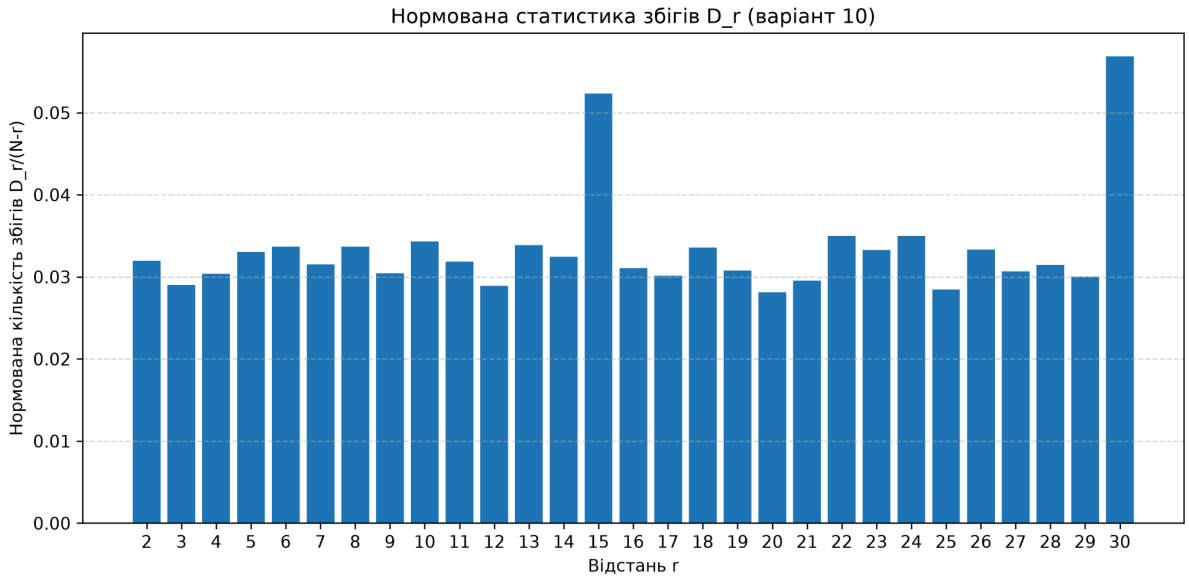


Рисунок 2 — Нормована статистика збігів $D_r/(n-r)$ залежно від відстані r

Для більшості r середній індекс відповідності лежить приблизно в межах 0.0325–0.0391. Різко виділяються r = 15 (0.054125) та r = 30 (0.054126): обидва значення наближаються до індексу природної мови 0.055534. Це означає, що за такого розбиття кожен блок переважно зашифрований одним фіксованим зсувом Цезаря.

Статистика D_r підтверджує результат: для r = 15 отримано $D_{15} = 337$, а для r = 30 — $D_{30} = 365$. Нормовані значення становлять відповідно 0.052362 та 0.056845; для більшості інших r вони перебувають близько до 0.03–0.035.

5.2. Вибір довжини ключа

Порогове значення $(I(\text{мови}) + I_0)/2 = 0.043392$ перевищують лише r = 15 та r = 30. Оскільки $30 = 2 \cdot 15$, найменшим кандидатом є r = 15. Значення при r = 30 є піком, що відповідає кратному періоду; мінімальний період приймаємо рівним 15.

5.3. Аналіз альтернативних кандидатів

Додатково перевірено r = 30 (кратне 15), r = 3 і r = 5 (дільники 15), r = 6 і r = 10 (кратні 3 та 5), r = 14 і r = 16 (сусідні значення), а також r = 29 як контрольний кандидат.

r	**Довжина блока (≈)**	**Avg IC**	**$D_r/(n-r)$**	**Блоків вище порога**	**Висновок**
15	430	0.054125	0.052362	—	істинний мінімальний період
30	215	0.054126	0.056845	—	кратне 15
5	1290	0.038953	0.033044	—	дільник 15; мовного піка немає

10	645	0.039067	0.034311	—	локальне підвищення, але нижче порога
3	2150	0.035515	0.029001	—	дільник 15; мовного піка немає
6	1075	0.035550	0.033670	—	нижче порога
14	460	0.032723	0.032469	—	сусід 15, піка немає
16	403	0.032808	0.031080	—	сусід 15, піка немає
29	222	0.032564	0.030053	—	контрольне значення

Таблиця 3 — Порівняння альтернативних кандидатів на довжину ключа

Для r = 15 та r = 30 середній індекс відповідності перевищує поріг. Інші кандидати не дають такого результату. Для пояснення проміжних підйомів використовується s = 15/gcd(r, 15): блок містить суміш s різних зсувів ключа. Коли s = 3 (наприклад, r = 5, 10, 20, 25), середній індекс вищий за фон; коли s = 5 (r = 3, 6, 9, …), підйом менший; коли s = 15, блоки містять усі зсуви і середній індекс наближається до випадкового рівня.

6. Відновлення ключа та відкритого тексту

6.1. Статистика блоків для r = 15

Шифртекст розбито на 15 блоків довжини приблизно 430–431 літера. Кожен блок зашифровано одним символом ключа, тобто окремим зсувом Цезаря. Для визначення символів ключа використано частоти літер блоків та критерій χ^2, який порівнює частоти після кожного з 32 можливих зсувів із частотами російської мови з КП №1.

Простий вибір найчастішої літери блока та припущення, що їй відповідає «о», дає попередній ключ «крадущяйгявтени». Для двох блоків цього припущення недостатньо: найчастішій літері там краще відповідає інша частотна позиція мови. Критерій χ^2 дозволяє оцінити всі 32 зсуви та отримати остаточний ключ «крадущийсявтени».

Показник	**Результат**
Визначений період	15
Попередній ключ за припущенням x* = «о»	крадущяйгявтени
Ключ після оцінювання χ^2	крадущийсявтени
Кількість символів ключа	15

Таблиця 4 — Підсумок відновлення ключа

6.2. Знайдений ключ та розшифрування

Знайдений ключ: крадущийсявтени (15 літер; фраза «крадущийся в тени»). Після розшифрування отримано читабельний російськомовний текст. Його початок після очищення від пробілів і розділових знаків:

тихотактихочтослышнокакмотылькицепляютсяхрупкимикрылышкамиз
аночнуюпрохладупораужеотправлятьсяпосвоимделамстражадавнопро
шланоясегоднячтотослишкомосторожничаюнекоенеобъяснимоечувство
заставляетменязадержатьсявозлестеныздانияпогруженноговтень

Кінець розшифрованого тексту: «…а пока придется держаться тени жмущейся к стенам высоких зданий которая стала бледной и пугливой от вездесущего света».

6.3. Перевірка ключа без знання початкового тексту

Показник	**Значення**
I(шифртексту)	0.032864
I(розшифрованого тексту)	0.053894
I(мови) за КП №1	0.055534
Найчастіші літери розшифрованого тексту	о, е, а, н, и, т
Результат перевірки	Текст читабельний; статистика близька до мовної

Таблиця 5 — Перевірка правильності відновленого ключа

Індекс відповідності розшифрованого тексту 0.053894 значно ближчий до індексу мови 0.055534, ніж індекс шифртексту 0.032864. Додатковою перевіркою є читабельність отриманого тексту та змістовність ключа. Отже, відновлення можна вважати правильним.

7. Дослідження впливу помилки в ключі

Для експерименту перший символ ключа «к» замінено на «а»: правильний ключ «крадущийсявтени», ключ із помилкою «арадущийсявтени». Оскільки період дорівнює 15, перший символ ключа використовується на позиціях i mod 15 = 0. Тому помилка має вплинути лише на кожну п’ятнадцяту літеру.

Показник	**Результат**
Правильний ключ	крадущийсявтени
Ключ із помилкою	арадущийсявтени
Довжина тексту	6451
Кількість змінених літер	431
Частка змінених літер	6.68%

Усі зміни на позиціях i mod 15 = 0	Так
Зсув змінених літер	+10 (mod 32)

Таблиця 6 — Результати експерименту з помилкою в одному символі ключа

Експеримент підтвердив прогноз: змінено 431 із 6451 літер (6.68%), усі на позиціях i mod 15 = 0. Зсув усіх змінених літер однаковий — +10 за модулем 32, оскільки номер літери «к» дорівнює 10, а «а» — 0. Решта 6020 літер не змінилася. Помилка не поширюється на сусідні позиції, а повторюється з періодом ключа.

8. Відповіді на питання для аналізу результатів

1. Як змінювався індекс відповідності шифртексту при використанні ключів різної довжини? Поясніть отриманий результат.

Для відкритого тексту I = 0.054446. Для шифртекстів отримано 0.044884 (r = 2), 0.040523 (r = 3), 0.035051 (r = 4), 0.038002 (r = 5) та 0.033223 (r = 13). Загалом індекс наближається до $I_0 = 0.03125$, оскільки різні зсуви розподіляють частотні піки по різних символах. Невелике відхилення для r = 5 пояснюється повторенням літери «о» в ключі «слово».

2. За якими ознаками було визначено найбільш імовірну довжину невідомого ключа?

За середнім індексом відповідності блоків та статистикою D_r. Для r = 15 середній IC = 0.054125, а для r = 30 — 0.054126; обидва значення близькі до індексу мови 0.055534. Водночас $D_{15} = 337$ та $D_{30} = 365$ є виразними піками. Оскільки 30 кратне 15, мінімальний період дорівнює 15.

3. Які альтернативні кандидати на довжину ключа ви досліджували, чому обрали саме їх та які результати отримали?

Перевірено r = 30 як кратне 15; r = 3 і 5 як дільники; r = 6 і 10 як кратні цих дільників; r = 14 і 16 як сусідні значення; r = 29 як контрольне. Лише r = 15 та 30 перевищили поріг 0.043392. Для решти середній IC залишився в межах приблизно 0.0325–0.0391, тому їх відхилено.

4. Яка статистична інформація використовувалася для відновлення окремих символів ключа?

Використовувалися частоти символів у кожному з 15 блоків, найчастіша літера блока та її кількість, а також χ^2 для всіх 32 можливих зсувів. Критерій χ^2 порівнює частоти розшифрованого блока з частотами російської мови, отриманими в КП №1. Зсув із найменшим χ^2 обирається як символ ключа для відповідного блока.

5. Як можна перевірити правильність відновленого ключа, не знаючи початкового відкритого тексту?

Після розшифрування індекс відповідності має наблизитися до індексу природної мови: у роботі отримано 0.053894 проти 0.055534. Також перевіряють частотний розподіл літер і читабельність тексту. Додатковою ознакою є узгодженість довжини ключа з періодом, знайденим статистичними методами.

6. Як змінився результат розшифрування після внесення помилки в один символ ключа? Поясніть характер і періодичність змін.

Після заміни «к» на «а» змінилася 431 літера з 6451 (6.68%). Усі зміни припали на позиції і mod 15 = 0 та мали однаковий зсув +10 mod 32. Інші 6020 літер залишилися незмінними, оскільки кожен символ періодичного ключа впливає лише на відповідний клас позицій.

7. Які етапи проведеного криптоаналізу найбільше залежать від обсягу доступного шифртексту? Чому?

Найбільше від обсягу залежать пошук періоду та відновлення символів ключа. Зі збільшенням довжини тексту статистичні піки стають помітнішими, а частоти в кожному блоці — точнішими. За короткого шифртексту випадкові коливання частот можуть завадити правильно визначити період або символ ключа.

8. Які результати ваших експериментів найкраще демонструють слабкість шифру Віженера з періодичним ключем?

Слабкість демонструють виразні піки IC та D_r при r = 15 і 30, можливість розділити шифртекст на 15 блоків і відновити ключ частотним аналізом, а також експеримент із помилкою: змінилася лише кожна п’ятнадцята літера. Це показує, що шифр із періодичним ключем зводиться до набору зсувів Цезаря та не забезпечує достатньої стійкості за наявності довгого шифртексту.

9. Висновки

У роботі досліджено шифр Віженера та виконано його криптоаналіз частотними методами. Для власного відкритого тексту довжиною 2187 літер індекс відповідності зменшився з 0.054446 до 0.033223 зі збільшенням довжини ключа до 13, наблизившись до індексу випадкового тексту 0.03125.

Для шифртексту варіанта 10 довжиною 6451 літера визначено мінімальний період ключа r = 15. Це підтверджують середній індекс відповідності блоків 0.054125 та статистика $D_{15} = 337$; аналогічні піки при r = 30 пояснюються кратністю періоду.

Ключ відновлено частотним аналізом блоків і критерієм χ^2: «крадущийсявтени». Індекс відповідності розшифрованого тексту становить 0.053894, що близько до індексу російської мови за КП №1 — 0.055534. Експеримент із заміною одного символу ключа змінив лише 431 із 6451 літер (6.68%), що підтверджує періодичний характер впливу ключа.

Отже, практична робота показала, що шифр Віженера з коротким або повторюваним ключем може бути зламаний статистичними методами за достатнього обсягу шифртексту.