Міністерство освіти і науки України
Національний технічний університет України
"Київський політехнічний інститут імені Ігоря Сікорського"
Фізико-технічний інститут

КРИПТОГРАФІЯ

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №3

«Криптоаналіз афінної біграмної підстановки»

Виконали студенти групи ФБ-43 Вориняк Василь та Оніщук Максим

Перевірила: Селюх Поліна Валентинівна

Київ - 2026

Мета: Набуття навичок частотного аналізу на прикладі розкриття моноалфавітної підстановки; опанування прийомами роботи в модулярній арифметиці.

Постановка задачі

Дано шифртекст, отриманий афінною підстановкою біграм з російського тексту без пробілів, розділових знаків і великих літер. Алфавіт містить 31 літеру (ё замінено на е, ъ і ь об'єднано), m = 31. Біграма (x1, x2) переводиться в число X = 31·x1 + x2. Шифрування: Y = (aX + b) mod 961, розшифрування: X = a^{-1}(Y - b) mod 961, де a взаємно просте з 31.

Потрібно знайти ключ (a, b), зіставляючи п'ять найчастіших біграм мови з п'ятьма найчастішими біграмами шифртексту, автоматично відібрати змістовний текст і розшифрувати шифртекст.

Варіант 8: шифртекст variants/08.txt, 8940 літер (4470 біграм), у папці роботи це файл 08.txt. Для налагодження програми використано тестовий файл for_test/V8 (V8.txt), 5080 літер.

Хід роботи

1. Математичні підпрограми

Функція egcd обчислює d = gcd(a, b) і коефіцієнти u, v, для яких d = ua + vb, за рекурентними формулами з методички. Функція inverse повертає u mod n, якщо gcd(a, n) = 1, і None, якщо оберненого елемента не існує. Функція solve розв'язує порівняння ax ≡ b (mod n): якщо d = gcd(a, n) = 1, розв'язок один; якщо b не ділиться на d, розв'язків немає; інакше повертаються всі d розв'язків x0 + k·n/d, де x0 = (b/d)·$(a/d)^{-1}$ mod (n/d).

```python
def egcd(a, b):
    u0, u1, v0, v1 = 1, 0, 0, 1
    while b:
        q = a // b
        a, b = b, a - q * b
        u0, u1 = u1, u0 - q * u1
        v0, v1 = v1, v0 - q * v1
    return a, u0, v0


def inverse(a, n):
    d, u, _ = egcd(a % n, n)
    return u % n if d == 1 else None


def solve(a, b, n):
    a, b = a % n, b % n
    d = egcd(a, n)[0]
    if b % d:
        return []
    n1 = n // d
    x0 = b // d * inverse(a // d, n1) % n1
    return [x0 + k * n1 for k in range(d)]
```

Результат виконання:

```
17^(-1) mod 961 = 848
-155x = 248 (mod 961): [17, 48, 79, 110, 141, 172, 203, 234, 265, 296, 327, 358, 389, 420, 451, 482, 513, 544, 575, 606, 637, 668, 699, 730
, 761, 792, 823, 854, 885, 916, 947]
-155x = 250 (mod 961):
```

2. Частоти біграм мови

За результатами КП1 (роман «Бесы», текст без пробілів, біграми без перетину) п'ять найчастіших біграм такі: то 0.01702, ов 0.01374, ст 0.01323, но 0.01284, не 0.01266. Три з п'яти біграм методички (то, ст, но) підтверджуються, на і ен у цьому тексті трохи рідші. Частоти найчастіших біграм близькі, тому їхній порядок залежить від тексту. Для атаки використано набір з методички: ст, но, то, на, ен.

3. П'ять найчастіших біграм шифртексту

Шифр замінює біграми без перетину, тому частоти рахувалися функцією bigrams(t, 2) з КП1. П'ять найчастіших біграм шифртексту варіанту 8: жц (65 разів, 0.01454), дэ (62, 0.01387), цэ (60, 0.01342), сц (57, 0.01275), оц (55, 0.01230).

```
жц 65 0.01454
дэ 62 0.01387
цэ 60 0.01342
сц 57 0.01275
оц 55 0.0123
```

4. Кандидати на ключ

Для кожної пари біграм мови X1, X2 (10 пар з ст, но, то, на, ен) і кожної впорядкованої пари біграм шифртексту Y1, Y2 (20 пар) розв'язувалася система (1): функцією solve знаходяться всі a з порівняння $a(X1 - X2) \equiv Y1 - Y2 \pmod{961}$, потім $b = (Y1 - a \cdot X1) \bmod 961$. Значення a, кратні 31, відкидаються, бо вони не обертаються за модулем 961.

Усього 200 систем дали 348 різних кандидатів на ключ. Кожним кандидатом шифртекст розшифровувався і перевірявся розпізнавачем.

5. Розпізнавач російської мови

Текст вважається змістовним, якщо сумарна частота літер о, а, е не менша за 0.22 і в ньому немає жодної забороненої біграми з набору аь, еь, иь, оь, уь, ыь, эь, юь, яь, йь, ьь.

Обґрунтування першої умови. За частотами літер з КП1 о+а+е = 0.1137 + 0.0890 + 0.0788 = 0.2815, а у випадковому рівноймовірному тексті 3/31 = 0.0968. Неправильний ключ дає текст, близький до випадкового, тому поріг 0.22 взято між цими значеннями, ближче до мовного. Так відкидаються і тексти, в яких правильно розшифровано лише частину літер.

Обґрунтування другої умови. М'який знак не пишеться після голосної, й та іншого ь, а слова з нього не починаються, тому такі біграми не з'являються навіть на межі слів у тексті без пробілів. У матриці біграм з КП1 жодна з них не трапилась. У випадковому тексті кожна біграма має ймовірність 1/961, тож на 8940 літер припадає в середньому

близько 100 заборонених біграм. Біграми рахуються з перетином, тому умова перевіряє і стики між зашифрованими парами (x2i, x2i+1).

Правильний текст проходить обидві умови із запасом, а кожна умова окремо відкидає всіх неправильних кандидатів

6. Перевірка на тестовому файлі

Програму спочатку перевірено на тестовому файлі V8.txt. П'ять найчастіших біграм: вв, эл, ух, чй, ьь. З 176 кандидатів розпізнавач прийняв лише (827, 58), розшифрований текст починається словами «а годы шли да шли»

```
Кандидатів на ключ: 176
Ключ (827, 58): о+а+е = 0.2717, заборонених біграм 0
агодышлидашлибыстроинеслышнокакподснежныеводыпротекаламолодостьеленывбездействиивнешнемвовнутреннейб
Відкинуто 175: о+а+е не більше 0.2004, заборонених біграм не менше 11
```

7. Розкриття варіанту і труднощі

З нумерацією алфавіту з методички (ы = 26, ь = 27) розпізнавач відкинув усі 348 кандидатів. Частота о+а+е в найкращого кандидата (0.2549) була вище порогу, але жоден кандидат не мав менше 13 заборонених біграм. Ця сама програма розшифрувала тестовий файл, отже, проблема в даних варіанту.

```
MacBook-Pro lab3 % python3 3_attack.py V8.txt
Кандидатів на ключ: 176
Ключ (827, 58): о+а+е = 0.2717, заборонених біграм 0
агодышлидашлибыстроинеслышнокакподснежныеводыпротекаламолодостьеленывбездействиивнешнемвовнутреннейб
Відкинуто 175: о+а+е не більше 0.2004, заборонених біграм не менше 11
```

Методичка каже, що ъ замінено на ь «або навпаки», тобто об'єднана літера може стояти на місці ъ, перед ы. З нумерацією ь = 26, ы = 27 (параметр swap) розпізнавач прийняв рівно одного кандидата, (17, 94). Найчастіші біграми мови і шифртексту не містять ь та ы, тому набір із 348 кандидатів однаковий для обох нумерацій, а відрізняється лише розшифрування.

```
MacBook-Pro lab3 % python3 3_attack.py 08.txt swap
Кандидатів на ключ: 348
Ключ (17, 94): о+а+е = 0.2651, заборонених біграм 0
мальчикизаулыбалисьисжаромвзялисьзаделоонирвализолотистыецветыцветычтонаводняютвесьмирпереплескивают
Відкинуто 347: о+а+е не більше 0.2076, заборонених біграм не менше 20
```

Відповіді на контрольні питання

Питання 1. Які статистичні властивості шифртексту були використані під час формування кандидатів на ключ?
Частоти біграм шифртексту без перетину. Афінна підстановка завжди замінює однакові біграми відкритого тексту однаковими біграмами шифртексту, тому розподіл частот біграм зберігається з точністю до перестановки. Отже, найчастіші біграми шифртексту з великою ймовірністю є образами найчастіших біграм мови, і з двох таких зіставлень складається система (1).

Питання 2. Чому не кожне зіставлення частих біграм відкритого тексту та шифртексту приводить до допустимого ключа?
Порівняння $a(X1 - X2) \equiv Y1 - Y2 \pmod{961}$ не має розв'язків, якщо X1 - X2 ділиться на 31, а Y1 - Y2 ні. Розв'язок a може ділитися на 31, тоді він не обертається за модулем 961 і

розшифрування неможливе. Нарешті, якщо біграми зіставлено неправильно, ключ формально допустимий, але дає безглуздий текст: так було з 347 кандидатами з 348.

Питання 3. Чи виникали під час криптоаналізу випадки, коли одне зіставлення біграм давало декілька кандидатів на ключ? Як такі кандидати оброблялися?
Так. Якщо дві біграми мови мають однакову другу літеру (но і то) і дві біграми шифртексту теж (оц і жц), то різниці X1 - X2 = -155 і Y1 - Y2 = 248 діляться на 31, і порівняння має 31 розв'язок (див. вивід 1_modarith.py). Функція solve повертає всі розв'язки, кожен дає свого кандидата, і всі вони перевіряються розпізнавачем нарівні з іншими. Правильне значення a = 17 є першим з цих 31 розв'язку.

Питання 4. За якими ознаками серед отриманих кандидатів було визначено правильний ключ?
Ключ (17, 94) єдиний пройшов розпізнавач: о+а+е = 0.2651, заборонених біграм немає, текст читається.

Питання 5. Який критерій автоматичного розпізнавання осмисленого тексту було використано? Чому було обрано саме його?
Поєднання критерію частих літер (о+а+е не менше 0.22) і критерію заборонених біграм (жодної біграми з ь після голосної, й чи ь). Обидва прості, швидко обчислюються і дають велику різницю між мовою та випадковим текстом. Частота літер оцінює текст загалом, а заборонені біграми перевіряють і стики між зашифрованими парами, тому відкидають тексти, в яких правильно розшифровано лише частину літер.

Питання 6. Як поводився обраний критерій для правильного відкритого тексту та для результатів розшифрування неправильними ключами?
Для правильного тексту о+а+е = 0.2651 (у мові 0.2815), заборонених біграм 0. Для решти 347 кандидатів о+а+е не більше 0.2076, а заборонених біграм не менше 20, тож кожна умова окремо відкидає їх усіх. З нумерацією алфавіту з методички розпізнавач відкинув усі 348 кандидатів, бо кожен мав щонайменше 13 заборонених біграм.

Висновки

У роботі реалізовано розширений алгоритм Евкліда, обчислення оберненого елемента і розв'язування лінійних порівнянь з поверненням усіх розв'язків, а також атаку на афінну підстановку біграм на основі частотного аналізу.

Для варіанту 8 з 348 кандидатів, отриманих з п'яти найчастіших біграм мови та шифртексту, розпізнавач відібрав єдиний ключ (a, b) = (17, 94). Атака вдалася, бо шифр зберігає частоти біграм: наприклад, біграма «ст» під знайденим ключем переходить у «цэ», одну з найчастіших біграм шифртексту.

Розпізнавач на основі частоти літер о, а, е і заборонених біграм з ь чітко відділив змістовний текст від результатів неправильних ключів. Він же допоміг виявити особливість варіанту: нумерацію алфавіту, в якій ь стоїть перед ы.