

КРИПТОГРАФІЯ

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №3

Криптоаналіз афінної біграмної підстановки

Мета роботи

Набуття навичок частотного аналізу на прикладі розкриття моноалфавітної підстановки; опанування прийомами роботи в модулярній арифметиці.

Необхідні теоретичні відомості

1. Опис афінного шифру біграмної заміни

Афінна підстановка біграм являє собою наступне криптографічне перетворення. Відкритий текст $x_1, x_2, x_3, \dots$, розбивається на біграми, що не перетинаються: (x_1, x_2) , (x_3, x_4) , Нехай m – кількість букв в алфавіті. Занумеруємо букви алфавіту числами від 0 до $m-1$; тоді кожній біграмі (x_{2i-1}, x_{2i}) можна єдиним чином співставити число X_i у границях від 0 до m^2-1 :

$$(x_{2i-1}, x_{2i}) \leftrightarrow X_i = x_{2i-1}m + x_{2i}.$$

Наприклад, біграмі $(e, b) = (2, 1)$ при $m = 31$ відповідає число $X = 2 \cdot 31 + 1 = 63$.

Біграми шифруються незалежно за таким правилом. Нехай $X_i = (x_{2i-1}, x_{2i})$ – біграма відкритого тексту, а $Y_i = (y_{2i-1}, y_{2i})$ – відповідна біграма шифрованого тексту. Тоді

$$Y_i = (aX_i + b) \bmod m^2,$$

де $0 < a < m^2$ – число, взаємно просте з m , $0 \leq b < m^2$ – довільне число у вказаних границях. Таким чином, ключ шифру афінної підстановки складається з пари чисел a і b .

При розшифруванні виконується обернене перетворення:

$$X_i = a^{-1}(Y_i - b) \bmod m^2$$

2. Атака на афінний шифр

Афінна підстановка при атаці, що базується тільки на знанні шифртексту, розкривається за допомогою *частотного аналізу*, що ґрунтується на такому спостереженні: афінний шифр зберігає статистичні властивості мови, пов'язані із частотами біграм.

Нехай з деяких міркувань криптоаналітику стало відомо, що біграма X^* перейшла при шифруванні у біграму Y^* , а біграма X^{**} – у біграму Y^{**} . Тоді для невідомих параметрів ключа a, b можна скласти систему рівнянь:

$$\begin{cases} Y^* \equiv aX^* + b \pmod{m^2} \\ Y^{**} \equiv aX^{**} + b \pmod{m^2} \end{cases}, \quad (1)$$

звідки маємо рівняння для визначення параметру a :

$$Y^* - Y^{**} \equiv a(X^* - X^{**}) \pmod{m^2}. \quad (2)$$

Рівняння (2) може мати один або декілька розв'язків. Для кожного можливого значення a відповідне значення b знаходиться з рівняння

$$b = (Y^* - aX^*) \pmod{m^2}.$$

Остаточний ключ шифрування знаходиться перебором по знайдених кандидатах із перевіркою на інших біграмах шифртексту.

Звідки ж аналітик може знати про відповідність біграм відкритого та шифртекстів? Він може скористатись тим, що описаний афінний шифр зберігає частоти біграм мови. Якщо позначити через X^* біграму, що найчастіше зустрічається у мові, X^{**} – наступну за нею за частотою і т.д., Y^* , Y^{**} – біграми шифртексту, що також розташовані в порядку спадання частот, то можна очікувати, що біграма X^* під час шифрування переходить у Y^* , а X^{**} – у Y^{**} , звідки й знаходиться ключ шифрування.

Припущення про те, що X^* та X^{**} шифруються відповідно в Y^* та Y^{**} , може виявитися помилковим. Тоді треба підставляти в (1) інші пари X та Y з числа найбільш імовірних у мові і найчастіших у шифртексті, доки при дешифруванні не вийде змістовний текст.

3. Критерії автоматичного визначення змістовного тексту

При фінальному пошуку з-поміж кандидатів у ключі шифрування, які залишилися після аналізу, ми користуємось тим, що правильний ключ при розшифруванні дає змістовний текст, в той час як неправильні ключі будуть давати випадкові тексти (точніше, імовірність, що на неправильному ключі після розшифрування ми одержимо змістовний текст, є вкрай малою). Звісно, коли кандидатів є невелика кількість, то аналітик може просто переглянути їх всі та обрати правильний візуально. Але коли треба перебрати вже сотню варіантів, використання людини в якості розпізнавача мови є негуманним. Тому в програмах криптографічного аналізу потрібно передбачати засоби автоматичного розпізнавання змістовних текстів та відбору їх від текстів випадкових.

В якості засобів розрізнення текстів на природних мовах виступають їх статистичні властивості. Наведемо деякі поширені критерії відбору змістовних текстів.

1) *Критерій заборонених l-грам*. Деякі комбінації символів в природних мовах не зустрічаються (наприклад, «аь» в українській мові). Отже, поява таких послідовностей у тексті із великою імовірністю свідчить про його випадковість.

Для застосування даного критерію аналітик повинен обрати множину тих l -грам, які він вважає забороненими. Існує декілька варіантів використання критеріїв: в першому текст відкидається за наявності в ньому будь-якої із обраних заборонених l -грам; в другому текст відкидається, якщо частоти появи кожної l -грами не перевищують задане порогове значення; нарешті, в третьому аналітик оцінює сумарну частоту появи в тексті усіх заборонених l -грам та відкидає текст, якщо ця сума перевищує заданий поріг.

2) *Критерій частих l-грам* відрізняється від попереднього тим, що досліджуються комбінації символів, які зустрічаються в мові найчастіше (наприклад, «the» для

англійської мови). Відповідно, появи частих l -грам в змістовному тексті не повинні бути нижчими за деякий поріг.

В цьому критерії можна відслідковувати як частоту окремих літер, так і біграм, триграм тощо. Але зауважте, що описаний в практикумі афінний шифр зберігає частотний профіль незалежних біграм, на які розбивається відкритий текст. При використанні критерію частих біграм для афінного шифру потрібно досліджувати біграми, взяті на перетині шифрованих пар символів – (x_{2i}, x_{2i+1}) в термінах першого розділу.

3) *Критерій рівномірності l -грам* вивчає кількість l -грам, що зустрічаються у тексті. Оскільки природні мови є дуже нерівномірними, багато комбінацій символів в них не зустрічається. Тому аналітик може просто обчислити кількість l -грам, які не зустрічаються в заданому тексті, і якщо ця кількість менша за деяке порогове значення (яке обирається із урахуванням особливостей мови), то текст відкидається.

4) *Ентропійні критерії* порівнюють значення інтегральних характеристик тексту (таких, як ентропії символів та біграм, індекс відповідності тощо) із еталонними для мови.

5) *Структурний критерій* в простий спосіб визначає, чи має одержаний текст надлишковість: якщо текст добре стискається відомими алгоритмами стиснення даних, то він є змістовним. Випадкові ж тексти зазвичай не стискаються взагалі, оскільки не мають надлишковості, притаманної природним мовам.

Існує і безліч інших критеріїв, що виявляють ті чи інші властивості природної мови; також можливе застосування довільних комбінацій цих методів. Якість відбору залежить від налаштування параметрів (порогових та еталонних значень).

4. Додаткові відомості з теорії чисел

Рівність (2) є так званим *лінійним порівнянням*; розв'язки лінійних порівнянь знаходяться за такою процедурою.

Нехай $ax \equiv b \pmod{n}$ і треба встановити значення x за відомими a та b . Маємо такі випадки:

1) $\gcd(a, n) = 1$. В цьому випадку порівняння має один розв'язок: $x \equiv a^{-1}b \pmod{n}$.

2) $\gcd(a, n) = d > 1$. Маємо дві можливості:

2.1) Якщо b не ділиться на d , то порівняння не має розв'язків.

2.2) Якщо b ділиться на d , то порівняння має рівно d розв'язків $x_0, x_0 + n_1, x_0 + 2n_1, \dots, x_0 + (d-1)n_1$, де $a = a_1d, b = b_1d, n = n_1d$ і x_0 є єдиним розв'язком порівняння $a_1x \equiv b_1 \pmod{n_1}$: $x_0 = b_1 \cdot a_1^{-1} \pmod{n_1}$.

Для обчислення обернених елементів за даним модулем пропонується використовувати розширений алгоритм Евкліда.

Нагадаємо, що алгоритм Евкліда обчислює найбільший спільний дільник двох чисел $d = \gcd(a, b)$ таким чином. Задаємо $r_0 = a, r_1 = b$ та обчислюємо послідовність (r_i) для $i \geq 2$ шляхом ділення з остачею:

$$r_0 = r_1q_1 + r_2,$$

$$r_1 = r_2q_2 + r_3,$$

...

$$r_{s-2} = r_{s-1}q_{s-1} + r_s;$$

$$r_{s-1} = r_sq_s.$$

Якщо на відповідному кроці виявилось, що $r_{s+1} = 0$, то $d = r_s$.

Розширений алгоритм Евкліда обчислює дві додаткові послідовності (u_i) та (v_i) такі, що на кожному кроці виконується рівність $r_i = u_ia + v_ib$; зокрема, для найбільшого

спільного дільника матимемо $d = r_s = u_s a + v_s b$. Ці послідовності також можна обчислити рекурентно за допомогою часток q_i :

$$\begin{aligned}u_0 &= 1, u_1 = 0, u_{i+1} = u_{i-1} - q_i u_i; \\v_0 &= 0, v_1 = 1, v_{i+1} = v_{i-1} - q_i v_i.\end{aligned}$$

Звідси обернений елемент до числа a за модулем n знаходиться таким чином: оскільки a обертається лише за умови $\gcd(a, n) = 1$, то за розширеним алгоритмом Евкліда знаходяться такі числа u та v , що $au + nv = 1$. Звідси $au \equiv 1 \pmod{n}$ та $u \equiv a^{-1} \pmod{n}$.

Порядок виконання роботи

0. Уважно прочитати методичні вказівки до виконання комп'ютерного практикуму.
1. Реалізувати підпрограми із необхідними математичними операціями: обчисленням оберненого елемента за модулем із використанням розширеного алгоритму Евкліда, розв'язуванням лінійних порівнянь. При розв'язуванні порівнянь потрібно коректно обробляти випадок із декількома розв'язками, повертаючи їх усі.
2. За допомогою програми обчислення частот біграм, яка написана в ході виконання комп'ютерного практикуму №1, знайти 5 найчастіших біграм запропонованого шифртексту (за варіантом).
3. Перебрати можливі варіанти співставлення частих біграм мови та частих біграм шифртексту (розглядаючи пари біграм із п'яти найчастіших). Для кожного співставлення знайти можливі кандидати на ключ (a, b) шляхом розв'язання системи (1).
4. Для кожного кандидата на ключ дешифрувати шифртекст. Якщо шифртекст не є змістовним текстом російською мовою, відкинути цього кандидата.
5. Повторювати дії 3-4 доти, доки дешифрований текст не буде змістовним.

Методичні вказівки

Студентам надається текст, що є результатом шифрування за допомогою афінної підстановки біграм відкритого тексту, написаного російською мовою без пробілів, знаків пунктуації та великих літер. Буква «ё» заміщена буквою «е», а «ъ» – буквою «ь» (або навпаки). Таким чином, алфавіт відкритого тексту складається з 31 букви, що занумеровані в алфавітному порядку: $a = 0, b = 1, \dots, y = 30$.

П'ятьма найчастішими біграмами російської мови (в порядку спадання частот) є біграми «ст», «но», «то», «на», «ен». Перевірте ці відомості за допомогою програми підрахунку частот біграм з комп'ютерного практикуму №1.

Під час дешифрування виникне потреба відрізнити змістовний текст російською мовою від тексту-шуму, що виникає при неправильному дешифруванні. Вважаючи на доволі велику кількість можливих варіантів ключів, для цієї задачі необхідно побудувати автоматичний розпізнавач російської мови. Створення та принцип роботи такого розпізнавача залишається на ваш розсуд; традиційно використовують такі критерії змістовного тексту:

- перевірку частот частих літер («о», «а», «е», частоти можуть розглядатись окремо або в сукупності);
- перевірку частот рідкісних літер («ф», «щ», «ь», частоти також можуть розглядатись окремо або в сукупності);
- перевірку частот біграм, підраховану для біграм «на перетині» (у вищенаведених позначеннях – біграм виду (x_{2i}, x_{2i+1}));
- перевірку частот триграм та довільних l -грам.

Зашифровані файли за варіантами завдань містяться в папці “variants”. Зашифровані файли, що містяться у папці “for_test”, є більш простими для аналізу, ніж основні варіанти, їх можна використовувати для тестування або налаштування ваших програм.

Оформлення звіту

Звіт має містити:

- мету комп’ютерного практикуму;
- постановку задачі та варіант завдання;
- хід роботи, опис труднощів, що виникали, та шляхів їх розв’язання;
- знайдені п’ять найчастіших біграм шифртексту;
- опис роботи запропонованого вами автоматичного розпізнавача російської мови (із обґрунтуванням коректності);
- шифрований та відповідний розшифрований тексти (відповідно до варіанту завдання), знайдене значення ключа;
- відповіді на контрольні питання;
- висновки.

Контрольні питання

1. Які статистичні властивості шифртексту були використані під час формування кандидатів на ключ?
2. Чому не кожне зіставлення частих біграм відкритого тексту та шифртексту приводить до допустимого ключа?
3. Чи виникали під час криптоаналізу випадки, коли одне зіставлення біграм давало декілька кандидатів на ключ? Як такі кандидати оброблялися?
4. За якими ознаками серед отриманих кандидатів було визначено правильний ключ?
5. Який критерій автоматичного розпізнавання осмисленого тексту було використано? Чому було обрано саме його?
6. Як поведився обраний критерій для правильного відкритого тексту та для результатів розшифрування неправильними ключами?

Оцінювання практикуму

Максимальна оцінка за роботу – 8 балів:

- 1 бал — коректність програмної реалізації;
- 2 бали — виконання експериментальної частини, аналіз результатів та оформлення звіту;
- 1 бал — результат індивідуального тестування;
- 3 бали — результат індивідуального усного захисту;
- 1 бал — своєчасне виконання роботи.

Оцінка за програмну реалізацію, експериментальну частину та своєчасність є спільною для бригади. Результати тестування та усного захисту оцінюються для кожного студента індивідуально.